UNIVERSIDADE DO ESTADO DE SANTA CATARINA – UDESC
NOME DO CENTRO – CEAVI
PROGRAMA DE GRADUAÇÃO – ESO

CLARA DOS SANTOS BECKER

PREDIÇÃO DAS FAIXAS DE DESEMPENHO DO IDEB EM MUNICÍPIOS CATARINENSES VIA APRENDIZADO DE MÁQUINA E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

IBIRAMA
2026

CLARA DOS SANTOS BECKER

PREDIÇÃO DO ÍNDICE DO IDEB COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

Trabalho de conclusão apresentado ao curso de Engenharia de Software do Centro de Educação Superior do Alto Vale do Itajaí (CEAVI), da Universidade do Estado de Santa Catarina (UDESC), como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Software.

Orientador: Prof. Dr. Marcelo de Souza

IBIRAMA
2026

Para gerar a ficha catalográfica de teses e
dissertações acessar o link:
https://www.udesc.br/bu/manuais/ficha

dos Santos Becker, Clara
Predição do índice do IDEB com modelos de aprendizado de máquina explicáveis e Indicadores de Desenvolvimento Sustentável / Clara dos Santos Becker. – Ibirama, 2026.
40 p. : il.

Orientador: Prof. Dr. Marcelo de Souza.
Trabalho de Conclusão de Curso – Universidade do Estado de Santa Catarina, Centro de Educação Superior do Alto Vale do Itajaí, Programa de Graduação em Engenharia de Software, Ibirama, 2026.

1. Índice de Desenvolvimento da Educação Básica. 2. Aprendizado de Máquina. 3. Objetivos de Desenvolvimento Sustentável. 4. Interpretabilidade de Modelos. 5. Políticas Públicas Educacionais. I. de Souza, Marcelo. II. Universidade do Estado de Santa Catarina, Centro de Educação Superior do Alto Vale do Itajaí, Programa de Graduação em Engenharia de Software. III. Predição do índice do IDEB com modelos de aprendizado de máquina explicáveis e Indicadores de Desenvolvimento Sustentável.

ERRATA

Elemento opcional.

Exemplo:

Sobrenome, Prenome do Autor. Título de obra: subtítulo (se houver). Ano de depósito. Tipo do trabalho (grau e curso) - Vinculação acadêmica, local de apresentação/defesa, data.

Folha	**Linha**	**Onde se lê**	**Leia-se**
1	10	auto-conclavo	autoconclavo

CLARA DOS SANTOS BECKER

PREDIÇÃO DO ÍNDICE DO IDEB COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

Trabalho de conclusão apresentado ao curso de Engenharia de Software do Centro de Educação Superior do Alto Vale do Itajaí da Universidade do Estado de Santa Catarina, como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Software Orientador: Prof. Dr. Marcelo de Souza

BANCA EXAMINADORA:

Prof°. Marcelo de Souza Dr.
Universidade do Estado de Santa Catarina

Membros:

Nome do Orientador e Titulação.
Nome da Instituição

Nome do Orientador e Titulação
Nome da Instituição

Nome do Orientador e Titulação
Nome da Instituição

Joinville, 01 de maio de 2026

Dedico aos meus pais por sempre serem meu maior exemplo de dignidade, força e resiliência. Especialmente à minha mãe, que me ensinou a conquistar a liberdade feminina através dos estudos.

AGRADECIMENTOS

Agradeço primeiramente aos meus pais, Hertz Becker e Rejane Clezar, por sempre me incentivarem e me apoiarem ao longo de toda a minha trajetória pessoal e acadêmica. Sou grata também pelo apoio da minha irmã, Gabriela, por sempre me ouvir quando as coisas pesaram, espero um dia ser uma inspiração para ela. Minha conquista acadêmica não é apenas minha, mas de toda a minha família, que sempre fez o que estava ao seu alcance e além, para me dar oportunidades.

Agradeço também ao meu orientador, Prof. Dr. Marcelo de Souza, pela orientação ao longo dos anos, pela colaboração em vários projetos de pesquisa e por aceitar conduzir este trabalho de conclusão de curso. Meu agradecimento também por mostrar que a pesquisa é um caminho a se seguir e por ser um verdadeiro exemplo de pesquisador.

Sou grata aos meus amigos Thaiane Bento, Erick Warmling, Lucas Gitirana, Thassyana Alves e Marco Possamai que se tornaram uma segunda família em Ibirama, especialmente ao meu mais querido amigo e colega Lucas Falcade, minha dupla de faculdade. Nosso apoio mútuo durante toda a jornada acadêmica fez toda a diferença. Agradeço também aos meus amigos felinos de quatro patas, Jade e Vesguinho, que me acompanharam em todos os momentos, sempre à procura de carinho.

Agradeço também aos outros pilares da minha vida Luz Bopsin, minha melhor amiga há 13 anos que me viu por todas as fases e transformações e sempre decidiu estar ao meu lado. Agradeço por fim ao meu namorado Matheus Oliver por me acompanhar na jornada do desenvolvimento desse trabalho e por sempre acreditar no meu potêncial.

Como disse Taylor Swift: "Nenhum de nós fez isso sozinho. Cada um de nós é uma colcha de retalhos daqueles que nos amaram, daqueles que acreditaram em nosso futuro, daqueles que nos mostraram empatia e bondade ou nos disseram a verdade mesmo quando não era fácil de ouvir". A todos os que foram minha colcha de retalhos nesta jornada, meu muito obrigada.

“Que ninguém se engane: a liberdade é
conquistada a duras penas, mas é o único chão
onde vale a pena pisar.” (Lispector, Clarice)

RESUMO

A qualidade da educação básica é frequentemente avaliada de forma isolada, sem considerar os fatores socioeconômicos e ambientais que impactam o desempenho escolar fora do ambiente de sala de aula. Neste contexto, os indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC) oferecem uma perspectiva multidimensional que pode ser explorada para compreender o desempenho educacional em nível municipal. Este trabalho propõe analisar o desempenho de modelos preditivos baseados em árvores de decisão na tarefa de classificação das faixas de desempenho do Índice de Desenvolvimento da Educação Básica (IDEB) nos municípios do estado de Santa Catarina, com dados do IDSC. A metodologia compreende etapas de análise exploratória, pré-processamento com remoção preventiva de vazamento de dados, seleção de atributos por filtragem de correlação e remoção dos indicadores com relação à educação, além de validação cruzada para ajuste de hiperparâmetros. Foram comparados os algoritmos *Random Forest*, *XGBoost*, *LightGBM* e *CatBoost*, avaliados separadamente para os Anos Iniciais (AI) e para os Anos Finais (AF) do ensino fundamental, por meio de Acurácia, Precisão, *Recall* e F1-*score* (macro). Algoritmos do tipo *Gradient Boosting*, obtiveram o melhor desempenho preditivo nas duas variáveis alvo, embora com diferenças pequenas entre os modelos. A análise de importância dos atributos mostrou que os indicadores de saúde pública (ODS 3) concentram a maior parcela da importância na separação das faixas do IDEB nos Anos Finais. Portanto, os resultados indicam associação entre o contexto socioeconômico dos municípios catarinenses e as faixas de desempenho do IDEB, fornecendo embasamentos quantitativos e interpretáveis para o planejamento e a formulação de políticas públicas integradas na gestão educacional.

Palavras-chave: Índice de Desenvolvimento da Educação Básica; Aprendizado de Máquina; Objetivos de Desenvolvimento Sustentável; Interpretabilidade de Modelos; Políticas Públicas Educacionais.

ABSTRACT

The quality of basic education is frequently assessed in isolation, without considering the socioeconomic and environmental factors that impact school performance outside the classroom environment. In this context, the indicators from the Sustainable Development Cities Index (IDSC) offer a multidimensional perspective that can be explored to understand educational performance at the municipal level. This work aims to analyze the performance of decision tree-based predictive models in the classification task of the performance bands of the Basic Education Development Index (IDEB) in the municipalities of the state of Santa Catarina, using IDSC data. The methodology comprises exploratory data analysis stages, preprocessing with preventive removal of data leakage, feature selection via correlation filtering and removal of education-related indicators, as well as cross-validation for hyperparameter tuning. The algorithms *Random Forest*, *XGBoost*, *LightGBM*, and *CatBoost* were compared, evaluated separately for Early Years (AI) and Final Years (AF) of elementary school, using Accuracy, Precision, *Recall*, and F1-*score* (macro). Gradient Boosting algorithms achieved the best predictive performance for both target variables, although with small differences among models. Feature importance analysis showed that public health indicators (SDG 3) concentrate the largest share of importance in separating the IDEB performance bands in the Final Years. Therefore, the results indicate an association between the socioeconomic context of Santa Catarina municipalities and the IDEB performance bands, providing quantitative and interpretable grounds for the planning and formulation of integrated public policies in educational management.

Keywords: Basic Education Development Index; Machine Learning; Sustainable Development Goals; Model Interpretability; Educational Public Policies.

LISTA DE ILUSTRAÇÕES

Figura 1 – Matriz de correlação linear entre indicadores do IDSC e o IDEB. 25
Figura 2 – Gráfico de dispersão entre o indicador de Baixa Renda (eixo x) e o IDEB (eixo) com linha de tendência linear. 26
Figura 3 – Organização do projeto. 31
Figura 4 – Importância agregada por ODS para os Anos Finais na base parcial. 35

LISTA DE TABELAS

Tabela 1 – Distribuição dos municípios catarinenses por faixa do IDEB, após os filtros aplicados. 28
Tabela 2 – Espaços de busca dos hiperparâmetros de cada algoritmo. 30
Tabela 3 – Métricas de desempenho no conjunto de teste para Anos Finais (AF) com a base global (sem balanceamento). 33
Tabela 4 – Métricas de desempenho no conjunto de teste para Anos Iniciais (AI) com a base global (sem balanceamento). 33
Tabela 5 – Métricas de desempenho no conjunto de teste para Anos Finais (AF) com a base parcial (sem balanceamento). 34
Tabela 6 – Métricas de desempenho no conjunto de teste para Anos Iniciais (AI) com a base parcial (sem balanceamento). 35

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
BU	Biblioteca Universitária
IN	Instrução Normativa
NBR	Normas Técnicas Brasileiras
TCC	Trabalho de Conclusão de Curso
Udesc	Universidade do Estado de Santa Catarina
IDSC	Índice de Desenvolvimento Sustentável das Cidades
ONU	Organização das Nações Unidas
IDEB	Índice de Desenvolvimento da Educação Básica
ODS	Objetivos de Desenvolvimento Sustentável
XAI	Inteligência Artificial Explicável

LISTA DE SÍMBOLOS

X	Matriz ou vetor de características de entrada (atributos preditores do IDSC)
Y	Variável alvo (faixas de desempenho do IDEB)
$\hat{f}(X)$	Função estimada pelo modelo de aprendizado de máquina
$\hat{y}$	Valor predito pelo modelo
TP	Verdadeiros Positivos (*True Positives*)
TN	Verdadeiros Negativos (*True Negatives*)
FP	Falsos Positivos (*False Positives*)
FN	Falsos Negativos (*False Negatives*)
$F1$	Métrica F_1-*score* (média harmônica entre precisão e *recall*)
K	Número total de classes no problema multiclasse
c	Classe específica avaliada no cenário multiclasse
r	Coeficiente de correlação linear de Pearson
L_1, L_2	Termos de regularização de normas L1 e L2
$\sum$	Símbolo de somatório utilizado nas equações de média e métricas

SUMÁRIO

	Abstract	**9**
1	**INTRODUÇÃO**	**15**
1.1	PROBLEMA	**16**
1.2	OBJETIVOS	**16**
1.3	JUSTIFICATIVA	**17**
1.4	METODOLOGIA	**17**
2	**FUNDAMENTAÇÃO TEÓRICA**	**19**
2.1	APRENDIZADO DE MÁQUINA	**19**
2.1.1	**Paradigmas de Aprendizado de Máquina**	**19**
2.1.2	**Conjunto de Dados**	**19**
2.1.3	**Redução de Dimensionalidade e Seleção de Atributos**	**20**
2.2	MODELOS DE CLASSIFICAÇÃO E PREDIÇÃO	**20**
2.2.1	**Random Forest**	**21**
2.2.2	**Gradient Boosting**	**21**
2.2.3	**Métricas de Avaliação de Modelos de Classificação**	**22**
2.2.4	**Métricas Nativas de Importância Baseadas em Árvores**	**22**
2.3	TRABALHOS CORRELATOS	**23**
3	**ABORDAGEM PROPOSTA**	**25**
3.1	ANÁLISE EXPLORATÓRIA DE DADOS	**25**
3.2	PRÉ-PROCESSAMENTO DA BASE DE DADOS	**26**
3.3	TREINAMENTO DOS MODELOS	**27**
3.3.1	**Definição das classes**	**27**
3.3.2	**Partição dos dados**	**28**
3.3.3	**Seleção de atributos**	**28**
3.3.4	**Modelos e ajuste de hiperparâmetros**	**29**
3.3.5	**Métricas de avaliação**	**29**
3.3.6	**Importância dos atributos**	**30**
3.4	ORGANIZAÇÃO DO PROJETO	**31**
3.5	GERENCIAMENTO DO PROCESSO DE DESENVOLVIMENTO	**32**
4	**RESULTADOS E DISCUSSÃO**	**33**
4.1	ANÁLISE DE DESEMPENHO DOS MODELOS	**33**
4.2	IMPACTO DA SELEÇÃO DE ATRIBUTOS	**34**
4.3	ANÁLISE DA IMPORTÂNCIA DOS ATRIBUTOS	**35**
5	**CONSIDERAÇÕES FINAIS**	**37**
	REFERÊNCIAS	**39**

1 INTRODUÇÃO

O plano global criado pela ONU, denominado Agenda 2030, propõe uma ação conjunta que visa o desenvolvimento sustentável e a erradicação da pobreza em todas as suas formas. Segundo (Organização das Nações Unidas, 2015), a ação proposta pela Agenda 2030 estabelece 17 objetivos e 169 metas que abrangem as cinco grandes áreas: pessoas, planeta, prosperidade, paz e parceria. As cinco áreas abrangem objetivos para garantir condições dignas de vida às pessoas, possibilitando acesso à educação, saúde e igualdade. Conservação do meio ambiente, com o objetivo de combater a degradação ambiental e promover uso sustentável de recursos ambientais, possibilitando um desenvolvimento e a prosperidade da sociedade de forma equilibrada, visando também estabelecer a paz e a justiça social.

O Brasil possui o Índice de Desenvolvimento Sustentável das Cidades (IDSC) (Instituto Cidades Sustentáveis, 2023), 100 indicadores coletados que apresentam métricas de cada uma das cidades com relação ao cumprimento dos 17 objetivos de desenvolvimento sustentável (ODS) definidos na Agenda. Esses indicadores oferecem uma visão do desenvolvimento dos municípios de forma multidimensional, compreendendo esferas sociais, ambientais e institucionais. Um dos indicadores pertencentes ao IDSC é o Índice de Desenvolvimento da Educação Básica (IDEB), responsável por avaliar a qualidade da educação básica. De acordo com (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024), o indicador, calculado a partir de dados, abrange dois aspectos fundamentais: o fluxo escolar e as médias de desempenho nas avaliações.

Avanços tecnológicos, como Modelos de Aprendizado de Máquina, fornecem técnicas de aprendizado supervisionado para a predição de avaliadores como o IDEB. A predição desse valor é realizada exclusivamente com base nos dados do IDSC, diferente da realização do cálculo baseado em notas e taxas de aprovação. Sendo assim, leva em conta a realidade do aluno com base em fatores externos à sala de aula. A abordagem aplicada fornece uma predição baseada em aspectos sociais, econômicos e ambientais do município dos alunos. A abordagem é válida para gestão pública educacional, apresentando o valor do IDEB integrado a fatores da realidade dos alunos fora do ambiente escolar.

A abordagem proposta visa analisar especificamente os municípios do estado de Santa Catarina, além disso, se faz necessária a interpretabilidade do resultado da predição. Para a resolução desse aspecto, serão aplicadas métricas de relevância dos atributos nos modelos baseados em árvores de decisão, o que permite extrair de forma direta quais os indicadores da base de dados do IDSC que possuem maior influência no índice educacional. Diante do cenário apresentado, o entendimento dos aspectos que têm maior peso na variação do índice do IDEB auxiliam a tomada de decisão no poder público, visando à melhoria do sistema educacional catarinense. A tarefa de identificação dos fatores de desenvolvimento sustentável do município que influenciam diretamente a qualidade da educação básica pode levar à implementação de políticas públicas com objetivos diretos na educação.

1.1 PROBLEMA

O conjunto de dados IDSC, que abrange todos os indicadores de cumprimento dos objetivos definidos na Agenda 2030, apresenta diversas características com relação ao desenvolvimento sustentável do município que ainda não foram analisadas e exploradas sob a ótica da ciência de dados, sobretudo de forma aprofundada, por meio da construção de modelos capazes de realizar a predição do indicador do IDEB.

O conjunto abrange informações sobre todos os municípios brasileiros, neste estudo serão explorados os dados e características apenas dos municípios catarineses. Neste cenário, cada muncicípo pode ter diferentes níveis de associação com o IDEB, não apresentando uma relação determinante com o indicador de avaliação em todos os municípios de forma igualitária. O estudo então se faz responsável por explorar os fatores comuns em todos os municípios do estado que incluenciam a educação.

Além disso, o indicador do IDEB geralmente é visto como uma métrica isolada apenas no âmbito da educação, sem levar em conta aspectos do desenvolvimento do município, como saúde ou saneamento básico. Aspectos esses que estão disponíveis no conjunto de indicadores IDSC e ainda não foram explorados com esse objetivo. Os modelos preditivos podem ser aplicados e, com base no treinamento, predizer a nota do IDEB. Porém, para uma tomada de decisão com relação à melhoria do sistema educacional, se faz necessária a compreensão dos fatores que influenciam o resultado da predição, por isso a proposta visa à aplicabilidade de técnicas de interpretabilidade dos modelos empregados.

1.2 OBJETIVOS

Este trabalho se propõe à exploração e análise da base de dados dos indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC), aplicando modelos de aprendizado de máquina com o objetivo de realizar a predição do Índice de Desenvolvimento da Educação Básica (IDEB) dos municípios catarinenses.

Adicionalmente, busca-se analisar as métricas de relevância de atributos inerentes aos modelos preditivos para interpretar os fatores que mais influenciam os resultados. O objetivo geral deste trabalho é analisar o desempenho de modelos de classificação baseados em Árvores de Decisão na predição do índice nos municípios do estado de Santa Catarina, utilizando suas métricas estruturais de importância de atributos para identificar os indicadores sustentáveis comuns entre os municípios que possuem maior impacto na educação básica.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

Realizar uma revisão da literatura sobre modelos de aprendizado de máquina supervisionado, com ênfase em modelos baseados em árvores de decisão e métricas de interpretabilidade de atributos; Aplicar técnicas para exploração e análise inicial da base de dados do IDSC; Aplicar técnicas de redução de dimensionalidade da base de dados para seleção de características para predição. Aplicar técnicas de modelo de aprendizado de máquina de classificação baseados em

árvores de decisão para prever o valor do avaliador educacional IDEB dos municípios de Santa Catarina; Aplicar métricas de extração da importância dos atributos nos modelos preditivos para validar a influência dos indicadores do IDSC na predição do IDEB e o entendimento do funcionamento do modelo de predição; Avaliar e comparar o desempenho dos modelos e o comportamento das métricas de relevância de atributos entre o subconjunto de dados do município catarinense.

1.3 JUSTIFICATIVA

Diante da crescente complexidade do cenário social e econômico, a tomada de decisão baseada em evidências se revela essencial para a formulação de políticas públicas regionais. Embora o Brasil apresente acentuada heterogeneidade entre suas regiões, a análise delimitada ao estado de Santa Catarina possibilita compreender um contexto socioeconômico e educacional mais homogêneo e representativo da realidade local. Dessa forma, a aplicação de modelos de aprendizado de máquina voltados especificamente à classificação do desempenho do IDEB nos municípios catarinenses permite superar abordagens aplicadas à base contendo todos os municípios brasileiros, oferecendo diagnósticos mais precisos e acionáveis para a gestão pública estadual e municipal.

Nesse cenário, técnicas de análise de dados e aprendizado de máquina possibilitam a identificação de padrões complexos entre os indicadores de desenvolvimento sustentável (IDSC) e o Índice de Desenvolvimento da Educação Básica (IDEB). A partir dessas técnicas, a predição do índice fornece uma visão estratégica fundamental aos gestores públicos, permitindo identificar possíveis relações entre fatores sociais e ambientais e o rendimento escolar, o que possibilita a adoção de medidas prévias para a melhoria da educação básica, antes da consolidação do índice oficial.

Para que essa aplicação seja verdadeiramente útil à gestão pública, a predição do modelo deve vir acompanhada da interpretabilidade. A tarefa de predição realizada a partir da aplicação de modelos baseados em árvores de decisão permite extrair diretamente a relevância de atributos. A análise se concentra no uso dessas métricas para mapear quais fatores do IDSC exercem maior peso sobre o desempenho educacional. Esse diagnóstico quantitativo direciona o poder público para a implementação de políticas em aspectos específicos, solucionando problemas que são a causa principal da desigualdade escolar.

1.4 METODOLOGIA

Para a realização de todos os objetivos, será necessária uma exploração inicial da base de dados, além de um estudo aprofundado em técnicas de aprendizado supervisionado e métodos de interpretabilidade de modelos. Essa exploração da base e o estudo teórico visam compreender o cenário e fundamentar a escolha dos algoritmos de aprendizado de máquina, levando em consideração uma delimitação da base de dados a um subconjunto dos municípios do estado de

Santa Catarina para predição do índice do IDEB. A análise exploratória de dados será realizada com o objetivo de compreender a distribuição dos indicadores e identificar padrões preliminares. Após essa análise, será executado o pré-processamento da base de dados, visando à adequação dos dados para a execução dos modelos de aprendizado de máquina, de forma a garantir a confiabilidade e o desempenho dos algoritmos.

A etapa preditiva inicial consiste na aplicação dos modelos de classificação no subconjunto de dados dos municípios catarinenses para a obtenção de um resultado preditivo de referência. Os modelos aplicados para comparação e análise serão os algoritmos baseados em árvores de decisão Random Forest e Gradient Boosting, sendo representado neste trabalho pelos algoritmos *Extreme Gradient Boosting*, *Light Gradient Boosting Machine* e *Categorical Boosting*. Logo após, com o objetivo de melhorar as métricas de avaliação dos resultados do modelo será realizada uma seleção de atributos dos dados. Nessa etapa, serão utilizadas técnicas de análise de correlação de variáveis para, após essa seleção, realizar uma nova predição com as características selecionadas de todos os municípios catarinenses.

A etapa subsequente consiste na análise do desempenho dos modelos em duas abordagens distintas: utilizando o subconjunto de dados completo e empregando apenas o conjunto de atributos selecionados. O desempenho dos modelos de classificação será avaliado por meio das métricas de Acurácia, Precisão e *Recall*. Por fim, a extração da relevância dos atributos ocorrerá por meio da análise das métricas de importância intrínsecas aos algoritmos baseados em árvore de decisão, calculadas a partir da redução da impureza ou ganho de informação nos nós de decisão. Essa perspectiva estrutural permite identificar quais indicadores do IDSC exercem maior influência no aprendizado dos modelos, auxiliando no mapeamento dos fatores associados ao desempenho educacional dos municípios catarinenses.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 APRENDIZADO DE MÁQUINA

O Aprendizado de Máquina (*Machine Learning*) é o ramo da Inteligência Artificial focado no desenvolvimento de algoritmos com capacidade de identificar padrões em grandes volumes de dados, com o objetivo de predizer o resultado de um atributo específico. Segundo a definição clássica (Mitchell, 1997), o aprendizado de máquina permite que sistemas melhorem seu desempenho com base na experiência. No estudo apresentado, esses algoritmos são empregados para modelar a relação entre os índices do IDSC e o índice de avaliação do IDEB, sendo responsáveis por estimar a relação matemática entre as variáveis.

2.1.1 Paradigmas de Aprendizado de Máquina

A literatura divide as abordagens de aprendizado de máquina em categorias formadas de acordo com a presença ou ausência de uma variável resposta durante o treinamento. As duas categorias abrangidas neste estudo são o aprendizado supervisionado e o não supervisionado.

O aprendizado de máquina supervisionado, de acordo com (Murphy, 2012), consiste no mapeamento de uma função que conecta um vetor de características de entrada X a uma saída esperada Y, utilizando um conjunto de dados previamente rotulado. O objetivo é aproximar uma função $\hat{f}(X) \approx Y$ que minimize o erro. O processo envolve a divisão dos dados em dois subconjuntos: treino e teste. O conjunto de treino é responsável pelo aprendizado por meio da identificação de padrões e o de teste é responsável por validar a eficácia do modelo, observando dados desconhecidos na fase de treinamento para avaliar seu resultado. Então, o algoritmo aprende a função que mapeia entradas em saídas por meio dos dados rotulados, aprendendo a relação entre as variáveis de entrada e de resposta.

Já o aprendizado não supervisionado, segundo (Bishop, 2006), foca na identificação de estruturas e correlações latentes em bases de dados que não possuem um alvo predefinido. Sem rótulos para guiar o treinamento, os algoritmos operam a partir de propriedades matemáticas dos dados, como proximidade espacial e densidade. Nesse estudo, esse paradigma é empregado no agrupamento dos municípios em perfis conforme suas características.

2.1.2 Conjunto de Dados

O estudo utiliza uma única base de dados, de acesso público: o Índice de Desenvolvimento Sustentável das Cidades - Brasil (IDSC-BR), edição de 2025 (Instituto Cidades Sustentáveis, 2023), estruturado a partir dos 17 Objetivos de Desenvolvimento Sustentável (ODS) da ONU (Organização das Nações Unidas, 2015). A planilha original reúne os 5.570 municípios brasileiros e 442 colunas, entre indicadores brutos, indicadores normalizados em escala de 0 a 100, pontuações por objetivo, classificações do Painel e metadados. O Índice de Desenvolvimento da Educação Básica (IDEB), produzido pelo Instituto Nacional de Estudos e Pesquisas Educacionais

Anísio Teixeira (INEP) (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024), está incluído na própria base como indicador do ODS 4, tanto para os anos iniciais quanto para os anos finais do ensino fundamental.

Dessa forma, atributos e variável alvo têm a mesma origem. A nota bruta do IDEB foi extraída da base e mantida em arquivo separado, constituindo a variável alvo (Y), enquanto os demais indicadores compõem os atributos preditores (X), após a remoção preventiva das colunas que compartilham dependência com o IDEB. O recorte espacial compreende os 295 municípios do estado de Santa Catarina, identificados pelo código do IBGE, dos quais permaneceram 151 municípios nos anos finais e 272 nos anos iniciais após a exclusão daqueles sem IDEB divulgado e das classes com menos de dois exemplos.

2.1.3 Redução de Dimensionalidade e Seleção de Atributos

Com o objetivo de mitigar a complexidade informacional, remover redundâncias e selecionar os indicadores mais relevantes da base de dados do IDSC, empregam-se técnicas de pré-processamento voltadas à redução de dimensionalidade e seleção de *features*.

A primeira abordagem consiste na análise de correlação de variáveis, utilizada para identificar e eliminar atributos altamente colineares. Essa técnica avalia o grau de associação linear entre os pares de variáveis preditoras, permitindo descartar aquelas que carregam informações redundantes e mantendo apenas as que possuem maior independência estatística ou maior correlação direta com a variável alvo.

Adicionalmente, utiliza-se a técnica de análise de componentes principais (PCA - *Principal Component Analysis*). Proposta originalmente na estatística por Karl Pearson em 1901 (Pearson, 1901) e posteriormente desenvolvida de forma independente por Harold Hotelling em 1933 (Hotelling, 1933), a PCA é um método não supervisionado de transformação linear amplamente aplicado para simplificar conjuntos de dados de alta dimensionalidade. O algoritmo mapeia o espaço original de variáveis para um novo sistema de coordenadas ortogonais, maximizando a variância explicada. As novas variáveis geradas, denominadas componentes principais, são combinações lineares dos indicadores originais, reduzindo o ruído e otimizando a eficiência computacional dos modelos preditivos.

2.2 MODELOS DE CLASSIFICAÇÃO E PREDIÇÃO

Modelos de classificação, como técnicas de aprendizado de máquina supervisionado, buscam aproximar uma função capaz de mapear variáveis preditoras X em uma variável alvo discreta Y (correspondente às faixas ou categorias de desempenho do IDEB). Neste estudo, a matriz X guarda os indicadores do IDSC e Y armazena a classe categórica do IDEB dos municípios catarinenses.

2.2.1 Random Forest

O modelo *Random Forest*, proposto por Breiman (2001a), evolui o modelo de árvores de decisão. O modelo cria árvores de decisão independentes; cada árvore opera em um subespaço estocástico, ou seja, apenas uma parte dos dados e uma parte das variáveis. Além disso, cada árvore é treinada com uma amostra diferente dos dados originais, selecionada por amostragem com reposição. Essa técnica garante que cada árvore de decisão aprenda especificidades diferentes do conjunto total.

O algoritmo usa duas estratégias de sorteio: a amostragem com reposição (*Bootstrap*), que significa que cada árvore é treinada com uma amostra diferente extraída do banco de dados, e o subespaço aleatório de atributos, onde, em cada divisão de nós da árvore, a escolha do melhor ponto de corte fica restrita a um grupo sorteado de variáveis, e não a todas. O resultado final do algoritmo *Random Forest* para classificação é obtido por meio do voto majoritário das predições de todas as árvores.

O processo de construção de cada árvore ocorre de forma recursiva, dividindo os dados em nós hierárquicos. Em tarefas de classificação, o algoritmo determina o ponto de corte em cada nó avaliando qual divisão resulta na maior pureza ou ganho de informação dos dados entre os nós filhos criados. Esse cálculo mede a homogeneidade das classes resultantes. Ao final do treinamento do modelo, o algoritmo consolida o aprendizado coletando as classes preditas independentes de cada árvore e aplicando o voto majoritário para gerar a predição final.

2.2.2 Gradient Boosting

O modelo *Gradient Boosting Decision Trees* treina árvores de decisão de forma sequencial, se diferenciando do modelo *Random Forest*, que treina árvores de decisão em paralelo. Conforme (Friedman, 2001), o princípio do modelo é a otimização de uma função de perda através de um ajuste iterativo, onde cada árvore é treinada para prever resíduos das árvores anteriores. Existem três variações que evoluem o algoritmo:

XGBoost (*Extreme Gradient Boosting*): Proposto por Chen e Guestrin (2016), adiciona dois termos de regularização (L_1 e L_2) à função de perda para conter o crescimento exagerado das árvores e reduzir o sobreajuste. Destaca-se ao incorporar técnicas de otimização que aumentam a eficiência computacional e contribuem para a construção de um modelo mais robusto.

LightGBM (*Light Gradient Boosting Machine*): Proposto por Ke et al. (2017) no ecossistema da Microsoft, adota o crescimento das árvores focado nas folhas. Essa estratégia divide o nó que traz a maior redução de erro global, independentemente do nível da árvore.

CatBoost (*Categorical Boosting*): Desenvolvido por Prokhorenkova et al. (2018) na empresa Yandex, possui técnicas matemáticas complexas para o tratamento de variáveis categóricas no treinamento, prevenindo o vazamento de dados (*target leakage*).

2.2.3 Métricas de Avaliação de Modelos de Classificação

Para a validação estatística e a comparação dos modelos, foram adotadas quatro métricas baseadas na Matriz de Confusão. No cenário multiclasse, TP, TN, FP e FN são obtidos para cada classe c considerando-a como positiva e as demais como negativas (abordagem um-contra-todos).

A **Acurácia** mede a proporção total de predições corretas realizadas pelo modelo em relação ao total de instâncias avaliadas, sendo definida por:

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN} \tag{1}$$

onde TP representa os verdadeiros positivos, TN os verdadeiros negativos, FP os falsos positivos e FN os falsos negativos. No cenário multiclasse, equivale à razão entre a soma da diagonal principal da matriz de confusão e o total de instâncias.

A **Precisão** indica a proporção de predições corretas para uma classe específica em relação ao total de amostras classificadas como pertencentes àquela classe, calculada por:

$$\text{Precisão} = \frac{TP}{TP+FP} \tag{2}$$

O *Recall* (ou Sensibilidade) mede a capacidade do modelo de identificar corretamente todos os resultados reais pertencentes a uma determinada classe, sendo representado por:

$$\text{Recall} = \frac{TP}{TP+FN} \tag{3}$$

O **F1-*score*** é a média harmônica entre a precisão e o *recall*, resumindo em um único valor o equilíbrio entre os dois. Por penalizar valores muito baixos de qualquer um deles, é menos sensível do que a média aritmética a modelos que privilegiam uma métrica em detrimento da outra:

$$F1 = \frac{2 \times \text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}} \tag{4}$$

Em problemas com mais de duas classes, precisão, *recall* e F1 são calculados para cada classe e combinados por uma média. Na **média macro**, atribui-se o mesmo peso a todas as classes, independentemente do número de instâncias de cada uma:

$$\text{Métrica}_{macro} = \frac{1}{K}\sum_{c=1}^{K} \text{Métrica}_c \tag{5}$$

em que K é o número de classes. Assim, o F1 macro é a média dos valores de F1 de cada classe. Essa agregação é adequada a problemas com classes desbalanceadas, pois o desempenho deficiente nas classes minoritárias reduz o valor final, o que não ocorre com a acurácia.

2.2.4 Métricas Nativas de Importância Baseadas em Árvores

Os modelos baseados em árvores de decisão possuem indicadores nativos com o objetivo de quantificar a relevância das variáveis preditoras. Em cenários com a aplicação de modelos de

classificação, a principal técnica empregada é a redução de impureza, do inglês *Mean Decrease in Impurity* (MDI). Essa técnica aplica um cálculo baseado na redução da impureza (como Gini ou Entropia) nos nós de decisão cada vez que um atributo é elegido para dividir os dados. O grau de importância da variável é o somatório ponderado dos ganhos de pureza, calculado ao longo das ramificações da árvore.

Adicionalmente, modelos *Gradient Boosting* possuem três métricas adicionais para o cálculo da importância do atributo. A primeira é o ganho, que representa a relevância do atributo para melhoria da precisão do resultado do modelo; a métrica é semelhante ao MDI e indica quanto a função de perda caiu ao introduzir uma divisão baseada na variável avaliada. A segunda é denominada frequência, que contabiliza o número de vezes em que o atributo foi selecionado para realizar pontos de corte ao longo das árvores. Por fim, a última métrica é a cobertura, que mede o número de observações que passaram pelo nó associado à variável observada.

2.3 TRABALHOS CORRELATOS

Conforme revisão bibliográfica realizada, são encontrados diversos estudos com aplicações de algoritmos de aprendizado de máquina em microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) para predição do Índice de Desenvolvimento da Educação Básica (IDEB) e para identificação de quais fatores são determinantes. Em uma escala regional, Soares et al. (Soares et al., 2020) realizam a predição por meio da aplicação de Árvores de Decisão em dados de escolas do estado do Maranhão; o estudo identificou que a escolaridade dos pais foi a variável com maior influência no modelo. Ademais, (Pinto, 2021) adotou técnicas de seleção de atributos nos dados de Alagoas, com o objetivo de reduzir o ruído da base de dados, isolando os dados que realmente impactavam a gestão municipal. Outra abordagem adotada por Silva (Silva, 2022) foi o processo KDD (*Knowledge Discovery in Databases*), empregado para projetar cenários preventivos. O autor argumenta que a ciência de dados deve ser aplicada antes do fechamento dos ciclos de avaliação do governo.

Outro estudo, agora em escala nacional, volta-se para o mapeamento de técnicas e modelos mais robustos. A revisão sistemática da literatura de Feitosa (Feitosa, 2025) documentou os métodos mais adotados nas pesquisas do país, apontando modelos como *Random Forest*, SVM e *Árvores de Decisão* como os algoritmos mais aplicados e com melhor desempenho nessa área de pesquisa. Ainda com a aplicação de modelos baseados em árvores, Barros et al. (Barros; Alves; Mello, 2024) combinaram *Gradient Boosting* com a abordagem SHAP (XAI) para adicionar interpretabilidade ao modelo, medindo o impacto de atributos com distorção entre a idade e série do aluno ou falta de laboratórios nas escolas. 2

O que diferencia esse trabalho da linha de pesquisa dos estudos presentes na literatura é o foco em dados externos ao ambiente escolar para predição da qualidade escolar da educação básica. Enquanto a maior parte das pesquisas explora exclusivamente os dados disponibilizados pelo INEP, o presente estudo avalia o impacto direto dos indicadores do Índice de Desenvolvi-

mento Sustentável das Cidades (IDSC) sobre a nota do IDEB. Além disso, a metodologia integra técnicas de agrupamento para definir os perfis de município, o que permite segmentar a base de dados e entender como os fatores afetam cada subconjunto de dados.

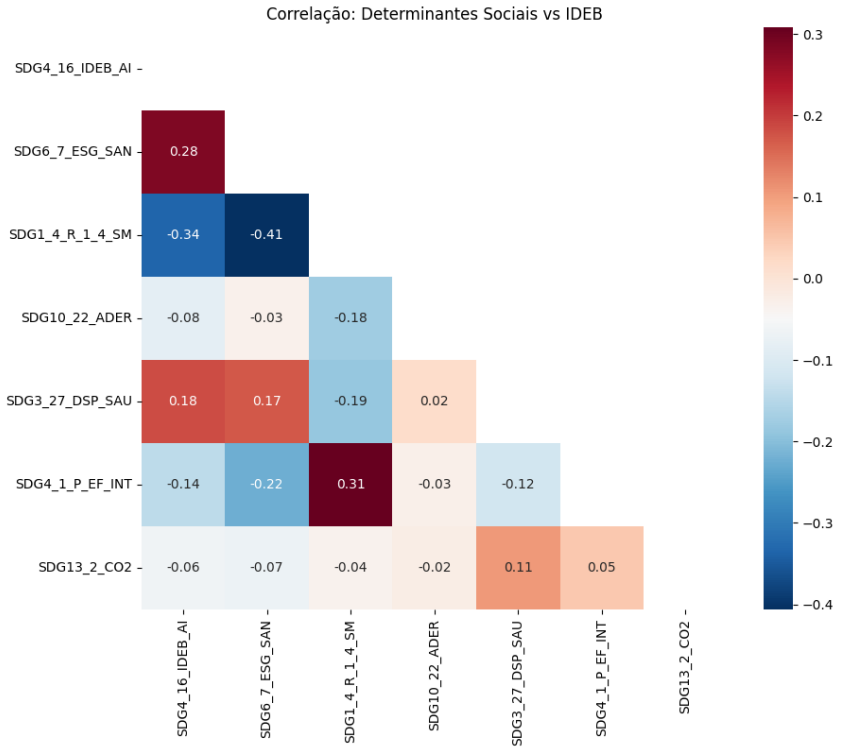
3 ABORDAGEM PROPOSTA

Este capítulo detalha a execução prática da metodologia proposta, abrangendo desde o fluxo operacional e as ferramentas utilizadas até o treinamento dos modelos preditivos de classificação e o gerenciamento do projeto.

3.1 ANÁLISE EXPLORATÓRIA DE DADOS

A aplicabilidade da técnica de Análise Exploratória de dados apresentou informações relevantes para este estudo. Em um primeiro momento foi extraída a matriz de correlação linear entre variáveis dos indicadores IDSC e o índice do IDEB. A análise da matriz de correlação evidenciou que os indicadores socioeconômicos apresentam associação com o índice do IDEB, porém essa análise identifica apenas relações lineares, se faz necessário o uso de modelos para identificar relações não lineares. A Figura 1 apresenta a matriz de correlação das variáveis citadas.

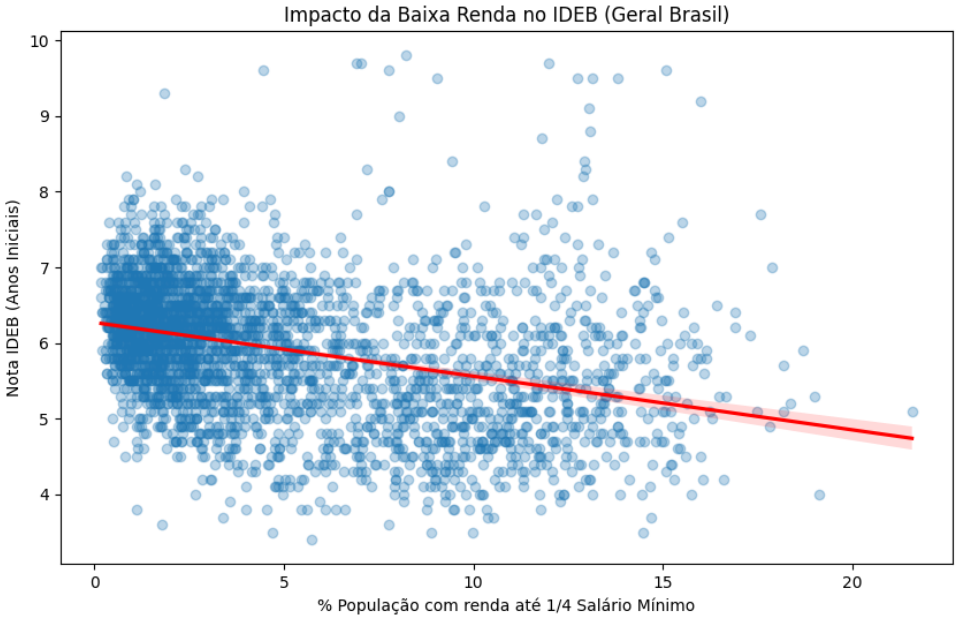
Figura 1 – Matriz de correlação linear entre indicadores do IDSC e o IDEB.



Fonte: A autora, 2026.

Conforme observado na Figura 2, ao lado esquerdo do gráfico o cenário de menor vulnerabilidade socioeconômica apresenta maior dispersão de dados, isso indica que ao estabilizar a renda da população outros fatores possuem maior importância no desempenho do índice de qualidade da educação básica. A linha de tendência central tenta resumir o comportamento nacional, levando em conta todos os municípios presentes na base completa, mas não abrange dados de municípios que se comportam como *outliers* positivos.

Figura 2 – Gráfico de dispersão entre o indicador de Baixa Renda (eixo x) e o IDEB (eixo) com linha de tendência linear.



Fonte: A autora, 2026.

A Análise Exploratória de Dados evidencia o comportamento da base de dados, demonstrando heterogeneidade dos dados dos municípios brasileiros. Esse comportamento demanda uma estratégia de segmentação da base, no caso deste estudo, a seleção do suconjunto de municípios do estado de Santa Catarina.

3.2 PRÉ-PROCESSAMENTO DA BASE DE DADOS

Nesta etapa, foram aplicadas técnicas sistemáticas de pré-processamento de dados com o objetivo de estruturar e adequar a base de dados do IDSC-BR para a execução dos algoritmos de aprendizado de máquina. Inicialmente, realizou-se a inspeção do conjunto de dados para a identificação de metadados, colunas descritivas e variáveis categóricas irrelevantes para o processo de predição. Uma etapa metodológica adotada nesta fase foi a remoção preventiva de colunas e índices que pudessem induzir ao vazamento de dados (*data leakage*). Para isso, foram removidas variáveis e notas intermediárias que compartilhavam dependência semântica com as notas e faixas do IDEB, assegurando que os modelos de classificação fossem treinados estritamente com base nos indicadores exógenos de desenvolvimento sustentável, sem variáveis que gerassem acurácias artificialmente infladas. Por fim, após a conclusão da limpeza de dados, a base de dados resultante foi convertida e persistida no formato CSV (*Comma-Separated Values*), otimizando o fluxo de leitura computacional para as etapas subsequentes de modelagem.

3.3 TREINAMENTO DOS MODELOS

Após a realização da etapa de pré-processamento da base de dado, a predição do índice do IDEB foi formulada como um problema de classificação multiclasse. Nessa tarefa, os indicadores do IDSC atuam como atributos preditores e a a faixa de desempenho do município na nota do IDEB, como variável alvo. Sendo assim, foram considerados duas variáveis alvo independentes: Anos Iniciais (AI) e os Anos Finais (AF) do ensino fundamental. Os modelos foram treinados e avaliados separadamente para cada variável.

3.3.1 Definição das classes

Levando em conta que o IDEB é uma variável contínua, a nota bruta normalizada em uma escala de 0 a 10 foi distribuída em cinco faixas de desempenho:

- **Classe 1 (Insuficiente):** notas inferiores a 4,0;
- **Classe 2 (Básico):** notas entre 4,0 e 4,9;
- **Classe 3 (Intermediário):** notas entre 5,0 e 5,9;
- **Classe 4 (Adequado):** notas entre 6,0 e 6,9;
- **Classe 5 (Avançado):** notas maiores ou iguais a 7,0.

Para treinamento do modelo a nota bruta e as classificações do Painel do IDSC-BR não foram utilizadas como atributos, mantidas em arquivo separado. É válida a explicação de que a variável de classificação Painel, que classifica o desempenho dos indicadores em cores não foi utilizada pois alguns municípios não possuiam valor da variável alvo, por isso foi feita a classificação com a nota bruta, abrangendo todos os muniípios. Essa escolha preserva a escala original do índice e dispensa a categorização em quatro cores definida pelo IDSC-BR. A classificação do Painel não foi avaliada como alvo alternativo. Ressalta-se que ela abrange os mesmos municípios que a nota bruta, de modo que a escolha não decorre de diferença de cobertura.

Dos 295 municípios catarinenses, foram mantidos apenas aqueles com IDEB divulgado para a etapa correspondente: 152 nos anos finais e 273 nos anos iniciais. Em seguida, como o estudo se restringe a Santa Catarina, algumas faixas não possuem representantes suficientes. Os municípios pertencentes a classes com menos de dois exemplos foram removidos, pois inviabilizavam a divisão estratificada entre treino e teste. Nos anos finais, foi removido um município da faixa avançada, restando quatro classes e 151 municípios. Nos anos iniciais, foi removido um município da faixa básica e nenhum município se enquadrou na faixa insuficiente, restando três classes e 272 municípios. A Tabela 1 apresenta a distribuição final das classes em cada alvo.

Tabela 1 – Distribuição dos municípios catarinenses por faixa do IDEB, após os filtros aplicados.

Etapa	Faixa do IDEB	Municípios	%
Anos finais (n = 151)	Insuficiente ($< 4{,}0$)	7	4,6
	Básico (4,0–4,9)	55	36,4
	Intermediário (5,0–5,9)	75	49,7
	Adequado (6,0–6,9)	14	9,3
Anos iniciais (n = 272)	Intermediário (5,0–5,9)	65	23,9
	Adequado (6,0–6,9)	176	64,7
	Avançado ($\geq 7{,}0$)	31	11,4

3.3.2 Partição dos dados

Como foi explicado anteriormente, dos 295 municípios catarinenses presentes no IDSC-BR 2025, foram utilizados apenas aqueles com IDEB divulgado para a etapa correspondente e pertencentes a classes com ao menos dois exemplos, resultando em 151 municípios para os anos finais (AF) e 272 para os anos iniciais (AI), conforme a Tabela 1.

A base de dados abrange 151 municípios para os anos finais (AF) e 272 para os anos iniciais. Sendo assim, para cada alvo, os dados foram divididos em 80% para treino e 20% para teste, divididos pela classe e com semente aleatória fixa (*random_state* = 42), garantindo a reprodutibilidade dos resultados. Nesse cenário, a variável alvo dos AF ficou com 120 municípios para treino e 31 para teste, e a variável alvos dos AI, com 217 para treino e 55 para teste. O conjunto de teste foi mantido isolado durante o ajuste de hiperparâmetros e usado apenas na avaliação final.

Em razão do tamanho reduzido da base, a classificação incorreta de um único município altera a acurácia em aproximadamente 3,2 pontos percentuais no alvo AF e 1,8 ponto percentual no alvo AI. Além disso, as classes menos frequentes ficam com menos exemplos no teste, no contexto desse estudo na variável AF, a classe insuficiente, com 7 municípios, tem apenas um ou dois no conjunto de teste, o que torna as métricas mais instáveis. Esses aspectos limitam a precisão das comparações entre modelos e são considerados na análise dos resultados.

3.3.3 Seleção de atributos

Como comparação de resultados dos modelos treinados com a base de dados com todos os atributos preditores, exceto os alvos e o identificador do município foi realizado um experimento adicional, o treinamento do modelo com um subconjunto de 105 atributos resultante da seleção descrita a seguir. A primeira etapa de filtragem ocorreu por meio de uma análise exploratória, com base na matriz de correlação de Pearson, foram identificados 15 pares de variáveis com correlação absoluta superior ao valor de 0,80, devido a alta correlação, em cada par, foi descartada a variável com maior correlação média que as demais, a primeira etapa já rediziu o conjunto de variáveis preditoras de 135 para 121 colunas. Na etapa subsequente, foram removidas as

variáveis relacionadas à educação e ao próprio IDEB (indicadores do ODS 4), evitando que a resposta fosse inferida de atributos semanticamente dependentes do alvo, o que resultou em 105 atributos. Além das duas etapas foi aplicada a Análise de Componentes Principais (PCA) sobre os dados padronizados, com imputação pela mediana dos valores, com 15 componentes foi obtido um valor percentual de 51,53% da variância explicada acumulada, fato que indica que a informação está distribuída entre dimensões que a projeção com poucos componentes não identificaria parte relevante da variabilidade. Sendo assim, esse se mostrou o motivo principal de a análise não ser considerada para eliminação de variáveis. O subconjunto final corresponde ao obtido após as duas etapas iniciais de filtragem de dados.

Durante a etapa de treinamento dos modelos os valores ausentes foram tratados conforme o comportamente de cada algoritmo. Levando em conta que o *Random Forest* não realiza o treinamento com valores ausentes, foi aplicada imputação iterativa, ajustada apenas sobre o conjunto de treino e aplicada ao de teste. Os algoritmos XGBoost, LightGBM e CatBoost, por comportamento, já tratam valores ausentes nativamente.

3.3.4 Modelos e ajuste de hiperparâmetros

A abordagem principal visa realizar a comparação de quatro algoritmos baseados em árvores de decisão: *Random Forest*, *Extreme Gradient Boosting* (XGBoost), *Light Gradient Boosting Machine* (LightGBM) e *Categorical Boosting* (CatBoost). A escolha se justifica pela adequação a dados tabulares de alta dimensionalidade e pela disponibilidade de medidas intrínsecas de importância de atributos, requisito da etapa de interpretabilidade.

Os hiperparâmetros foram ajustados por busca aleatória (*RandomizedSearchCV*) com 10 combinações sorteadas do espaço de busca de cada algoritmo, apresentados na Tabela 2. Cada combinação foi avaliada por validação cruzada estratificada de três *folds* sobre o conjunto de treino, com a acurácia como critério de seleção, e o modelo com melhor desempenho foi reajustado sobre todo o conjunto de treino e avaliado no conjunto de teste. Os demais hiperparâmetros foram mantidos nos valores padrão de cada biblioteca, e a semente aleatória foi fixada em 42.

3.3.5 Métricas de avaliação

O desempenho dos modelos foi avaliado no conjunto de teste por meio de acurácia, precisão, *recall* e F1-*score*, definidos na Seção **??**. Como as classes são desbalanceadas (Tabela 1), precisão, *recall* e F1 foram calculados pela média macro, e o F1 macro foi adotado como principal referência, uma vez que a acurácia isolada pode ser elevada apenas pela predição da classe majoritária.

Tabela 2 – Espaços de busca dos hiperparâmetros de cada algoritmo.

Algoritmo	Hiperparâmetro	Valores
Random Forest	`n_estimators`	100, 200, 300
	`max_depth`	sem limite, 5, 10, 15, 20
	`min_samples_split`	2, 5, 10
	`min_samples_leaf`	1, 2, 4
	`max_features`	`sqrt`, `log2`, todos
XGBoost	`n_estimators`	100, 200, 300, 500
	`max_depth`	3, 5, 7, 9
	`learning_rate`	0,01; 0,05; 0,1; 0,2
	`subsample`	0,6; 0,8; 1,0
	`colsample_bytree`	0,6; 0,8; 1,0
LightGBM	`n_estimators`	100, 200, 300, 500
	`num_leaves`	15, 31, 63, 127
	`learning_rate`	0,01; 0,05; 0,1; 0,2
	`subsample`	0,6; 0,8; 1,0
	`colsample_bytree`	0,6; 0,8; 1,0
CatBoost	`iterations`	200, 400, 600
	`depth`	4, 6, 8, 10
	`learning_rate`	0,01; 0,05; 0,1; 0,2
	`l2_leaf_reg`	1, 3, 5, 7

3.3.6 Importância dos atributos

A relevância dos atributos foi extraída por meio das medidas de importância intrínsecas aos algoritmos baseados em árvores de decisão. Essas medidas são calculadas a partir da redução da impureza ou do ganho de informação obtido nos nós de decisão em que cada atributo é utilizado, o que permite identificar quais indicadores do IDSC exercem maior influência no aprendizado dos modelos e auxilia no mapeamento dos fatores associados ao desempenho educacional dos municípios catarinenses. Cada algoritmo fornece uma medida própria:

- *Random Forest*: redução média de impureza (Breiman, 2001b);
- XGBoost e LightGBM: ganho médio dos nós em que o atributo é utilizado, e não o número de vezes em que aparece nas árvores (Chen; Guestrin, 2016; Ke et al., 2017);
- CatBoost: mudança média na predição quando o valor do atributo varia (*PredictionValuesChange*), medida de natureza semelhante ao ganho, embora não seja baseada em impureza (Prokhorenkova et al., 2018).

A análise de importância dos atributos foi aplicada nos quatro algoritmos, nos dois alvos (anos finais e anos iniciais) e nos dois experimentos (todos os atributos e atributos selecionados). Para cada combinação, foram mantidos os melhores hiperparâmetros obtidos na busca aleatória

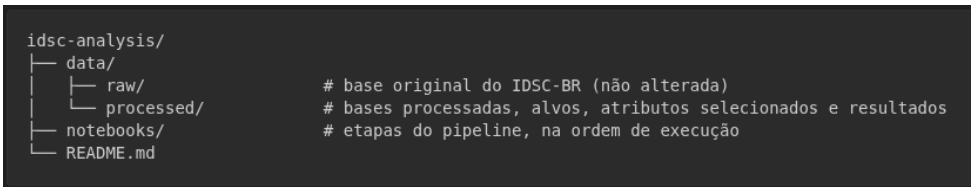
e o modelo foi reajustado sobre o conjunto de treino com cinco sementes aleatórias distintas. Foi definida a importância final de cada atributo corresponde à média entre as sementes, o que reduz a instabilidade esperada em uma base de tamanho reduzido como o subconjunto de indicados IDSC dos municípios catarinenses. Como as medidas dos algoritmos têm escalas diferentes, os valores de cada modelo foram normalizados para somar 1, tornando-os comparáveis.

Em uma etapa subsequente, para consolidar os resultados entre os algoritmos, foram calculados, para cada atributo, a importância média, o desvio entre os modelos, a posição média no ranking e o número de modelos em que o atributo aparece entre os 20 mais importantes. Atributos que se destacam simultaneamente em diferentes algoritmos são tratados como mais consistentes. Por fim, as importâncias dos indicadores foram agregadas por Objetivo de Desenvolvimento Sustentável (ODS), de modo a identificar as dimensões do desenvolvimento sustentável a qual se realciona com a informação explorada pelos modelos. Os escores que já resumem vários indicadore, como por exemplo, as pontuações por objetivo e a pontuação geral do índice, foram mantidos em um grupo separado, para que um mesmo indicador não fosse contado mais de uma vez. É válido ressaltar que as importâncias extraídas refletem os atributos explorados pelo modelo dividir as classes do IDEB, sendo assim indicam uma associação e não necessáriamente uma relação de causa e consequência.

3.4 ORGANIZAÇÃO DO PROJETO

A estrutura do projeto foi organizada de forma modular e sequencial, de modo a facilitar a manutenção e a reprodutibilidade dos experimentos. A Figura 3 apresenta uma visão geral do projeto.

Figura 3 – Organização do projeto.



Fonte: A autora, 2026.

O diretório `data` armazena os dados em duas etapas. Em `raw` fica a base original do IDSC-BR 2025, mantida sem alterações. Em `processed` ficam os arquivos gerados pelas etapas de preparação: a base processada (`Base_de_Dados_Processada.csv`), os alvos do IDEB mantidos em arquivo separado (`Base_de_Alvos_IDEB.csv`), a lista de atributos selecionados (`features_selecionadas_sc.json`) e os resultados da análise de importância dos atributos.

O diretório `notebooks` concentra o código, organizado em *notebooks* Jupyter que seguem a ordem do fluxo de trabalho: análise exploratória dos dados, limpeza da base, construção dos alvos de classificação, seleção de atributos , predição com todos os atributos, predição com os

atributos selecionados e análise da importância dos atributos. Cada *notebook* lê os arquivos produzidos pela etapa anterior, de modo que o encadeamento fica explícito.

Manter os alvos em um arquivo separado da base de atributos evita o vazamento de informação, pois a nota br(`07_feature_importance`)uta do IDEB e a classificação do Painel nunca fazem parte dos dados fornecidos aos modelos. A separação entre os dois experimentos em *notebooks* distintos, com o mesmo procedimento de avaliação, permite compará-los em condições idênticas. Todas as etapas com componente aleatório utilizam semente fixa, o que permite reproduzir os resultados.

O projeto foi desenvolvido em Python, com as bibliotecas *pandas* e *scikit-learn* para a manipulação dos dados e a avaliação, *XGBoost*, *LightGBM* e *CatBoost* para os modelos, e *matplotlib* e *seaborn* para as visualizações. O código está disponível publicamente no GitHub[1], permitindo sua reprodução e exploração por outros pesquisadores.

3.5 GERENCIAMENTO DO PROCESSO DE DESENVOLVIMENTO

Nesta seção é descrita a forma como o desenvolvimento do projeto foi conduzido. Não foi adotada uma metodologia ágil formal, o trabalho seguiu um processo iterativo e incremental, no qual cada etapa do fluxo (análise exploratória, limpeza, seleção de atributos, treinamento e interpretação dos modelos) foi implementada em um *notebook* próprio e revisada à medida que os resultados da etapa seguinte indicavam ajustes.

Na fase inicial, o acompanhamento foi realizado por meio de reuniões semanais, nas quais eram discutidos os resultados parciais e definidas as atividades da semana seguinte. Com o decorrer do semeste, a execução das atividades passou a ocorrer nos períodos disponíveis, principalmente à noite e aos finais de semana, sem um cronograma fixo de entregas. O controle de versão foi feito com o Git, com o repositório hospedado no GitHub, o que manteve o histórico das alterações do código.

[1] https://github.com/clarabecker/idsc-analysis

4 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos na avaliação experimental dos modelos preditivos aplicados à tarefa de classificação das faixas de desempenho do Índice de Desenvolvimento da Educação Básica (IDEB) nos municípios do estado de Santa Catarina. A Seção 4.1 analisa o desempenho quantitativo dos algoritmos para os Anos Finais (AF) e Anos Iniciais (AI) do ensino fundamental, considerando o cenário sem balanceamento de classes na base global. A Seção 4.2 aborda os impactos da etapa de seleção de atributos (base parcial). Por fim, a Seção 4.3 explora a análise de importância dos atributos agregada por Objetivos de Desenvolvimento Sustentável (ODS).

4.1 ANÁLISE DE DESEMPENHO DOS MODELOS

A avaliação dos modelos foi conduzida de forma independente para os Anos Finais (AF) e Anos Iniciais (AI). A Tabela 3 apresenta o desempenho na base com todas as variáveis para os Anos Finais.

Tabela 3 – Métricas de desempenho no conjunto de teste para Anos Finais (AF) com a base global (sem balanceamento).

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-Score (Macro)**
LightGBM	0,6129	0,4297	0,4652	0,4447
Random Forest	0,6129	0,4389	0,4634	0,4367
CatBoost	0,5806	0,3832	0,4414	0,4087
XGBoost	0,5161	0,3782	0,3901	0,3737

Fonte: A autora, 2026.

Para os Anos Finais, *LightGBM* e *Random Forest* apresentaram valor de acurácia de 61,29%, mas o *LightGBM* obteve o maior F1-*score* macro (0,4447) e o maior *recall* macro (0,4652), enquanto o *Random Forest* teve a maior precisão macro (0,4389). Isso indica que, embora acertem a mesma proporção de municípios, o *LightGBM* recupera melhor as faixas menos frequentes, ao passo que o *Random Forest* é mais limitado ao atribuí-las. O *XGBoost* apresentou o pior desempenho em todas as métricas, possuindo o valor de acurácia em 51,61%. A Tabela 4 apresenta os resultados obtidos na base completa para os Anos Iniciais.

Tabela 4 – Métricas de desempenho no conjunto de teste para Anos Iniciais (AI) com a base global (sem balanceamento).

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-Score (Macro)**
Random Forest	0,6545	0,4657	0,3902	0,3641
CatBoost	0,6545	0,4444	0,4275	0,4198
LightGBM	0,6545	0,5581	0,4732	0,4917

Fonte: A autora, 2026.

Nos Anos Iniciais, os três modelos alcançaram a mesma acurácia (65,45%), evidenciando desempenho competitivo entre eles. As métricas macro revelam a diferença: o *LightGBM* se destaca com F1-*score* de 0,4917, *CatBoost* apresenta valor de 0,4198 e *Random Forest* com 0,3641. O *Random Forest*, apesar de precisão próxima à do *LightGBM*, tem o menor valor de *recall* (0,3902), o que sugere maior tendência de apresentar predições para classe majoritária. Observa-se que os modelos preditores di índice do IDEB dos anos finais apresentam acurária superior aos modelos preditores da variável dos anos finais, o que pode ser relacionado com o maior número de registros avaliados na fase de teste.

4.2 IMPACTO DA SELEÇÃO DE ATRIBUTOS

Com o intuito de verificar se a remoção de redundâncias melhora a capacidade preditiva dos modelos selecionados para esse estudo, analisou-se o comportamento dos modelos explorando um conjunto de dados com atributos selecionados. A Tabela 5 apresenta os resultados para os Anos Finais.

Tabela 5 – Métricas de desempenho no conjunto de teste para Anos Finais (AF) com a base parcial (sem balanceamento).

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-Score (Macro)**
LightGBM	0,7097	0,3568	0,4152	0,3818
XGBoost	0,7097	0,3643	0,4212	0,3906
CatBoost	0,6774	0,3372	0,4045	0,3675
Random Forest	0,6452	0,3219	0,3879	0,3505

Fonte: A autora, 2026.

Ao realizar análise dos resultados dos modelos dos anos finais, a seleção de atributos elevou o valor da métrica da acurácia de todos os modelos: *LightGBM* e *XGBoost* atingiram 70,97%, e o ganho do *XGBoost* foi o mais expressivo (de 51,61% para 70,97%). Entretanto, esse ganho não se refletiu nas métricas macro. O F1-*score* do *LightGBM* caiu de 0,4447 para 0,3818 e o do *Random Forest*, de 0,4367 para 0,3505. Apenas o *XGBoost* melhorou nas duas métricas de F1-*score*, anteriormente com valor de 0,3737, agora com 0,3906. Isso sugere que, para a maioria dos modelos, a redução de atributos favoreceu a classificação das faixas majoritárias em detrimento das minoritárias, provavlemente pela eliminação de variáveis que ajudavam a delimitar aas classes. Sendo assim, a melhora de acurácia deve ser interpretada com cautela, já que representa alguns municípios a mais classificados corretamente. A Tabela 6 apresenta os resultados para os Anos Iniciais.

Ao observar os resultados dos anos iniciais, o efeito da seleção foi menos uniforme. O *CatBoost* obteve a maior valor da acurácia (69,09%) e o *Random Forest* melhorou tanto em acurácia, passando do valor de 65,45% para 67,27% quanto em F1, de 0,3641 para 0,3952. Já o *LightGBM* manteve a acurácia (65,45%) e teve queda no F1, passando de 0,4917 para 0,4523.

Tabela 6 – Métricas de desempenho no conjunto de teste para Anos Iniciais (AI) com a base parcial (sem balanceamento).

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-Score (Macro)**
CatBoost	0,6909	0,4535	0,4174	0,4070
XGBoost	0,6727	0,4466	0,3754	0,3485
Random Forest	0,6727	0,4196	0,4081	0,3952
LightGBM	0,6545	0,7031	0,4288	0,4523

Fonte: A autora, 2026.

Chama atenção a precisão macro de 0,7031 do *LightGBM*, modelo se mostra mais criterioso em suas predições.

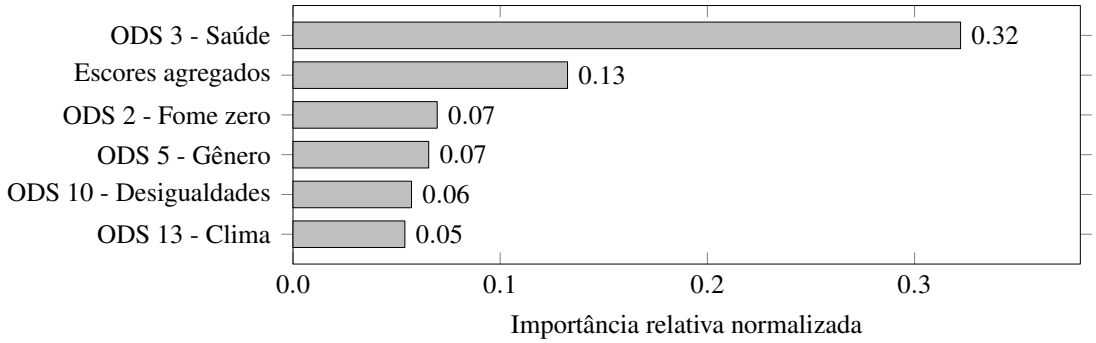
Em uma análise geral, a seleção de atributos não produziu melhora significativa: aumentou a acurácia nos modelos preditores do índice dos anos finais, mas reduziu o equilíbrio entre as classes na maior parte dos modelos. Na segunda variável alvo, índice do IDEB do anos iniciais, seu efeito dependeu do algoritmo. Em ambas as etapas, o *LightGBM* e o *CatBoost* revelaram-se os mais competitivos, e a escolha entre eles depende da métrica priorizada.

4.3 ANÁLISE DA IMPORTÂNCIA DOS ATRIBUTOS

A importância dos atributos, calculada de forma intrínseca pelos modelos baseados em árvores, foi agregada por ODS para identificar quais temas mais contribuem para a classificação do IDEB. Aplicando na base de dados completa, com todos os atributos, os mesmos três grupos lideram nas duas etapas. Para a variável do índice dos anos finais, o ODS 3, que compreende saúde e bem-estar, tem a maior importância (25,80%), seguido pelo ODS 4, educação de qualidade, com 15,96%, e pelos Escores agregados, com 12,32%. Para a variável do índice dos anos iniciais, o ODS 4 apresenta maior porcentagem de importância com valor 21,44%, seguido pelos Escores agregados 18,85% e pelo ODS 3 com valor de 13,96%.

A Figura 4 mostra os seis ODS mais importantes nos Anos Finais após a seleção de atributos.

Figura 4 – Importância agregada por ODS para os Anos Finais na base parcial.



Fonte: A autora, 2026.

Com a seleção de atributos, o ODS 4 deixou de aparecer entre os principais grupos nas duas etapas. Isso é coerente com a remoção de atributos correlacionados: ao eliminar indicadores redundantes, a importância se concentra nos que restam. Em resumo, variáveis relacionadas a saúde (ODS 3) e os Escores agregados são os grupos mais associados às faixas do IDEB, e a educação (ODS 4) tem peso maior no cenário da predição dos anos iniciais com a base de dados completa.

5 CONSIDERAÇÕES FINAIS

O trabalho presente se propôs a seguinte investigação: em que medida os indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC) permitem classificar as faixas de desempenho do Índice de Desenvolvimento da Educação Básica (IDEB) nos municípios de Santa Catarina e quais desses indicadores mais influenciam os modelos. Para isso, o IDEB dos anos iniciais (AI) e dos anos finais (AF) do ensino fundamental foi segmentado em faixas a partir da nota bruta, e quatro algoritmos baseados em árvores de decisão (*Random Forest*, *XGBoost*, *LightGBM* e *CatBoost*) foram treinados e comparados em dois experimentos: um com todos os atributos da base, total de 132 atributos, e outro com um subconjunto de 105 atributos, obtido por filtragem de correlação e remoção dos indicadores do ODS 4, relacionados à educação. A importância dos atributos foi extraída pelas medidas intrínsecas de cada algoritmo, normalizadas, calculadas entre sementes e associadas ao Objetivo de Desenvolvimento Sustentável (ODS).

Os resultados permitem atender aos objetivos específicos propostos. A revisão da literatura sustentou a escolha de modelos de árvores e de métricas de interpretabilidade. A análise exploratória evidencia a complexa diversidade da base nacional e justifica o recorte em Santa Catarina. A seleção de atributos reduziu o conjunto de 135 para 105 colunas, e a comparação entre os dois experimentos mostrou que essa redução não alterou o desempenho de forma perceptível, dentro da análise permitida pelo tamanho do conjunto de teste. Os modelos de classificação foram aplicados e avaliados nas duas variáveis alvo e as métricas de importância evidenciaram os indicadores mais relevantes. Portanto, considera-se atingido o objetivo geral de analisar o desempenho de modelos de classificação baseados em árvores de decisão na predição das faixas do IDEB e de identificar, por suas métricas estruturais, os indicadores sustentáveis associados a essa classificação. A principal contribuição do trabalho é a análise do IDEB a partir de dados externos ao ambiente escolar, restrita a um estado e acompanhada de interpretabilidade, com um procedimento reprodutível.

Quanto ao desempenho preditivo, os algoritmos de *gradient boosting* (*LightGBM*, *XGBoost* e *CatBoost*) apresentaram resultados semelhantes ao *Random Forest*. A etapa de seleção de atributos mostrou-se benéfica ao eliminar variáveis redundantes, resultando em um ganho na acurácia dos modelos para ambas as etapas do ensino fundamental. Contudo, como a diferença de acertos entre os algoritmos equivale a poucos municípios no conjunto de teste, não é possível afirmar a superioridade absoluta de um modelo sobre os demais. Na análise de importância, os indicadores de saúde pública (ODS 3) destacaram-se como os mais influentes nos anos finais, enquanto nos anos iniciais a relevância esteve concentrada nos indicadores educacionais (ODS 4) e nos escores agregados do índice. Esses achados reforçam que a qualidade educacional municipal está associada a fatores socioeconômicos externos ao ambiente escolar, fornecendo direcionamentos úteis para a gestão pública. Cabe ressaltar que os resultados indicam associação estatística entre as variáveis, e não uma relação direta de causa e efeito.

Algumas limitações metodológicas devem ser consideradas, como: o número reduzido

de municípios analisados, que torna o conjunto de dados pequeno, o que deixa o modelo mais sensível a erros pontuais. Além disso, os testes foram realizados com uma única divisão dos dados, sem validações repetidas. Adicionalmente, a baixa quantidade de cidades com notas extremas (muito altas ou muito baixas) também dificulta uma avaliação mais estável nessas faixas. Outro ponto é que alguns índices gerais podem apresentar informações parecidas com a nota avaliada, e variáveis semelhantes acabam dividindo a importância entre si, dificultando isolar o impacto de cada indicador. Por fim, os resultados refletem apenas a realidade de Santa Catarina e não devem ser generalizados para outros estados.

Como trabalho futuro, sugere-se inicialmente repetir a avaliação com validação cruzada repetida ou múltiplas partições, de modo a obter intervalos de confiança e comparações estatisticamente mais robustas. Além de complementar as métricas intrínsecas com outras técnicas de interpretabilidade, como a importância por permutação e o TreeSHAP, que também indica a direção do efeito de cada indicador. Ainda há a possibilidade de tratar as faixas do IDEB como categorias ordenadas, por meio de classificação ordinal ou regressão, em vez de classes independentes, além de incluir agrupamentos de municípios em perfis, a fim de verificar se modelos específicos por perfil melhoram a predição. Esse trabalho também possui a possibilidade de estender a análise a outros estados ou a outros anos do IDEB, bem como incorporar dados escolares do INEP, de modo a comparar a contribuição de fatores internos e externos à escola.

REFERÊNCIAS

BARROS, Abílio Nogueira; ALVES, Gabriel; MELLO, Rafael Ferreira. Entendendo os fatores de previsão do TDI nas escolas públicas brasileiras: Uma abordagem usando a técnica SHAP. In: **Anais do XXXV Simpósio Brasileiro de Informática na Educação (SBIE)**. Porto Alegre, RS: Sociedade Brasileira de Computação (SBC), 2024. p. 1529–1542. Disponível em: https://sol.sbc.org.br/index.php/sbie/article/view/31339. Citado na página 23.

BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006. Citado na página 19.

BREIMAN, Leo. Random forests. **Machine Learning**, Springer, v. 45, n. 1, p. 5–32, 2001. Citado na página 21.

BREIMAN, Leo. Random forests. **Machine learning**, Springer, v. 45, n. 1, p. 5–32, 2001. Citado na página 30.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco, California: ACM, 2016. p. 785–794. Citado 2 vezes nas páginas 21 e 30.

FEITOSA, T. C. Aplicações de aprendizagem de máquina com dados do INEP: Uma revisão de literatura. In: SOCIEDADE BRASILEIRA DE COMPUTAçãO (SBC). **Anais do XXIV Congresso Brasileiro de Informática na Educação (CBIE)**. Porto Alegre, RS, 2025. p. 120–131. Disponível em: https://sol.sbc.org.br/index.php/ctrle/article/view/40463. Citado na página 23.

FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, JSTOR, v. 29, n. 5, p. 1189–1232, 2001. Citado na página 21.

HOTELLING, Harold. Analysis of a complex of statistical variables into principal components. **Journal of Educational Psychology**, Warwick & York, v. 24, n. 6, p. 417–441, 1933. Citado na página 20.

Instituto Cidades Sustentáveis. Índice de desenvolvimento sustentável das cidades - brasil (idsc-br). 2023. Disponível em: https://idsc.cidadessustentaveis.org.br/. Citado 2 vezes nas páginas 15 e 19.

Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Índice de desenvolvimento da educação básica (ideb). 2024. Disponível em: https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/ideb. Citado 2 vezes nas páginas 15 e 20.

KE, Guolin et al. Lightgbm: A highly efficient gradient boosting decision tree. In: **Advances in Neural Information Processing Systems 30 (NIPS 2017)**. [S.l.]: Curran Associates, Inc., 2017. p. 3146–3154. Citado 2 vezes nas páginas 21 e 30.

MITCHELL, Tom M. **Machine Learning**. New York: McGraw-Hill, 1997. Citado na página 19.

MURPHY, Kevin P. **Machine Learning: A Probabilistic Perspective**. Cambridge: MIT Press, 2012. Citado na página 19.

Organização das Nações Unidas. Transformando nosso mundo: A agenda 2030 para o desenvolvimento sustentável. 2015. Disponível em: https://brasil.un.org/sites/default/files/2020-09/agenda2030-pt-br.pdf. Citado 2 vezes nas páginas 15 e 19.

PEARSON, Karl. On lines and planes of closest fit to systems of points in space. **The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science**, Taylor & Francis, v. 2, n. 11, p. 559–572, 1901. Citado na página 20.

PINTO, Glevson da Silva. **Modelo de análise e predição para identificação dos fatores que influenciam o desempenho escolar na rede de ensino básico: estudo de caso em escolas municipais de Alagoas**. Dissertação (Dissertação de Mestrado) — Universidade Federal de Alagoas (UFAL), Maceió, AL, 2021. Disponível em: https://www.repositorio.ufal.br/handle/riufal/7782. Citado na página 23.

PROKHORENKOVA, Liudmila et al. Catboost: unbiased boosting with categorical features. In: **Advances in Neural Information Processing Systems 31 (NeurIPS 2018)**. [S.l.]: Curran Associates, Inc., 2018. p. 6639–6649. Citado 2 vezes nas páginas 21 e 30.

SILVA, Ivonaldo Vicente da. **Mineração de Dados para Descoberta de Fatores Preditivos do IDEB**. Tese (Tese de Doutorado) — Universidade Paulista (UNIP), São Paulo, SP, 2022. Disponível em: https://repositorio.unip.br/engenharia-dissertacoes-teses/mineracao-de-dados-para-descoberta-de-fatores-preditivos-de-sucesso-em-avaliacoes-de-larga-escala-dos-a Citado na página 23.

SOARES, Raimundo de Castro et al. Minerando dados para entender os fatores de influência da qualidade educacional do maranhão. **Revista Brasileira de Informática na Educação (RBIE)**, v. 28, p. 854–878, 2020. Disponível em: https://journals-sol.sbc.org.br/index.php/rbie/article/view/2831. Citado na página 23.