UNIVERSIDADE DO ESTADO DE SANTA CATARINA – UDESC
CEAVI
PROGRAMA DE GRADUAÇÃO – ESO

CLARA DOS SANTOS BECKER

PREDIÇÃO DO DESEMPENHO DO IDEB EM MUNICÍPIOS CATARINENSES VIA APRENDIZADO DE MÁQUINA E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL DAS CIDADES

IBIRAMA
2026

CLARA DOS SANTOS BECKER

PREDIÇÃO DO DESEMPENHO DO IDEB EM MUNICÍPIOS CATARINENSES VIA APRENDIZADO DE MÁQUINA E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL DAS CIDADES

Trabalho de conclusão apresentado ao curso de Engenharia de Software do Centro de Educação Superior do Alto Vale do Itajaí (CEAVI), da Universidade do Estado de Santa Catarina (UDESC), como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Software.

Orientador: Prof. Dr. Marcelo de Souza

IBIRAMA
2026

Para gerar a ficha catalográfica de teses e
dissertações acessar o link:
https://www.udesc.br/bu/manuais/ficha

dos Santos Becker, Clara
PREDIÇÃO DO DESEMPENHO DO IDEB EM MUNICÍPIOS CATARINENSES VIA APRENDIZADO DE MÁQUINA E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL DAS CIDADES / Clara dos Santos Becker. – Ibirama, 2026.
44 p. : il.

Orientador: Prof. Dr. Marcelo de Souza.
Trabalho de Conclusão de Curso – Universidade do Estado de Santa Catarina, Centro de Educação Superior do Alto Vale do Itajaí, Programa de Graduação em Engenharia de Software, Ibirama, 2026.

1. Índice de Desenvolvimento da Educação Básica. 2. Aprendizado de Máquina. 3. Objetivos de Desenvolvimento Sustentável. 4. Interpretabilidade de Modelos. 5. Políticas Públicas Educacionais. I. de Souza, Marcelo. II. Universidade do Estado de Santa Catarina, Centro de Educação Superior do Alto Vale do Itajaí, Programa de Graduação em Engenharia de Software. III. Predição do índice do IDEB com modelos de aprendizado de máquina explicáveis e Indicadores de Desenvolvimento Sustentável.

CLARA DOS SANTOS BECKER

PREDIÇÃO DAS FAIXAS DE DESEMPENHO DO IDEB EM MUNICÍPIOS CATARINENSES VIA APRENDIZADO DE MÁQUINA E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

Trabalho de conclusão apresentado ao curso de Engenharia de Software do Centro de Educação Superior do Alto Vale do Itajaí da Universidade do Estado de Santa Catarina, como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Software.

Orientador: Prof. Dr. Marcelo de Souza

BANCA EXAMINADORA:

Prof. Marcelo de Souza, Dr.
Universidade do Estado de Santa Catarina

Membros:

Prof. Marília Guterres Ferreira, Dra.
Universidade do Estado de Santa Catarina

Prof. Carlos Alberto Barth, Me.
Universidade do Estado de Santa Catarina

Ibirama, 10 de novembro de 2026

Dedico aos meus pais por sempre serem meu maior exemplo de dignidade, força e resiliência. Especialmente à minha mãe, que me ensinou a conquistar a liberdade feminina através dos estudos.

AGRADECIMENTOS

Agradeço primeiramente aos meus pais, Hertz Becker e Rejane Clezar, por sempre me incentivarem e me apoiarem ao longo de toda a minha trajetória pessoal e acadêmica. Sou grata também pelo apoio da minha irmã, Gabriela, por sempre me ouvir quando as coisas pesaram, espero um dia ser uma inspiração para ela. Minha conquista acadêmica não é apenas minha, mas de toda a minha família, que sempre fez o que estava ao seu alcance e além, para me dar oportunidades.

Agradeço também ao meu orientador, Prof. Dr. Marcelo de Souza, pela orientação ao longo dos anos, pela colaboração em vários projetos de pesquisa e por aceitar conduzir este trabalho de conclusão de curso. Meu agradecimento também por mostrar que a pesquisa é um caminho a se seguir e por ser um verdadeiro exemplo de pesquisador.

Sou grata aos meus amigos Thaiane Bento, Erick Warmling, Lucas Gitirana, Thassyana Alves e Marco Possamai que se tornaram uma segunda família em Ibirama, especialmente ao meu mais querido amigo e colega Lucas Falcade, minha dupla de faculdade. Nosso apoio mútuo durante toda a jornada acadêmica fez toda a diferença. Agradeço também aos meus amigos felinos de quatro patas, Jade e Vesguinho, que me acompanharam em todos os momentos, sempre à procura de carinho.

Agradeço também aos outros pilares da minha vida Luz Bopsin, minha melhor amiga há 13 anos que me viu por todas as fases e transformações e sempre decidiu estar ao meu lado. Agradeço por fim ao meu namorado Matheus Oliver por me acompanhar na jornada do desenvolvimento desse trabalho e por sempre acreditar no meu potencial.

Como disse Taylor Swift: "Nenhum de nós fez isso sozinho. Cada um de nós é uma colcha de retalhos daqueles que nos amaram, daqueles que acreditaram em nosso futuro, daqueles que nos mostraram empatia e bondade ou nos disseram a verdade mesmo quando não era fácil de ouvir". A todos os que foram minha colcha de retalhos nesta jornada, meu muito obrigada.

“Que ninguém se engane: a liberdade é
conquistada a duras penas, mas é o único chão
onde vale a pena pisar.” (Lispector, Clarice)

RESUMO

A qualidade da educação básica é frequentemente avaliada de forma isolada, sem considerar os fatores socioeconômicos e ambientais que impactam o desempenho escolar fora de sala de aula. Neste contexto, os indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC) oferecem uma perspectiva multidimensional que pode ser explorada para compreender o desempenho educacional em nível municipal. Este trabalho propõe analisar o desempenho de modelos preditivos baseados em árvores de decisão na tarefa de classificação das faixas de desempenho do Índice de Desenvolvimento da Educação Básica (IDEB) nos municípios do estado de Santa Catarina, com dados do IDSC. A metodologia compreende etapas de análise exploratória, pré-processamento com remoção preventiva de vazamento de dados, seleção de atributos por filtragem de correlação e remoção dos indicadores com relação à educação, além de validação cruzada para ajuste de hiperparâmetros. Foram comparados os algoritmos *Random Forest*, *XGBoost*, *LightGBM* e *CatBoost*, avaliados separadamente para os anos iniciais e para os anos finais do ensino fundamental, por meio de acurácia, precisão, *recall* e F1-*score*. A análise de importância dos atributos mostrou que os indicadores de saúde pública (ODS 3) concentram a maior parcela da importância na separação das faixas do IDEB nos Anos Finais. Os resultados indicam associação entre o contexto socioeconômico dos municípios catarinenses e as faixas de desempenho do IDEB, fornecendo embasamentos quantitativos e interpretáveis para o planejamento e a formulação de políticas públicas integradas na gestão educacional.

Palavras-chave: Índice de Desenvolvimento da Educação Básica; Aprendizado de Máquina; Objetivos de Desenvolvimento Sustentável; Interpretabilidade de Modelos; Políticas Públicas Educacionais.

ABSTRACT

The quality of basic education is frequently assessed in isolation, without considering the socioeconomic and environmental factors that impact school performance outside the classroom. In this context, the indicators of the Sustainable Development Cities Index (IDSC) offer a multidimensional perspective that can be explored to understand educational performance at the municipal level. This work proposes to analyze the performance of decision tree-based predictive models in the classification task of the performance bands of the Basic Education Development Index (IDEB) in the municipalities of the state of Santa Catarina, using IDSC data. The methodology comprises stages of exploratory data analysis, preprocessing with preventive removal of data leakage, feature selection by correlation filtering and removal of indicators related to education, as well as cross-validation for hyperparameter tuning. The algorithms *Random Forest*, *XGBoost*, *LightGBM*, and *CatBoost* were compared, evaluated separately for the Early Years and Final Years of elementary school, through accuracy, precision, *recall*, and F1-*score*. The feature importance analysis showed that public health indicators (SDG 3) concentrate the largest share of importance in separating the IDEB bands in the final years. The results indicate an association between the socioeconomic context of Santa Catarina municipalities and the IDEB performance bands, providing quantitative and interpretable grounds for the planning and formulation of integrated public policies in educational management.

Keywords: Basic Education Development Index; Machine Learning; Sustainable Development Goals; Model Interpretability; Educational Public Policies.

LISTA DE ILUSTRAÇÕES

Figura 1 – Matriz de correlação linear entre indicadores do IDSC e o IDEB. 26
Figura 2 – Gráfico de dispersão entre o indicador de Baixa Renda (eixo x) e o IDEB (eixo) com linha de tendência linear. 27
Figura 3 – Organização do projeto. 32

LISTA DE TABELAS

Tabela 1 – Comparativo entre os trabalhos correlatos e o presente estudo. 25
Tabela 2 – Distribuição dos municípios catarinenses por faixa de desafio do IDEB (Painel IDSC-BR), após os filtros aplicados. 29
Tabela 3 – Espaços de busca dos hiperparâmetros de cada algoritmo. 31
Tabela 4 – Métricas de desempenho no conjunto de teste para anos finais com o conjunto de dados completo. 34
Tabela 5 – Métricas de desempenho no conjunto de teste para anos iniciais com o conjunto de dados completo. 35
Tabela 6 – Métricas de desempenho no conjunto de teste para anos finais com subconjunto de dados com 105 atributos. 36
Tabela 7 – Métricas de desempenho no conjunto de teste para anos iniciais com subconjunto de dados com 105 atributos. 36
Tabela 8 – Importância agregada por ODS no conjunto e subconjunto com 105 atributos para os anos finais. 38
Tabela 9 – Importância agregada por ODS no conjunto e subconjunto com 105 atributos para os anos iniciais. 38
Tabela 10 – Uso de ferramentas de inteligência artificial. 43
Tabela 11 – Prompts enviados à ferramenta de IA e resumo das respostas. 44

LISTA DE ABREVIATURAS E SIGLAS

IDEB	Índice de Desenvolvimento da Educação Básica[cite: 102]
IDSC	Índice de Desenvolvimento Sustentável das Cidades[cite: 102]
ODS	Objetivos de Desenvolvimento Sustentável[cite: 102]
ONU	Organização das Nações Unidas[cite: 102]
UDESC	Universidade do Estado de Santa Catarina[cite: 102]

LISTA DE SÍMBOLOS

X	Matriz ou vetor de características de entrada (atributos preditores do IDSC)
Y	Variável alvo (faixas de desempenho do IDEB)
$\hat{f}(X)$	Função estimada pelo modelo de aprendizado de máquina
$\hat{y}$	Valor predito pelo modelo
TP	Verdadeiros Positivos (*True Positives*)
TN	Verdadeiros Negativos (*True Negatives*)
FP	Falsos Positivos (*False Positives*)
FN	Falsos Negativos (*False Negatives*)
$F1$	Métrica F_1-*score* (média harmônica entre precisão e *recall*)
K	Número total de classes no problema multiclasse
c	Classe específica avaliada no cenário multiclasse
r	Coeficiente de correlação linear de Pearson
L_1, L_2	Termos de regularização de normas L1 e L2
$\sum$	Símbolo de somatório utilizado nas equações de média e métricas

SUMÁRIO

	Abstract	**8**
1	**INTRODUÇÃO**	**15**
1.1	PROBLEMA	**16**
1.2	OBJETIVOS	**16**
1.3	JUSTIFICATIVA	**17**
2	**METODOLOGIA**	**18**
2.1	CONJUNTO DE DADOS	**18**
2.2	FLUXO OPERACIONAL E ABORDAGEM PREDITIVA	**18**
2.3	AVALIAÇÃO E INTERPRETABILIDADE	**19**
3	**FUNDAMENTAÇÃO TEÓRICA**	**20**
3.1	APRENDIZADO DE MÁQUINA	**20**
3.1.1	**Paradigmas de Aprendizado de Máquina**	**20**
3.1.2	**Redução de Dimensionalidade e Seleção de Atributos**	**20**
3.2	MODELOS PREDITIVOS DE CLASSIFICAÇÃO	**21**
3.2.1	**Random Forest**	**21**
3.2.2	**Gradient Boosting**	**22**
3.2.3	**Métricas de Avaliação de Modelos de Classificação**	**22**
3.2.4	**Métricas Nativas de Importância Baseadas em Árvores**	**23**
3.3	TRABALHOS CORRELATOS	**24**
4	**ABORDAGEM PROPOSTA**	**26**
4.1	ANÁLISE EXPLORATÓRIA DE DADOS	**26**
4.2	PRÉ-PROCESSAMENTO DA BASE DE DADOS	**28**
4.3	TREINAMENTO DOS MODELOS	**28**
4.3.1	**Definição das classes com base no Painel IDSC**	**28**
4.3.2	**Partição dos dados**	**29**
4.3.3	**Seleção de atributos**	**29**
4.3.4	**Modelos e ajuste de hiperparâmetros**	**30**
4.3.5	**Métricas de avaliação**	**31**
4.3.6	**Importância dos atributos**	**31**
4.4	ORGANIZAÇÃO DO PROJETO	**32**
5	**RESULTADOS E DISCUSSÃO**	**34**
5.1	ANÁLISE DE DESEMPENHO DOS MODELOS	**34**
5.2	IMPACTO DA SELEÇÃO DE ATRIBUTOS	**35**
5.3	ANÁLISE DA IMPORTÂNCIA DOS ATRIBUTOS	**37**
5.3.1	**Importância agregada por ODS na base completa**	**37**

5.3.2 Efeito da seleção de atributos sobre a importância 37
6 CONSIDERAÇÕES FINAIS 39
REFERÊNCIAS 41
6.1 USO DE FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL **43**
6.2 PROMPTS UTILIZADOS **44**

1 INTRODUÇÃO

O plano global criado pela ONU, denominado Agenda 2030, propõe uma ação conjunta que visa o desenvolvimento sustentável e a erradicação da pobreza em todas as suas formas.Segundo a Organização das Nações Unidas (2015), a ação proposta pela Agenda 2030 estabelece 17 objetivos e 169 metas que abrangem cinco grandes áreas: pessoas, planeta, prosperidade, paz e parceria. As cinco áreas abrangem objetivos para garantir condições dignas de vida às pessoas, possibilitando acesso à educação, saúde e igualdade. No que tange à conservação do meio ambiente, com o objetivo de combater a degradação ambiental e promover uso sustentável de recursos ambientais, possibilitando desenvolvimento e prosperidade da sociedade de forma equilibrada, visando também estabelecer a paz e a justiça social.

O Brasil possui o Índice de Desenvolvimento Sustentável das Cidades (IDSC) (Instituto Cidades Sustentáveis, 2023), com 100 indicadores que apresentam métricas de cada uma das cidades com relação ao cumprimento dos 17 objetivos de desenvolvimento sustentável (ODS) definidos na Agenda 2030. Esses indicadores oferecem uma visão do desenvolvimento dos municípios de forma multidimensional, compreendendo esferas sociais, ambientais e institucionais. Um dos indicadores pertencentes ao IDSC é o Índice de Desenvolvimento da Educação Básica (IDEB), responsável por avaliar a qualidade da educação básica. O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (2024) abrange dois aspectos fundamentais: o fluxo escolar e as médias de desempenho nas avaliações.

Avanços tecnológicos, como os modelos de aprendizado de máquina, fornecem técnicas de aprendizado supervisionado aplicáveis à predição de índices educacionais como o IDEB. No escopo deste trabalho, a predição desse valor é realizada exclusivamente com base nos indicadores do IDSC, diferenciando-se dos cálculos tradicionais fundamentados em notas e taxas de aprovação escolares. Sendo assim, a abordagem proposta considera a realidade do município com base em fatores exógenos à sala de aula, integrando aspectos sociais, econômicos e ambientais da realidade dos alunos catarinenses. Dessa forma, o método se mostra válido para a gestão pública educacional ao relacionar o desempenho do IDEB a um contexto multidimensional externo ao ambiente escolar.

A abordagem proposta visa analisar especificamente os municípios do estado de Santa Catarina, além disso, se faz necessária a interpretabilidade do resultado da predição. Para a resolução desse aspecto, são aplicadas métricas de relevância dos atributos nos modelos baseados em árvores de decisão, o que permite extrair de forma direta quais os indicadores do IDSC possuem maior influência no índice educacional. Diante do cenário apresentado, o entendimento dos aspectos que têm maior peso na variação do índice do IDEB auxiliam a tomada de decisão no poder público, visando à melhoria do sistema educacional catarinense. A tarefa de identificação dos fatores de desenvolvimento sustentável do município que influenciam diretamente a qualidade da educação básica pode levar à implementação de políticas públicas com objetivos diretos na educação.

1.1 PROBLEMA

O conjunto de dados IDSC, que abrange todos os indicadores de cumprimento dos objetivos definidos na Agenda 2030, apresenta diversas características com relação ao desenvolvimento sustentável do município que ainda não foram analisadas e exploradas sob a ótica da ciência de dados, sobretudo de forma aprofundada, por meio da construção de modelos capazes de realizar a predição do indicador do IDEB.

Cada município apresenta particularidades socioeconômicas e educacionais que influenciam de maneira distinta a sua relação com o IDEB, evidenciando uma dinâmica que não é homogênea em todo o estado. O estudo, portanto, busca explorar os padrões e fatores comuns predominantes entre os municípios catarinenses que impactam o desempenho educacional.

Além disso, o indicador do IDEB geralmente é visto como uma métrica isolada apenas no âmbito da educação, sem levar em conta aspectos do desenvolvimento do município, como saúde ou saneamento básico. Esses aspectos estão disponíveis no conjunto de indicadores IDSC e ainda não foram explorados com esse objetivo. Os modelos preditivos podem ser aplicados e, com base no treinamento, predizer a nota do IDEB. Porém, para uma tomada de decisão com relação à melhoria do sistema educacional, se faz necessária a compreensão dos fatores que influenciam o resultado da predição.

1.2 OBJETIVOS

Este trabalho se propõe à exploração e análise da base de dados dos indicadores do IDSC, aplicando modelos de aprendizado de máquina com o objetivo de realizar a predição do IDEB dos municípios catarinenses. Adicionalmente, busca-se avaliar a importância dos atributos inerentes aos modelos preditivos para identificar os fatores que mais influenciam os resultados.

O objetivo geral deste trabalho é analisar o desempenho de modelos de classificação baseados em Árvores de Decisão na predição do IDEB nos municípios do estado de Santa Catarina, utilizando suas métricas estruturais de importância de atributos para identificar os indicadores sustentáveis que possuem maior impacto na educação básica.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos: Aplicar técnicas de análise exploratória de dados, matriz de correlação linear de Pearson e gráficos de dispersão para a exploração e análise inicial da base de dados do IDSC;

Aplicar técnicas de redução de dimensionalidade e seleção de características, compreendendo filtragem de correlação e Análise de Componentes Principais (PCA), para a seleção de atributos para predição;

Aplicar modelos de aprendizado de máquina de classificação baseados em árvores de decisão: Random Forest, XGBoost, LightGBM e CatBoost, com ajuste de hiperparâmetros via busca aleatória e validação cruzada, para prever as faixas de desempenho do IDEB dos municípios de Santa Catarina;

Aplicar métricas de extração da importância dos atributos nos modelos preditivos: redução

média de impureza, ganho, frequência, cobertura e variação de predição. Agrupadas por Objetivos de Desenvolvimento Sustentável (ODS) para validar a influência dos indicadores do IDSC na predição do IDEB e o entendimento do funcionamento do modelo de predição;

Avaliar e comparar o desempenho dos modelos, por meio das métricas de acurácia, precisão, recall e F1-score e o comportamento das métricas de relevância de atributos entre os cenários com a base completa e com o subconjunto de atributos selecionados dos municípios catarinenses.

1.3 JUSTIFICATIVA

Diante da complexidade do cenário social e econômico atual, a formulação de políticas públicas regionais exige o uso de evidências empíricas. Embora o Brasil apresente fortes contrastes entre suas regiões, a escolha de delimitar a análise ao estado de Santa Catarina permite avaliar um contexto socioeconômico e educacional mais próximo da realidade local. Desse modo, o emprego de modelos de aprendizado de máquina direcionados à classificação do desempenho do IDEB nos municípios catarinenses evita as distorções de uma base nacional ampla, oferecendo diagnósticos mais assertivos e aplicáveis à gestão pública do estado.

Nesse contexto, as técnicas de análise de dados e aprendizado de máquina facilitam a identificação de padrões entre os indicadores do IDSC e o IDEB. A predição do índice oferece uma perspectiva estratégica aos gestores, pois ajuda a identificar como fatores externo se relacionam com o rendimento escolar. Isso viabiliza ações preventivas para a melhoria da educação básica antes mesmo da divulgação oficial das notas.

Por fim, para que essa abordagem seja útil à administração pública, o modelo preditivo precisa ser interpretável. O uso de algoritmos baseados em árvores de decisão permite extrair diretamente a importância de cada atributo, mapeando quais fatores do IDSC exercem maior peso sobre o desempenho escolar. Esse diagnóstico direciona o poder público para intervenções mais precisas, focando nos problemas estruturais que impactam a qualidade do ensino.

2 METODOLOGIA

Este capítulo detalha a execução prática da metodologia proposta, abrangendo desde o fluxo operacional e as ferramentas utilizadas até o treinamento dos modelos preditivos de classificação e a análise de interpretabilidade. A abordagem metodológica estrutura-se em etapas sequenciais que compreendem a análise exploratória dos dados do IDSC-BR, o pré-processamento com a remoção preventiva de vazamento de dados, a seleção de atributos e o particionamento do conjunto de dados. Em seguida, são apresentados o treinamento e o ajuste de hiperparâmetros de algoritmos baseados em árvores de decisão para a classificação das faixas de desempenho do IDEB nos municípios catarinenses, bem como as métricas de avaliação de desempenho e os métodos de extração da importância dos atributos para a interpretação dos fatores associados.

2.1 CONJUNTO DE DADOS

O estudo explora uma única base de dados, de acesso público: o Índice de Desenvolvimento Sustentável das Cidades (IDSC), edição de 2025 (Instituto Cidades Sustentáveis, 2023), estruturado a partir dos 17 Objetivos de Desenvolvimento Sustentável (ODS) da ONU (Organização das Nações Unidas, 2015). A planilha original reúne os 5.570 municípios brasileiros e 442 colunas, entre indicadores brutos, indicadores normalizados em escala de 0 a 100, pontuações por objetivo, classificações do Painel e metadados. O Índice de Desenvolvimento da Educação Básica (IDEB), produzido pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024), está incluído na própria base como indicador do ODS 4, tanto para os anos iniciais quanto para os anos finais do ensino fundamental.

Dessa forma, atributos e variável alvo têm a mesma origem. A nota bruta do IDEB foi extraída da base e mantida em arquivo separado, constituindo a variável alvo (Y), enquanto os demais indicadores compõem os atributos preditores (X), após a remoção preventiva das colunas que compartilham dependência com o IDEB. O recorte espacial compreende os 295 municípios do estado de Santa Catarina, identificados pelo código do IBGE, dos quais permaneceram 151 municípios nos anos finais e 272 nos anos iniciais após a exclusão daqueles sem IDEB divulgado e das classes com menos de dois exemplos.

2.2 FLUXO OPERACIONAL E ABORDAGEM PREDITIVA

Para a realização de todos os objetivos, é necessária uma exploração inicial da base de dados, além de um estudo aprofundado em técnicas de aprendizado supervisionado e métodos de interpretabilidade de modelos. Essa exploração da base e o estudo teórico visam compreender o cenário e fundamentar a escolha dos algoritmos de aprendizado de máquina, levando em consideração uma delimitação da base de dados a um subconjunto dos municípios do estado de

Santa Catarina para predição do índice do IDEB. A análise exploratória de dados é realizada com o objetivo de compreender a distribuição dos indicadores e identificar padrões preliminares. Após essa análise, é executado o pré-processamento da base de dados, visando à adequação dos dados para a execução dos modelos de aprendizado de máquina, de forma a garantir a confiabilidade e o desempenho dos algoritmos.

A etapa preditiva inicial consiste na aplicação dos modelos de classificação no subconjunto de dados dos municípios catarinenses para a obtenção de um resultado preditivo de referência. Os modelos aplicados para comparação e análise serão os algoritmos baseados em árvores de decisão *Random Forest* e *Gradient Boosting*, sendo representado neste trabalho pelos algoritmos *Extreme Gradient Boosting*, *Light Gradient Boosting Machine* e *Categorical Boosting*. Com o objetivo de melhorar as métricas de avaliação dos resultados do modelo é realizada uma seleção de atributos dos dados. Nessa etapa, são empregadas técnicas de análise de correlação de variáveis para, após essa seleção, realizar uma nova predição com as características selecionadas de todos os municípios catarinenses.

2.3 AVALIAÇÃO E INTERPRETABILIDADE

A etapa subsequente consiste na análise do desempenho dos modelos em duas abordagens distintas: inicialmente, com o subconjunto de dados completo e empregando apenas o conjunto de atributos selecionados. O desempenho dos modelos de classificação é avaliado por meio das métricas de Acurácia, Precisão, *Recall* e o F1-*score* macro. Por fim, a extração da relevância dos atributos ocorrerá por meio da análise das métricas de importância intrínsecas aos algoritmos baseados em árvore de decisão, calculadas a partir da redução da impureza ou ganho de informação nos nós de decisão. Essa perspectiva estrutural permite identificar quais indicadores do IDSC exercem maior influência no aprendizado dos modelos, auxiliando no mapeamento dos fatores associados ao desempenho educacional dos municípios catarinenses.

Este trabalho utilizou a ferramenta de Inteligência Artificial Generativa *Claude* com o modelo *Sonnet 5.5* em etapas específicas da elaboração do texto e do código, sob supervisão humana e em conformidade com o Guia para Uso Ético e Responsável da Inteligência Artificial Generativa da UDESC. O detalhamento encontra-se no Apêndice A e os *prompts* utilizados, no Apêndice B. Os experimentos, os resultados e as conclusões são de responsabilidade da autora, que revisou, validou e editou todo o conteúdo produzido com apoio da ferramenta.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 APRENDIZADO DE MÁQUINA

O aprendizado de máquina (*machine learning*) é o ramo da inteligência artificial focado no desenvolvimento de algoritmos com capacidade de identificar padrões em grandes volumes de dados, no caso do aprendizado supervisionado, a identificação tem como objetivo predizer o resultado de um atributo específico. Segundo a definição clássica (Mitchell, 1997), o aprendizado de máquina permite que sistemas melhorem seu desempenho com base na experiência. No estudo apresentado, esses algoritmos são empregados para modelar a relação entre os índices do IDSC e o índice de avaliação do IDEB, sendo responsáveis por estimar a relação matemática entre estas variáveis.

3.1.1 Paradigmas de Aprendizado de Máquina

A literatura divide as abordagens de aprendizado de máquina em categorias formadas de acordo com a presença ou ausência de uma variável resposta durante o treinamento. As duas categorias abrangidas neste estudo são o aprendizado supervisionado e o não supervisionado.

O aprendizado de máquina supervisionado, de acordo com Murphy (2012), consiste no mapeamento de uma função que conecta um vetor de características de entrada X a uma saída esperada Y, utilizando um conjunto de dados previamente rotulado. O objetivo é aproximar uma função $\hat{f}(X) \approx Y$ que minimize o erro. O processo envolve a divisão dos dados em dois subconjuntos: treino e teste. O conjunto de treino é responsável pelo aprendizado por meio da identificação de padrões e o de teste é responsável por validar a eficácia do modelo, observando dados desconhecidos na fase de treinamento para avaliar seu resultado. Então, o algoritmo aprende a função que mapeia entradas a saídas por meio dos dados rotulados, aproximndo a relação entre as variáveis de entrada e de resposta.

Já o aprendizado não supervisionado, segundo (Bishop, 2006), foca na identificação de estruturas e correlações latentes em bases de dados que não possuem um alvo predefinido. Sem rótulos para guiar o treinamento, os algoritmos operam a partir de propriedades matemáticas dos dados, como proximidade espacial e densidade. Nesse estudo, esse paradigma é empregado no agrupamento dos municípios em perfis conforme suas características.

3.1.2 Redução de Dimensionalidade e Seleção de Atributos

Com o objetivo de mitigar a complexidade informacional, remover redundâncias e selecionar os indicadores mais relevantes de uma base de dados, empregam-se técnicas de pré-processamento voltadas à redução de dimensionalidade e seleção de *features*.

A primeira abordagem consiste na análise de correlação de variáveis, utilizada para identificar e eliminar atributos altamente colineares. Essa técnica avalia o grau de associação linear entre os pares de variáveis preditoras, permitindo descartar aquelas que carregam informa-

ções redundantes e mantendo apenas as que possuem maior independência estatística ou maior correlação direta com a variável alvo.

Adicionalmente, utiliza-se a técnica de análise de componentes principais (PCA - *Principal Component Analysis*). Proposta originalmente na estatística por Pearson (1901) e posteriormente desenvolvida de forma independente por Hotelling (1933), a PCA é um método não supervisionado de transformação linear amplamente aplicado para simplificar conjuntos de dados de alta dimensionalidade. O algoritmo mapeia o espaço original de variáveis para um novo sistema de coordenadas ortogonais, maximizando a variância explicada. As novas variáveis geradas, denominadas componentes principais, são combinações lineares dos indicadores originais, reduzindo o ruído e otimizando a eficiência computacional dos modelos preditivos.

3.2 MODELOS PREDITIVOS DE CLASSIFICAÇÃO

Modelos de classificação, como técnicas de aprendizado de máquina supervisionado, buscam aproximar uma função capaz de mapear variáveis preditoras X em uma variável alvo discreta Y. São empregados neste estudo modelos de classifiação baseados em árvores de decisão e eles se diferenciam entre si pela forma como as árvores são construídas e combinada.

O *Random Forest* Breiman (2001) combina várias árvores treinadas de forma independente e define a classe de resultado através do voto majoritário, ele tem como característica a variância ao combinar árvores, mostrando mais robustez a ruído e sendo pouco sensível à escolha de hiperparâmetros. O modelo se mostra menos interpretável do que o modelo de árvore de decisão e exige a imputação de dados ausentes. Já os modelos de *Gradient Boosting* Friedman (2001) treinam as árvores de forma sequencial, cada ávore corrige o erro da anterior. Os modelos *Gradient Boosting* explorados possuem alto desempenho preditivo, tratam valores ausentes internamente, porém se mostram mais sensíveis a escolha de hiperparâmetro.

3.2.1 Random Forest

O modelo *Random Forest*, proposto por Breiman (2001), evolui o paradigma de árvores de decisão por meio de aprendizado em conjunto (*ensemble*). O modelo possui duas estratégias principais de aleatorização: a amostragem com reposição (*Bootstrap*), na qual cada árvore é treinada com uma amostra distinta extraída do conjunto de dados original, e o subespaço aleatório de atributos, que restringe a escolha do melhor ponto de corte a um subconjunto sorteado de variáveis em cada divisão de nós.

O processo de construção de cada árvore ocorre de forma recursiva. Em tarefas de classificação, o algoritmo determina o ponto de corte em cada nó avaliando qual divisão resulta na maior pureza ou ganho de informação dos dados entre os nós filhos criados, medindo a homogeneidade das classes resultantes. Ao final do treinamento, o aprendizado é consolidado por meio do voto majoritário das predições independentes de todas as árvores para gerar o resultado final.

3.2.2 Gradient Boosting

O modelo *Gradient Boosting* treina árvores de decisão de forma sequencial, se diferenciando do modelo *Random Forest*, no qual o treinamento ocorre em paralelo. Conforme Friedman (2001), o princípio do algoritmo é a otimização iterativa de uma função de perda, em que cada nova árvore é ajustada para prever os resíduos (erros) das árvores anteriores. Dentre as principais evoluções desse algoritmo, destacam-se:

- **XGBoost (*Extreme Gradient Boosting*)**: Proposto por Chen e Guestrin (2016), adiciona termos de regularização L_1 (Lasso) e L_2 (Ridge) à função de perda para conter a complexidade das árvores e mitigar o sobreajuste. O algoritmo utiliza uma aproximação de Taylor de segunda ordem para otimizar a função objetivo e emprega um algoritmo de busca por divisões baseado em histogramas e quantis, acelerando o processamento em grandes volumes de dados.

- **LightGBM (*Light Gradient Boosting Machine*)**: Proposto por Ke et al. (2017), adota o crescimento de árvores orientado a folhas (*leaf-wise*), dividindo o nó que proporciona a maior redução do erro global, independentemente do nível da árvore. Para otimizar o tempo de execução e o consumo de memória, introduz duas técnicas fundamentais: a amostragem unilateral baseada em gradiente (*Gradient-based One-Side Sampling* - GOSS), que prioriza instâncias com maiores gradientes, e a agrupação de recursos exclusivos (*Exclusive Feature Bundling* - EFB), que reduz a dimensão do espaço de atributos.

- **CatBoost (*Categorical Boosting*)**: Desenvolvido por Prokhorenkova et al. (2018), destaca-se pelo tratamento nativo e eficiente de variáveis categóricas via *Target Encoding* ordenado (*Ordered Target Statistics*). Essa abordagem calcula a estatística da variável resposta considerando apenas as observações anteriores em uma permutação aleatória dos dados, o que previne o vazamento de dados (*target leakage*) e o sobreajuste. Além disso, o algoritmo utiliza árvores de decisão oblíquas e simétricas (*oblivious trees*), garantindo predições mais rápidas no tempo de inferência.

3.2.3 Métricas de Avaliação de Modelos de Classificação

Para a validação e a comparação dos modelos, são adotadas diferentes métricas de avaliação. No cenário multiclasse, os valores de TP, TN, FP e FN são obtidos para cada classe, considerando-a de forma isolada em relação às demais. As variáveis citadas representam: TP os verdadeiros positivos, TN os verdadeiros negativos, FP os falsos positivos e FN os falsos negativos.

A **acurácia** mede a proporção total de predições corretas realizadas pelo modelo em relação ao total de instâncias avaliadas, sendo a acurácia definida por

$$\text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN},$$

A **precisão** indica a proporção de predições corretas para uma classe específica em relação ao total de amostras classificadas como pertencentes àquela classe, calculada por

$$\text{Precisão} = \frac{TP}{TP+FP}.$$

O *recall* (ou sensibilidade) mede a capacidade do modelo de identificar corretamente todos os resultados reais pertencentes a uma determinada classe, sendo representado por

$$\text{Recall} = \frac{TP}{TP+FN}.$$

O **F1-*score*** é a média harmônica entre a precisão e o *recall*, resumindo em um único valor o equilíbrio entre os dois. Por penalizar valores muito baixos de qualquer um deles, é menos sensível do que a média aritmética a modelos que privilegiam uma métrica em detrimento da outra. Essa medida é dada por

$$F1 = \frac{2 \times \text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}.$$

Em problemas com mais de duas classes, precisão, *recall* e F1 são calculados para cada classe e combinados por uma média. Na **média macro**, atribui-se o mesmo peso a todas as classes, independentemente do número de instâncias de cada uma, sendo

$$\text{Métrica}_{macro} = \frac{1}{K}\sum_{c=1}^{K} \text{Métrica}_c,$$

em que K é o número de classes. Assim, o F1 macro é a média dos valores de F1 de cada classe. Essa agregação é adequada a problemas com classes desbalanceadas, pois o desempenho deficiente nas classes minoritárias reduz o valor final, o que não ocorre com a acurácia.

3.2.4 Métricas Nativas de Importância Baseadas em Árvores

Os modelos baseados em árvores de decisão possuem indicadores nativos com o objetivo de quantificar a importância das variáveis preditoras no processo de tomada de decisão. Em cenários de classificação, a técnica padrão mais empregada é a redução de impureza, conhecida como *Mean Decrease in Impurity* (MDI) ou importância baseada em Gini. Essa técnica quantifica a relevância de um atributo por meio do somatório ponderado da redução da impureza (índice de Gini ou a Entropia) gerada em todos os nós em que o atributo foi utilizado para dividir os dados, ponderada pela fração de amostras que atingem aqueles nós.

Apesar de sua eficiência computacional, a métrica MDI apresenta limitações conhecidas na literatura, como o viés de favorecer variáveis contínuas ou com alta cardinalidade, número grande de categorias distintas, que tendem a ser selecionadas com maior frequência em divisões das árvores. A alternativa para mitigar esse comportamento, é aplicar a **Importância de Permutação** (*Permutation Importance*), uma abordagem complementar que mede a queda no

desempenho preditivo, avaliado pelas métricas de avaliação, quando os valores de uma variável específica são aleatoriamente embaralhados no conjunto de dados de teste, destruindo sua correlação com a classe real.

Adicionalmente, modelos baseados em *Gradient Boosting* (como *XGBoost*, *LightGBM* e *CatBoost*) fornecem três métricas nativas complementares para o cálculo da importância dos atributos ao longo das iterações sequenciais:

- **Ganho (*Gain*)**: Representa a melhoria média na função de objetivo ou redução de perda proporcionada pelas divisões que aplicam o atributo. Indica o impacto efetivo da variável na qualidade preditiva do modelo.
- **Frequência (*Frequency* ou *Weight*)**: Contabiliza o número total de vezes que um atributo foi selecionado para realizar pontos de corte em todas as árvores construídas no *ensemble*.
- **Cobertura (*Cover*)**: Mede o volume ou a proporção de amostra que transitaram pelos nós divididos pelo atributo analisado, indicando a abrangência populacional daquela regra de decisão no modelo.

3.3 TRABALHOS CORRELATOS

Conforme revisão bibliográfica realizada, são encontrados diversos estudos com aplicações de algoritmos de aprendizado de máquina em microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) para predição do IDEB e para identificação de quais fatores são determinantes. Em uma escala regional, Soares et al. Soares, Neto e Coutinho (2020) realizam a predição por meio da aplicação de Árvores de Decisão em dados de escolas do estado do Maranhão. O estudo identificou que a escolaridade dos pais foi a variável com maior influência no modelo. Ademais, Pinto (2021) adotou técnicas de seleção de atributos nos dados de Alagoas, com o objetivo de reduzir o ruído da base de dados, isolando os dados que realmente impactavam a gestão municipal. Em outra perspectiva, Silva (2022) empregou o processo KDD (*Knowledge Discovery in Databases*) para projetar cenários educacionais preventivos, argumentando que a mineração de dados deve atuar proativamente antes da consolidação oficial dos ciclos de avaliação governamental.

Outro estudo, agora em escala nacional, volta-se para o mapeamento de técnicas e modelos mais robustos. A revisão sistemática da literatura de Feitosa Feitosa (2025) documentou os métodos mais adotados nas pesquisas do país, apontando modelos como *Random Forest*, SVM e *Árvores de Decisão* como os algoritmos mais aplicados e com melhor desempenho nessa área de pesquisa. Ainda com a aplicação de modelos baseados em árvores, Barros, Alves e Mello (2024) combinaram *Gradient Boosting* com a abordagem SHAP (XAI) para adicionar interpretabilidade ao modelo, medindo o impacto de atributos com distorção entre a idade e série do aluno ou falta de laboratórios nas escolas.

O que diferencia este trabalho da linha de pesquisa dos estudos presentes na literatura é o foco em dados externos ao ambiente escolar para predição da qualidade escolar da educação básica. Enquanto a maior parte das pesquisas explora exclusivamente os dados disponibilizados pelo INEP, o presente estudo avalia o impacto direto dos indicadores do IDSC sobre a nota do IDEB. Além disso, o trabalho diferencia-se ao associar a predição de faixas do IDEB a uma análise de interpretabilidade orientada pelos Objetivos de Desenvolvimento Sustentável (ODS), conforme sintetizado na Tabela 1. Essa metodologia aplicada permite identificar quais dimensões do desenvolvimento sustentável estão mais associadas ao desempenho educacional, fornecendo subsídios quantitativos para a gestão pública.

Tabela 1 – Comparativo entre os trabalhos correlatos e o presente estudo.

Estudo	**Escopo Geográfico**	**Base de Dados**	**Técnicas / Modelos**	**Foco Principal**
Soares et al. (2020)	Maranhão (Regional)	Microdados INEP (Escolas)	Árvores de Decisão	Impacto da escolaridade dos pais no IDEB.
Pinto (2021)	Alagoas (Regional)	Microdados INEP (Municípios)	Seleção de Atributos	Redução de ruído e gestão municipal.
Silva (2022)	Âmbito Nacional	Dados Educacionais do Governo	KDD (*Knowledge Discovery*)	Cenários preventivos educacionais.
Feitosa (2025)	Brasil	Literatura Nacional (Revisão)	Random Forest, SVM, Árvores	Mapeamento de algoritmos mais robustos.
Barros et al. (2024)	Brasil (Nacional)	INEP + Infraestrutura Escolar	Gradient Boosting + SHAP (XAI)	Explicabilidade de fatores de infraestrutura.
Presente Estudo	**Santa Catarina (Estadual)**	**IDSC-BR + IDEB Municipal**	**CatBoost, XGBoost, LightGBM, RF**	**Indicadores ODS e interpretabilidade aplicada à gestão.**

A partir do panorama sintetizado na Tabela 1, evidencia-se que os avanços recentes como os de Barros, Alves e Mello (2024), concentram-se principalmente em variáveis de infraestrutura escolar e desempenho restrito ao INEP. A inclusão dos indicadores do IDSC rompe com essa limitação tradicional, permitindo mapear de que maneira as metas de sustentabilidade urbana e social dos municípios catarinenses impactam o IDEB e fortalecem a tomada de decisão estratégica na gestão pública.

4 ABORDAGEM PROPOSTA

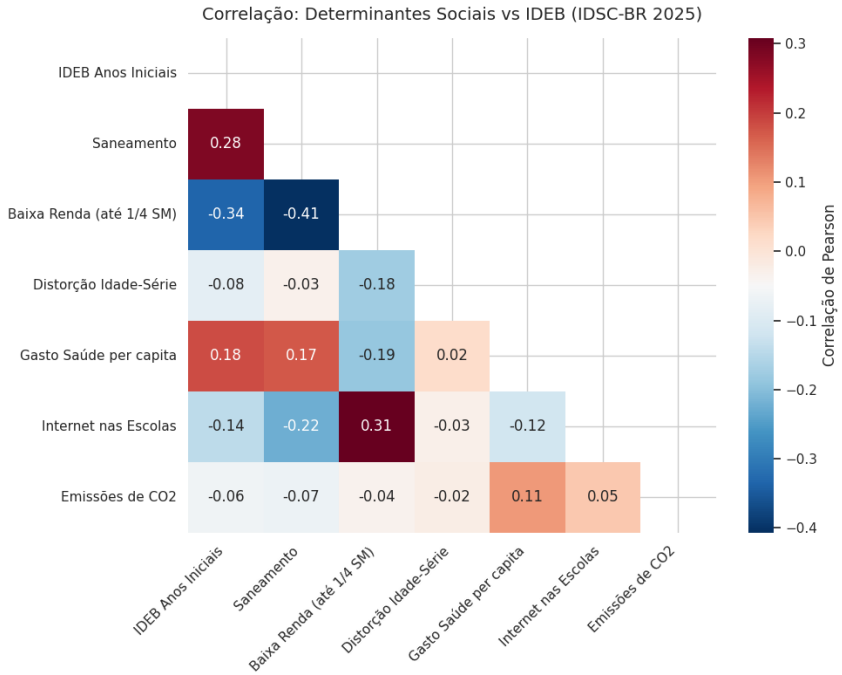
Este capítulo detalha a execução prática da metodologia proposta, abrangendo desde o fluxo operacional e as ferramentas utilizadas até o treinamento dos modelos preditivos de classificação e o gerenciamento do projeto.

4.1 ANÁLISE EXPLORATÓRIA DE DADOS

A análise exploratória dos dados apresentou informações relevantes para este estudo. Em um primeiro momento, foi extraída a matriz de correlação linear entre as variáveis dos indicadores do IDSC e o índice do IDEB. A análise da matriz evidenciou que vários indicadores socioeconômicos, tais como acesso ao esgotamento sanitário, renda, cobertura de água e serviços essenciais, apresentam associação com o índice do IDEB. No entanto, essa análise identifica apenas relações lineares. Portanto, sendo necessário o uso de modelos capazes de identificar relações não lineares.

A Figura **??** apresenta a matriz de correlação linear calculada para os determinantes sociais avaliados em relação ao IDEB. Observa-se que variáveis ligadas à infraestrutura urbana e serviços básicos apresentam coeficientes de correlação moderados, com valores variando entre $-0{,}36$ e $0{,}63$, indicando a presença de tendências socioeconômicas associadas ao desempenho educacional municipal, ainda que com diferentes intensidades e sentidos.

Figura 1 – Matriz de correlação linear entre indicadores do IDSC e o IDEB.

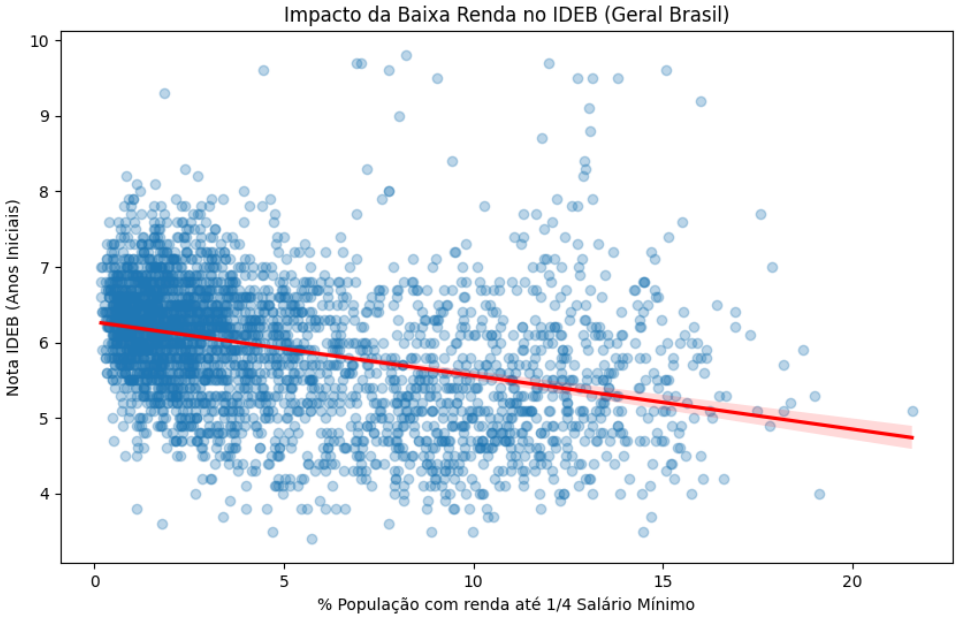


Fonte: A autora, 2026.

Para analisar a distribuição e o comportamento dessas variáveis frente ao desempenho escolar, elaborou-se o gráfico de dispersão apresentado na Figura 2. Conforme observado na

Figura 2, ao lado esquerdo do gráfico, o cenário de menor vulnerabilidade socioeconômica apresenta maior dispersão dos dados. Isso indica que, ao estabilizar a renda e as condições básicas da população, outros fatores passam a exercer maior importância no desempenho do índice de qualidade da educação básica. A linha de tendência central, ajustada por meio de uma regressão linear, busca resumir o comportamento médio dos dados, levando em conta os municípios presentes na base analisada, porém não abrange os municípios que se comportam como *outliers* positivos.

Figura 2 – Gráfico de dispersão entre o indicador de Baixa Renda (eixo x) e o IDEB (eixo) com linha de tendência linear.



Fonte: A autora, 2026.

A Figura 2 apresenta o gráfico de dispersão entre o indicador de proporção de baixa renda, população com rendimento nominal domiciliar per capita de até 1/4 de salário mínimo, e as notas do IDEB. Observa-se uma dispersão ampla dos municípios em âmbito nacional, acompanhada por uma leve tendência de declínio na linha de regressão linear. Esse comportamento sugere que municípios com maiores partes da população em situação de extrema vulnerabilidade econômica tendem a concentrar maiores desafios no desempenho educacional. Contudo, a alta variabilidade e a densidade de pontos evidenciam que fatores socioeconômicos isolados não explicam integralmente os resultados educacionais.

A análise exploratória de dados evidencia o comportamento heterogêneo do conjunto de dados nacional do IDSC, demonstrando a dispersão acentuada entre os municípios brasileiros. Esse comportamento demanda uma estratégia de segmentação do conjunto, motivando a seleção do subconjunto focado nos municípios do estado de Santa Catarina. O aprofundamento das análises exploratórias para o contexto catarinense revela especificidades regionais importantes que contribuem de forma relevante para a compreensão dos fatores associados ao desempenho educacional.

4.2 PRÉ-PROCESSAMENTO DA BASE DE DADOS

Nesta etapa, foram aplicadas técnicas de pré-processamento com o objetivo de estruturar e adequar a base de dados do IDSC-BR para a execução dos algoritmos de aprendizado de máquina. Inicialmente, realizou-se a inspeção do conjunto de dados para a identificação de metadados, colunas descritivas e variáveis categóricas irrelevantes para o processo preditivo. Uma diretriz metodológica adotada foi a remoção preventiva de colunas e índices que pudessem induzir ao vazamento de dados (*data leakage*). Para isso, foram eliminadas variáveis e notas intermediárias que compartilhavam dependência semântica com as notas e faixas do IDEB, assegurando que os modelos de classificação fossem treinados estritamente com base nos indicadores exógenos de desenvolvimento sustentável, sem variáveis que gerassem acurácias artificialmente infladas. Por fim, a base de dados resultante foi convertida e persistida no formato CSV (*Comma-Separated Values*).

4.3 TREINAMENTO DOS MODELOS

A predição do desempenho educacional foi formulada como um problema de classificação multiclasse. Nessa tarefa, os indicadores exógenos do IDSC atuam como atributos preditores, enquanto a variável alvo representa o nível de desafio do município no indicador de educação, derivado diretamente da metodologia do IDSC. Foram consideradas duas variáveis alvo independentes: os anos iniciais e os anos finais do ensino fundamental, cujos modelos foram treinados e avaliados separadamente.

4.3.1 Definição das classes com base no Painel IDSC

A variável alvo adotada neste estudo utiliza a classificação qualitativa do Painel do IDSC-BR inserida no escopo do ODS 4, educação de qualidade. Espelhada na metodologia internacional do *Sustainable Development Report* da Organização das Nações Unidas (2015), essa classificação agrupa o desempenho educacional dos municípios em uma escala de cores que representa a proximidade do cumprimento da meta estipulada para a Agenda 2030.

A categorização reflete os seguintes níveis de desafio:

- **Vermelho:** Desafios maiores. Indica que o município apresenta notas de IDEB baixas ou estagnadas, sendo uma zona de alerta máximo em relação aos objetivos de desenvolvimento sustentável.
- **Laranja:** Desafios significativos. Aponta que o município possui resultados intermediários ou baixos, necessitando de melhorias na qualidade da educação.
- **Amarelo:** Desafios moderados. Representa municípios com desempenho intermediário, próximos da média, mas que ainda precisam evoluir para alcançar o ideal de qualidade.

- **Verde:** Meta atingida. Indica que o município alcançou a pontuação de corte considerada excelente pelo índice, cumprindo plenamente a meta da Agenda 2030 para o indicador.

Dos 295 municípios catarinenses, foram mantidos aqueles com a classificação divulgada para a etapa correspondente, 152 municípios nos anos finais e 273 nos anos iniciais. O critério de remoção de classes com menos de dois exemplos não excluiu nenhuma categoria, mantendo a integridade estrutural das distribuições. A Tabela 2 apresenta a distribuição final das instâncias em cada alvo por categoria de desafio.

Tabela 2 – Distribuição dos municípios catarinenses por faixa de desafio do IDEB (Painel IDSC-BR), após os filtros aplicados.

Etapa	**Faixa de Desafio (Painel)**	**Municípios**	**%**
Anos finais (n = 152)	Vermelho (Desafios maiores)	2	1,3
	Laranja (Desafios significativos)	20	13,2
	Amarelo (Desafios moderados)	62	40,8
	Verde (Meta atingida)	68	44,7
Anos iniciais (n = 273)	Vermelho (Desafios maiores)	0	–
	Laranja (Desafios significativos)	28	10,3
	Amarelo (Desafios moderados)	171	62,6
	Verde (Meta atingida)	74	27,1

4.3.2 Partição dos dados

Os dados foram divididos em 80% para o conjunto de treinamento e 20% para o conjunto de teste, estratificados pela classe e com semente aleatória fixa (*random_state* = 42), garantindo a reprodutibilidade dos resultados. Desse modo, para os anos finais, o conjunto de treinamento ficou composto por 121 municípios e o de teste por 31 municípios; para os anos inicias, utilizou-se 218 municípios no treinamento e 55 no teste. O conjunto de teste foi mantido estritamente isolado durante o ajuste de hiperparâmetros, sendo empregado exclusivamente na avaliação final dos modelos.

4.3.3 Seleção de atributos

Como experimento adicional para comparar o desempenho preditivo, os modelos foram treinados utilizando um subconjunto reduzido de 105 atributos. O processo de filtragem ocorreu em duas etapas. Inicialmente, realizou-se uma análise exploratória da matriz de correlação de Pearson, na qual foram identificados 15 pares de variáveis com correlação absoluta superior a 0,80. Para cada par, descartou-se a variável que apresentava maior correlação média com as demais, reduzindo o conjunto de preditores de 132 para 121 colunas. Na etapa seguinte, foram removidas as variáveis diretamente relacionadas à educação e ao ODS 4, evitando que a resposta

fosse inferida de atributos semanticamente dependentes do alvo, o que resultou nos 105 atributos finais.

Adicionalmente, avaliou-se a aplicação da Análise de Componentes Principais (PCA) sobre os dados padronizados, com imputação prévia pela mediana. Utilizando 15 componentes, obteve-se uma variância explicada acumulada de 51,53%, evidenciando que a informação relevante encontra-se dispersa em múltiplas dimensões que uma projeção de baixa dimensionalidade não conseguiria capturar integralmente. Por esse motivo, a PCA não foi adotada para a eliminação de atributos, mantendo-se o subconjunto obtido pelas etapas de filtragem direta.

Durante o treinamento, o tratamento de valores ausentes seguiu o comportamento nativo de cada algoritmo. O modelo *Random Forest*, que não suporta dados faltantes nativamente. Para suprir essa limitação sem a necessidade de descartar amostras valiosas de municípios, empregou-se a técnica de **imputação iterativa** (*Multivariate Imputation by Chained Equations* - MICE). Por sua vez, os algoritmos *XGBoost*, *LightGBM* e *CatBoost* trataram os valores ausentes de forma nativa em suas estruturas.

A imputação iterativa preenche os valores vazios estimando-os com base nas outras variáveis da base de forma cíclica. No nosso caso, o modelo foi configurado usando o *Extra Trees Regressor* como base. Para evitar qualquer vazamento de dados (*data leakage*), o imputador foi treinado exclusivamente no conjunto de treino (*X_train*) e só depois aplicado no teste (*X_test*). Desse modo, foi mantida a distribuição original dos dados e permitido que o *Random Forest* fosse treinado de forma justa e comparável com os demais algoritmos.

4.3.4 Modelos e ajuste de hiperparâmetros

Este estudo compara quatro algoritmos baseados em árvores de decisão: *Random Forest*, *Extreme Gradient Boosting* (XGBoost), *Light Gradient Boosting Machine* (LightGBM) e *Categorical Boosting* (CatBoost). A escolha se justifica pela adequação a dados tabulares de alta dimensionalidade e pela disponibilidade de medidas intrínsecas de importância de atributos, requisito essencial para a etapa de interpretabilidade.

Os hiperparâmetros foram ajustados por meio de busca aleatória (*RandomizedSearchCV*), metodologia proposta por Bergstra e Bengio (2012), testando 25 combinações sorteadas do espaço de busca de cada algoritmo, conforme apresentado na Tabela 3. Cada combinação foi avaliada por validação cruzada estratificada de três *folds* sobre o conjunto de treino. Como as classes do problema são desbalanceadas, adotou-se o F1-*score* macro como critério de otimização na busca, evitando o viés de métricas orientadas apenas à acurácia global. O modelo que apresentou o melhor desempenho foi retreinado sobre todo o conjunto de treinamento e avaliado no conjunto de teste. Os demais hiperparâmetros foram mantidos nos valores padrão de cada biblioteca, e a semente aleatória foi fixada em 42.

Tabela 3 – Espaços de busca dos hiperparâmetros de cada algoritmo.

Algoritmo	**Hiperparâmetro**	**Valores**
Random Forest	`n_estimators`	100, 200, 300
	`max_depth`	sem limite, 5, 10, 15, 20
	`min_samples_split`	2, 5, 10
	`min_samples_leaf`	1, 2, 4
	`max_features`	`sqrt`, `log2`, todos
XGBoost	`n_estimators`	100, 200, 300, 500
	`max_depth`	3, 5, 7, 9
	`learning_rate`	0,01; 0,05; 0,1; 0,2
	`subsample`	0,6; 0,8; 1,0
	`colsample_bytree`	0,6; 0,8; 1,0
LightGBM	`n_estimators`	100, 200, 300, 500
	`num_leaves`	15, 31, 63, 127
	`learning_rate`	0,01; 0,05; 0,1; 0,2
	`subsample`	0,6; 0,8; 1,0
	`colsample_bytree`	0,6; 0,8; 1,0
CatBoost	`iterations`	200, 400, 600
	`depth`	4, 6, 8, 10
	`learning_rate`	0,01; 0,05; 0,1; 0,2
	`l2_leaf_reg`	1, 3, 5, 7

4.3.5 Métricas de avaliação

O desempenho dos modelos foi avaliado no conjunto de teste por meio de acurácia, precisão, *recall* e F1-*score*. Como as classes apresentam distribuição desbalanceada (Tabela 2), a precisão, o *recall* e o F1-*score* foram calculados utilizando a média macro. Adicionalmente, o F1-*score* macro foi adotado como métrica de referência principal, mitigando o viés da acurácia isolada, que pode ser artificialmente inflada pela predição recorrente da classe majoritária.

4.3.6 Importância dos atributos

A relevância dos atributos foi extraída por meio de medidas de importância intrínsecas aos algoritmos baseados em árvores de decisão. Essas métricas ajudam a identificar quais indicadores do IDSC exercem maior influência no aprendizado preditivo, auxiliando no mapeamento dos fatores associados ao desempenho educacional dos municípios catarinenses. Cada algoritmo emprega uma abordagem específica:

- *Random Forest*: baseia-se na redução média de impureza calculada nos nós da árvore (Breiman, 2001);
- XGBoost e LightGBM: utilizam o ganho médio obtido nos nós em que o atributo é acionado (Chen; Guestrin, 2016; Ke et al., 2017);

- CatBoost: emprega a variação média na predição quando o valor do atributo é alterado, medida de natureza similar ao ganho, porém sem basear-se na impureza (Prokhorenkova et al., 2018).

A análise de importância foi aplicada aos quatro algoritmos, considerando os dois alvos (anos finais e anos iniciais) e os dois conjuntos de dados (todos os atributos e subconjunto com menos atributos). Para cada combinação, utilizando os melhores hiperparâmetros obtidos na busca aleatória, o modelo foi retreinado sobre o conjunto de treinamento utilizando cinco sementes aleatórias distintas. A importância final de cada atributo corresponde à média entre as réplicas, o que atenua a instabilidade decorrente do conjunto de dados reduzido, como os índices dos municípios catarinenses.

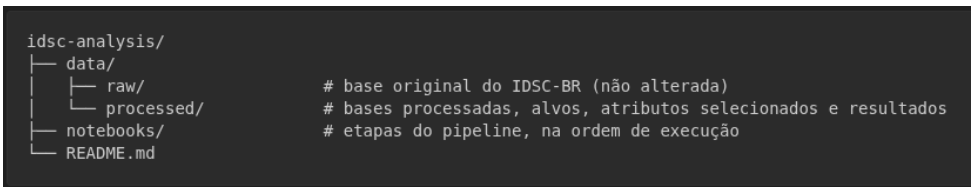
Para consolidar os resultados entre os diferentes modelos, calcularam-se a importância média, o desvio entre os algoritmos, a posição média no ranking e a frequência com que o atributo integrou o grupo dos 20 mais relevantes. Atributos destacados simultaneamente em múltiplos algoritmos foram considerados mais consistentes.

Por fim, as importâncias dos indicadores foram agrupadas por ODS. Os valores que resumem vários indicadores, como escores por objetivo e a pontuação geral do índice, foram mantidos em um grupo separado para evitar a contagem duplicada de uma mesma informação. Ressalta-se que as importâncias obtidas refletem os padrões estatísticos utilizados pelos modelos para a classificação das faixas do IDEB, indicando correlações estruturais e não necessariamente relações diretas de causa e efeito.

4.4 ORGANIZAÇÃO DO PROJETO

A estrutura do projeto foi organizada de forma modular e sequencial, de modo a facilitar a manutenção e a reprodutibilidade dos experimentos. A Figura 3 apresenta uma visão geral da estrutura do projeto.

Figura 3 – Organização do projeto.



Fonte: A autora, 2026.

O diretório `data` armazena os dados em duas etapas. Em `raw` fica o conjunto de dados original do IDSC-BR 2025, mantida sem alterações. Em `processed` ficam os arquivos gerados pelas etapas de preparação: a base processada (`Base_de_Dados_Processada.csv`), os alvos do IDEB mantidos em arquivo separado (`Base_de_Alvos_IDEB.csv`), a lista de atributos selecionados (`features_selecionadas_sc.json`) e os resultados da análise de importância dos atributos.

O diretório `notebooks` concentra o código, organizado em *notebooks* Jupyter que seguem a ordem do fluxo de trabalho: análise exploratória dos dados, limpeza do cojunto de dados, construção dos alvos de classificação, seleção de atributos, predição com todos os atributos, predição com os atributos selecionados e análise da importância dos atributos. Cada *notebook* lê os arquivos produzidos pela etapa anterior, de modo que o encadeamento fica explícito.

Manter os alvos em um arquivo separado da base de atributos evita o vazamento de informação, pois a classificação do Painel nunca faz parte dos dados fornecidos aos modelos. A separação entre os dois experimentos em *notebooks* distintos, com o mesmo procedimento de avaliação, permite compará-los em condições idênticas. Todas as etapas com componente aleatório utilizam semente fixa, o que permite reproduzir os resultados.

O projeto foi desenvolvido em Python, com as bibliotecas *pandas* e *scikit-learn* para a manipulação dos dados e a avaliação, *XGBoost*, *LightGBM* e *CatBoost* para os modelos, e *matplotlib* e *seaborn* para as visualizações. O código está disponível publicamente no GitHub[1], permitindo sua reprodução e exploração por outros pesquisadores.

[1] https://github.com/clarabecker/idsc-analysis

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos na avaliação experimental dos modelos preditivos aplicados à tarefa de classificação do desempenho do Índice de Desenvolvimento da Educação Básica (IDEB) nos municípios do estado de Santa Catarina, para os anos finais e anos iniciais do ensino fundamental. A Seção 5.1 analisa o desempenho quantitativo dos algoritmos no conjunto de dados com todos os atributos. A Seção 5.2 aborda os impactos da etapa de seleção de atributos, formando um subconjunto de dados. Por fim, a Seção 5.3 explora a importância dos atributos, tanto de forma agregada por Objetivos de Desenvolvimento Sustentável (ODS) quanto de forma individual, para identificar quais indicadores mais contribuem para a classificação do IDEB.

5.1 ANÁLISE DE DESEMPENHO DOS MODELOS

Os modelos foram avaliados de forma independente para os anos finais e anos iniciais. As bases têm tamanhos distintos: dos 295 municípios catarinenses, 152 possuem IDEB disponível para anos finais e 273 para anos iniciais. Com a reserva de 20% dos municípios para teste, os conjuntos de teste contêm 31 e 55 municípios, anos finais e iniciais. Esse tamanho deve ser considerado ao interpretar diferenças pequenas entre os modelos. Além disso, as métricas de precisão, *recall* e *F1-score* são reportadas pela média macro, que atribui o mesmo peso a cada faixa de desempenho, independentemente do número de municípios que ela contém. A Tabela 4 apresenta o desempenho dos modelos aplicados ao conjunto de dados com todos os atributos para predição do cenário dos anos finais do ensino fundamental.

Tabela 4 – Métricas de desempenho no conjunto de teste para anos finais com o conjunto de dados completo.

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-score (Macro)**
LightGBM	0,6129	0,4297	0,4652	0,4447
Random Forest	0,6129	0,4389	0,4634	0,4367
CatBoost	0,5806	0,3832	0,4414	0,4087
XGBoost	0,5161	0,3782	0,3901	0,3737

Fonte: A autora, 2026.

Para a tarefa de classificação do índice dos anos finais, o *LightGBM* e o *Random Forest* apresentaram acurácia de 61,29% (19 dos 31 municípios de teste). O *LightGBM* obteve o maior F1-*score* (0,4447) e o maior *recall* (0,4652), enquanto o *Random Forest* teve a maior precisão (0,4389). Entretanto, as diferenças entre os dois são inferiores a 0,01 em todas as métricas, o que, com apenas 31 municípios de teste, não permite apontar um modelo superior: trata-se de um empate. O *CatBoost* (58,06%) também apresenta desempenho competitivo, ao passo que o *XGBoost* apresentou o pior desempenho em todas as métricas, com acurácia de 51,61%. Para

dimensionar esses valores, cabe compará-los a um classificador que sempre prediz a classe majoritária, cuja acurácia equivale à proporção dessa classe na base: 44,7% nos anos finais. Todos os modelos superam esse referencial.

A Tabela 5 apresenta os resultados obtidos no subconjunto de dados com todos os atributos. Nessa variável alvo, a faixa majoritária concentra 62,6% dos municípios.

Tabela 5 – Métricas de desempenho no conjunto de teste para anos iniciais com o conjunto de dados completo.

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-score (Macro)**
Random Forest	0,6545	0,4657	0,3902	0,3641
CatBoost	0,6545	0,4444	0,4275	0,4198
LightGBM	0,6545	0,5581	0,4732	0,4917
XGBoost	0,5818	0,3137	0,3261	0,2802

Fonte: A autora, 2026.

A análise dos resultados dos anos iniciais revela que *Random Forest*, *CatBoost* e *LightGBM* alcançaram a mesma acurácia (65,45%, ou 36 dos 55 municípios de teste), enquanto o *XGBoost* obteve acurácia de 58,18%. Desse modo, a comparação entre os modelos depende do exame das métricas macro. O *LightGBM* manteve o lugar de destaque, obtendo o maior F1-*score* (0,4917) e o maior *recall* (0,4732), seguido pelo *CatBoost* (0,4198) e pelo *Random Forest* (0,3641). Por sua vez, o *XGBoost* apresentou o menor desempenho em todas as métricas macro (F1-*score* de 0,2802 e *recall* de 0,3261), o que evidencia uma forte tendência a classificar apenas as faixas majoritárias em detrimento das classes com menor representatividade de municípios.

5.2 IMPACTO DA SELEÇÃO DE ATRIBUTOS

Com o intuito de verificar se a remoção de redundâncias melhora a capacidade preditiva dos modelos, analisou-se o comportamento dos algoritmos em um subconjunto de dados com atributos selecionados, que reduz a base de 132 para 105 atributos. A Tabela 6 apresenta os resultados para tarefa preditiva da classificação do IDEB nos anos finais.

Na análise dos resultados da variável alvo dos anos finais com o subconjunto de atributos selecionados, o *LightGBM* e o *Random Forest* alcançaram a maior acurácia (64,52%), enquanto o *XGBoost* e o *CatBoost* atingiram 61,29% . Em relação à base completa, a seleção de atributos proporcionou um leve ganho de acurácia para a maioria dos algoritmos (o *LightGBM* e o *Random Forest* subiram de 61,29% para 64,52%, e o *XGBoost* de 51,61% para 61,29%), ao passo que o *CatBoost* manteve o desempenho em 61,29%.

Contudo, a avaliação das métricas macro revela comportamentos divergentes entre os modelos. O *LightGBM* destacou-se amplamente dos demais, apresentando evolução em todas as métricas macro no subconjunto parcial: o F1-*score* subiu de 0,4447 para 0,4590, a precisão macro

Tabela 6 – Métricas de desempenho no conjunto de teste para anos finais com subconjunto de dados com 105 atributos.

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-score (Macro)**
LightGBM	0,6452	0,5625	0,4424	0,4590
Random Forest	0,6452	0,3205	0,3818	0,3485
XGBoost	0,6129	0,3147	0,3652	0,3374
CatBoost	0,6129	0,3037	0,3591	0,3286

Fonte: A autora, 2026.

de 0,4297 para 0,5625 e o *recall* macro permaneceu competitivo em 0,4424. Em contrapartida, para o *Random Forest*, *XGBoost* e *CatBoost*, a redução de atributos resultou em queda acentuada nas métricas macro, com reduções significativas no F1-*score* (atingindo 0,3485, 0,3374 e 0,3286, respectivamente). Esse cenário indica que, com exceção do *LightGBM*, a eliminação de atributos nesses algoritmos acentuou a tendência de predição em favor das classes majoritárias, prejudicando a delimitação das faixas de desempenho educacional menos frequentes.

A Tabela 7 apresenta os resultados para tarefa preditiva da classificação do IDEB nos anos iniciais.

Tabela 7 – Métricas de desempenho no conjunto de teste para anos iniciais com subconjunto de dados com 105 atributos.

Modelo	**Acurácia**	**Precisão (Macro)**	**Recall (Macro)**	**F1-score (Macro)**
XGBoost	0,7636	0,8444	0,5499	0,5872
Random Forest	0,6909	0,4535	0,4174	0,4070
LightGBM	0,6909	0,6120	0,4801	0,5054
CatBoost	0,6727	0,4267	0,3917	0,3747

Fonte: A autora, 2026.

O modelo preditivo *XGBoost* obteve a maior acurácia (76,36%) e o melhor F1-*score* (0,5872). O *Random Forest* e o *LightGBM* alcançaram a mesma acurácia de 69,09%, com F1-*score* de 0,4070 e 0,5054, respectivamente. Por fim, o *CatBoost* apresentou acurácia de 67,27% e F1-*score* de 0,3747.

Em uma análise geral, a seleção de atributos produziu melhora consistente para o *XGBoost*, que saltou expressivamente em desempenho. Em relação ao conjunto de dados com todos os atributos, a acurácia aumentou em múltiplos modelos dos anos iniciais, embora as variações nas métricas macro tenham refletido dinâmicas distintas entre as classes.

Quanto à escolha entre os algoritmos, o *LightGBM* e o *XGBoost* se destacaram pelo F1-*score* e pela acurácia nos cenários parciais, enquanto *Random Forest* e *CatBoost* tiveram desempenho mais moderado. Isso demonstra que a escolha entre eles depende da métrica a ser priorizada.

5.3 ANÁLISE DA IMPORTÂNCIA DOS ATRIBUTOS

A importância dos atributos foi calculada de forma intrínseca pelos modelos baseados em árvores: redução média de impureza (Gini) no *Random Forest*, ganho (*gain*) no *XGBoost* e no *LightGBM*, e mudança no valor de predição no *CatBoost*. Como o conjunto de indicadores do IDSC de Santa Catarina possui poucos municípios e muitos atributos, o que torna a importância instável, cada modelo foi retreinado com cinco sementes aleatórias, em cinco réplicas do experimento. A importância de cada atributo foi normalizada (soma igual a 1 em cada modelo) e calculada pela média das sementes. O valor final é a média entre os quatro algoritmos, e a análise considera os indicadores tanto de forma individual quanto agregada por ODS. Os escores sintéticos do índice (*Goal N Score* e Pontuação Índice ODS 2025) formam um grupo próprio, denominado escores agregados, para que os indicadores que eles resumem não sejam contados duas vezes.

5.3.1 Importância agregada por ODS na base completa

Ao considerar todo o conjunto de dados, os mesmos três grupos se destacam nas duas etapas, ainda que em ordens distintas. Nos anos finais, o ODS 3 (saúde e bem-estar) concentra a maior importância (25,80%), seguido pelo ODS 4 (educação de qualidade), com 15,96%, e pelos escores agregados, com 12,32%. Nos anos iniciais, o ODS 4 assume a primeira posição de destaque (21,44%), seguido pelos escores agregados (18,85%) e pelo ODS 3 (13,96%). Em ambos os casos, os três grupos somam pouco mais da metade da importância total (54,08% nos anos finais e 54,25% nos anos iniciais), e nenhum dos demais ultrapassa 9%.

Observa-se que, ao classificar o índice educacional, o ODS 4 não seja o grupo mais importante nos anos finais; a variável de maior importância, o ODS 3, não se destaca apenas pela quantidade: quatro dos dez indicadores de maior importância média nos anos finais pertencem a ele, contra apenas um do ODS 4. Além disso, indicadores de saúde, nutrição e gênero podem funcionar como representantes indiretos das condições socioeconômicas dos municípios, que se associam ao desempenho escolar. Esses fatores não implicam que a saúde cause melhor desempenho educacional: a importância indica o quanto o modelo utiliza o atributo para separar as classes, e não uma relação causal.

5.3.2 Efeito da seleção de atributos sobre a importância

A Tabela 8 e a Tabela 9 comparam a importância agregada por ODS no conjunto de dados e no subconjunto com atributos selecionados, para os anos finais e anos iniciais, respectivamente. O resultado mais evidente é o desaparecimento do ODS 4 nas duas etapas: no subconjunto, nenhum indicador desse ODS permaneceu após a seleção de atributos. Esse desaparecimento não significa que a educação deixou de ser relevante, mas que seus indicadores foram retirados da base na etapa anterior, como descrito anteriormente. Além disso, como a importância é relativa e resulta em uma soma de 100% em cada modelo, a ausência do ODS 4 liberou 15,96% para

os anos finais e 21,44% para os anos iniciais de importância, que foram redistribuídos entre os demais grupos.

Tabela 8 – Importância agregada por ODS no conjunto e subconjunto com 105 atributos para os anos finais.

Base Completa		**Base Parcial (105 Atributos)**	
Grupo / ODS	**Importância (%)**	**Grupo / ODS**	**Importância (%)**
ODS 3 (Saúde e Bem-Estar)	25,80	ODS 3 (Saúde e Bem-Estar)	32,22
ODS 4 (Educação de Qualidade)	15,96	Escores Agregados	13,25
Escores Agregados	12,32	ODS 2 (Fome Zero e Agr. Sust.)	6,96
ODS 5 (Igualdade de Gênero)	5,99	ODS 5 (Igualdade de Gênero)	6,55
ODS 10 (Red. das Desigualdades)	4,63	ODS 10 (Red. das Desigualdades)	5,72
ODS 2 (Fome Zero e Agr. Sust.)	8,17	ODS 13 (Ação Clima)	5,40

Nota: Valores em % da importância total.
Fonte: A autora, 2026.

Tabela 9 – Importância agregada por ODS no conjunto e subconjunto com 105 atributos para os anos iniciais.

Base Completa		**Base Parcial (105 Atributos)**	
Grupo / ODS	**Importância (%)**	**Grupo / ODS**	**Importância (%)**
ODS 4 (Educação de Qualidade)	21,44	Escores Agregados	23,74
Escores Agregados	18,85	ODS 3 (Saúde e Bem-Estar)	17,97
ODS 3 (Saúde e Bem-Estar)	13,96	ODS 8 (Trabalho Decente e Cresc.)	8,20
ODS 8 (Trabalho Decente e Cresc.)	7,91	ODS 2 (Fome Zero e Agr. Sust.)	6,81
ODS 5 (Igualdade de Gênero)	6,89	ODS 11 (Cidades Sustentáveis)	6,73
ODS 2 (Fome Zero e Agr. Sust.)	4,66	ODS 10 (Red. das Desigualdades)	5,09

Nota: Valores em % da importância total.
Fonte: A autora, 2026.

6 CONSIDERAÇÕES FINAIS

Este trabalho investiga em que medida os indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC) permitem classificar as faixas de desempenho do Índice de Desenvolvimento da Educação Básica (IDEB) dos municípios de Santa Catarina, e quais desses indicadores mais influenciam os modelos preditivos. Para isso, o IDEB dos anos iniciais e anos finais do ensino fundamental foi segmentado em faixas a partir da nota bruta, e quatro algoritmos baseados em árvores de decisão (*Random Forest*, *XGBoost*, *LightGBM* e *CatBoost*) foram treinados e comparados em dois experimentos: o primeiro com 132 atributos do conjunto de dados, o segundo considera um subconjunto de 105 atributos, obtido por filtragem de correlação e remoção dos indicadores do ODS 4, relacionados à educação. A importância dos atributos foi extraída pelas medidas intrínsecas de cada algoritmo, normalizadas, calculadas entre diferentes replicações e associadas aos Objetivos de Desenvolvimento Sustentável (ODS).

Os resultados permitem atender aos objetivos propostos. A revisão da literatura sustentou a escolha de modelos de árvores e de métricas de interpretabilidade. A análise exploratória demonstra a complexa diversidade da base nacional e justifica o recorte em Santa Catarina. A seleção de atributos reduziu o conjunto de 132 para 105 colunas, e a comparação entre os dois experimentos mostrou que essa redução não produziu melhora consistente no desempenho, dentro da análise permitida pelo tamanho do conjunto de teste. Os modelos de classificação foram aplicados e avaliados nas duas variáveis alvo e as métricas de importância evidenciaram os indicadores mais relevantes. Portanto, considera-se atingido o objetivo geral de analisar o desempenho de modelos de classificação baseados em árvores de decisão na predição das faixas do IDEB e de identificar, por suas métricas estruturais, os indicadores sustentáveis associados a essa classificação. A principal contribuição do trabalho é a análise do IDEB a partir de dados externos ao ambiente escolar, restrita a um estado e acompanhada de interpretabilidade, com um procedimento reprodutível.

Quanto ao desempenho preditivo, os algoritmos de *gradient boosting* (*LightGBM*, *XGBoost* e *CatBoost*) apresentaram resultados semelhantes ao *Random Forest*. A etapa de seleção de atributos elevou a acurácia nos anos finais, mas reduziu o F1-*score* macro na maior parte dos modelos, e nos anos iniciais seu efeito dependeu do algoritmo. Contudo, como a diferença de acertos entre os algoritmos equivale a poucos municípios no conjunto de teste, não é possível afirmar a superioridade absoluta de um modelo sobre os demais. Na análise de importância, os indicadores de saúde pública (ODS 3) destacaram-se como os mais influentes nos anos finais, enquanto nos anos iniciais, na base completa, a relevância esteve concentrada nos indicadores educacionais (ODS 4) e nos escores agregados do índice. Esses achados reforçam que a qualidade educacional municipal está associada a fatores socioeconômicos externos ao ambiente escolar, fornecendo direcionamentos úteis para a gestão pública. Cabe ressaltar que os resultados indicam associação entre as variáveis, e não uma relação direta de causa e efeito.

Algumas limitações metodológicas devem ser consideradas, como o número reduzido de

municípios analisados, que torna o conjunto de dados pequeno e deixa o modelo mais sensível a erros pontuais. Além disso, os testes foram realizados com uma única divisão dos dados, sem validações repetidas. Adicionalmente, a baixa quantidade de cidades com notas extremas (muito altas ou muito baixas) também dificulta uma avaliação mais estável nessas faixas. Outro ponto é que alguns índices gerais podem apresentar informações parecidas com a nota avaliada, e variáveis semelhantes acabam dividindo a importância entre si, dificultando isolar o impacto de cada indicador. Por fim, os resultados refletem apenas a realidade de Santa Catarina e não devem ser generalizados para outros estados.

Como trabalho futuro, sugere-se inicialmente repetir a avaliação com validação cruzada repetida ou múltiplas partições, de modo a obter intervalos de confiança e comparações estatisticamente mais robustas. Além disso, sugere-se métricas intrínsecas com outras técnicas de interpretabilidade, como a importância por permutação e o TreeSHAP, que também indica a direção do efeito de cada indicador. Ainda há a possibilidade de tratar as faixas do IDEB como categorias ordenadas, por meio de classificação ordinal ou regressão, em vez de classes independentes, além de incluir agrupamentos de municípios em perfis, a fim de verificar se modelos específicos por perfil melhoram a predição. Este trabalho também possui a possibilidade de estender a análise a outros estados ou a outros anos do IDEB, bem como incorporar dados escolares do INEP, de modo a comparar a contribuição de fatores internos e externos à escola.

REFERÊNCIAS

BARROS, Abílio Nogueira; ALVES, Gabriel; MELLO, Rafael Ferreira. Entendendo os fatores de previsão do TDI nas escolas públicas brasileiras: Uma abordagem usando a técnica SHAP. In: **Anais do XXXV Simpósio Brasileiro de Informática na Educação (SBIE)**. Porto Alegre, RS: Sociedade Brasileira de Computação, 2024. p. 1529–1542. Disponível em: https://sol.sbc.org.br/index.php/sbie/article/view/31339. Citado 2 vezes nas páginas 24 e 25.

BERGSTRA, James; BENGIO, Yoshua. Random search for hyper-parameter optimization. **Journal of Machine Learning Research**, v. 13, n. Feb, p. 281–305, 2012. Citado na página 30.

BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006. Citado na página 20.

BREIMAN, Leo. Random forests. **Machine Learning**, Springer, v. 45, n. 1, p. 5–32, 2001. Citado 2 vezes nas páginas 21 e 31.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco, California: ACM, 2016. p. 785–794. Citado 2 vezes nas páginas 22 e 31.

FEITOSA, T. C. Aplicações de aprendizagem de máquina com dados do INEP: Uma revisão de literatura. In: **Anais do XXIV Congresso Brasileiro de Informática na Educação (CBIE)**. Porto Alegre, RS: Sociedade Brasileira de Computação (SBC), 2025. p. 120–131. Disponível em: https://sol.sbc.org.br/index.php/ctrle/article/view/40463. Citado na página 24.

FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, JSTOR, v. 29, n. 5, p. 1189–1232, 2001. Citado 2 vezes nas páginas 21 e 22.

HOTELLING, Harold. Analysis of a complex of statistical variables into principal components. **Journal of Educational Psychology**, Warwick & York, v. 24, n. 6, p. 417–441, 1933. Citado na página 21.

Instituto Cidades Sustentáveis. **Índice de Desenvolvimento Sustentável das Cidades - Brasil (IDSC-BR)**. 2023. Disponível em: https://idsc.cidadessustentaveis.org.br/. Acesso em: 2 nov. 2026. Citado 2 vezes nas páginas 15 e 18.

Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Índice de Desenvolvimento da Educação Básica (IDEB)**. 2024. Disponível em: https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/ideb. Acesso em: 2 nov. 2026. Citado 2 vezes nas páginas 15 e 18.

KE, Guolin et al. Lightgbm: A highly efficient gradient boosting decision tree. In: **Advances in Neural Information Processing Systems 30 (NIPS 2017)**. Red Hook, NY: Curran Associates, Inc., 2017. p. 3146–3154. Citado 2 vezes nas páginas 22 e 31.

MITCHELL, Tom M. **Machine Learning**. New York: McGraw-Hill, 1997. Citado na página 20.

MURPHY, Kevin P. **Machine Learning: A Probabilistic Perspective**. Cambridge: MIT Press, 2012. Citado na página 20.

Organização das Nações Unidas. **Transformando Nosso Mundo: A Agenda 2030 para o Desenvolvimento Sustentável**. 2015. Disponível em: https://brasil.un.org/sites/default/files/2020-09/agenda2030-pt-br.pdf. Acesso em: 2 nov. 2026. Citado 3 vezes nas páginas 15, 18 e 28.

PEARSON, Karl. On lines and planes of closest fit to systems of points in space. **The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science**, Taylor & Francis, v. 2, n. 11, p. 559–572, 1901. Citado na página 21.

PINTO, Glevson da Silva. **Modelo de análise e predição para identificação dos fatores que influenciam o desempenho escolar na rede de ensino básico: estudo de caso em escolas municipais de Alagoas**. Dissertação (Mestrado) — Universidade Federal de Alagoas (UFAL), Maceió, AL, 2021. Disponível em: https://www.repositorio.ufal.br/handle/riufal/7782. Citado na página 24.

PROKHORENKOVA, Liudmila et al. Catboost: unbiased boosting with categorical features. In: **Advances in Neural Information Processing Systems 31 (NeurIPS 2018)**. Red Hook, NY: Curran Associates, Inc., 2018. p. 6639–6649. Citado 2 vezes nas páginas 22 e 32.

SOARES, Raimundo de Castro; NETO, Nelson Weber; COUTINHO, Luciano Reis. Minerando dados para entender os fatores de influência da qualidade educacional do maranhão. **Revista Brasileira de Informática na Educação (RBIE)**, v. 28, p. 854–878, 2020. Disponível em: https://journals-sol.sbc.org.br/index.php/rbie/article/view/2831. Citado na página 24.

6.1 USO DE FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

Etapa	**Ferramenta e versão**	**Data**	**Objetivo**	**Revisão aplicada**	**Prompts**
Figura 4	Claude (Anthropic), Sonnet 5.5	26/10/2026	Código TikZ do gráfico	Teste, ajuste e verificação dos valores da figura	Apêndice B
Revisão geral do texto	Claude (Anthropic), Sonnet 5.5	26/10/2026	Identificação de inconsistências entre capítulos	Originalidade do texto escrito pela autora, sem alterações	Apêndice B
Notebook de importância	Claude (Anthropic), Sonnet 5.5	26/10/2026	Revisão do código quanto a risco de vazamento de dados	Resultados iguais aos iniciais com código implementado	Apêndice B

Tabela 10 – Uso de ferramentas de inteligência artificial.

Fonte: A autora, 2026.

6.2 PROMPTS UTILIZADOS

Nº	Etapa	Data	Prompt (texto original)	Resposta da ferramenta
1	Figura 4	26/10/2026	“A figura ficou bugada na página” [anexo: captura de tela]	Explicação da causa (posicionamento do *float*) e sugestão de ajuste.
2	Figura 4	26/10/2026	“Não posso usar o float vai bugar tudo” [anexo: preâmbulo LaTeX]	Correção sem o pacote *float*, usando `[!htbp]` e ajustes de parâmetros.
3	Figura 4	26/10/2026	“Ficou meio feia, não tem como deixar mais bonito?” [anexo: captura de tela]	Nova versão do gráfico (destaque, porcentagens, grade).
4	Revisão geral	26/10/2026	“Meu tcc ficou bom?” [anexo: PDF do TCC]	Avaliação geral, lista de inconsistências e erros de texto.
5	Notebook de importância	26/10/2026	“Possível vazamento nos “Escores agregados”. Eles aparecem entre os mais importantes. Confira se a pontuação geral do IDSC e a do ODS 4, que embutem o IDEB, foram removidas na base parcial. [anexo: notebook `07_feature_importance.ipynb`]	Análise do notebook: risco de vazamento pelos escores agregados e inconsistência quanto ao balanceamento.

Tabela 11 – Prompts enviados à ferramenta de IA e resumo das respostas.

Fonte: A autora, 2026.