UNIVERSIDADE DO ESTADO DE SANTA CATARINA – UDESC
NOME DO CENTRO – CEAVI
PROGRAMA DE GRADUAÇÃO – ESO

CLARA DOS SANTOS BECKER

PREDIÇÃO DO ÍNDICE DO IDEB COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

IBIRAMA
2026

CLARA DOS SANTOS BECKER

PREDIÇÃO DO ÍNDICE DO IDEB COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

Trabalho de conclusão apresentado ao curso de Engenharia de Software do Centro de Educação Superior do Alto Vale do Itajaí (CEAVI), da Universidade do Estado de Santa Catarina (UDESC), como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Software.

Orientador: Prof. Dr. Marcelo de Souza

IBIRAMA
2026

Para gerar a ficha catalográfica de teses e
dissertações acessar o link:
https://www.udesc.br/bu/manuais/ficha

dos Santos Becker, Clara
Predição do índice do IDEB com modelos de aprendizado de máquina explicáveis e Indicadores de Desenvolvimento Sustentável / Clara dos Santos Becker. – Ibirama, 2026.
35 p. : il.

Orientador: Prof. Dr. Marcelo de Souza.
Trabalho de Conclusão de Curso – Universidade do Estado de Santa Catarina, Centro de Educação Superior do Alto Vale do Itajaí, Programa de Graduação em Engenharia de Software, Ibirama, 2026.

1. Palavra-chave. 2. Palavra-chave. 3. Palavra-chave. 4. Palavra-chave. 5. Palavra-chave. I. de Souza, Marcelo. II. Universidade do Estado de Santa Catarina, Centro de Educação Superior do Alto Vale do Itajaí, Programa de Graduação em Engenharia de Software. III. Predição do índice do IDEB com modelos de aprendizado de máquina explicáveis e Indicadores de Desenvolvimento Sustentável.

ERRATA

Elemento opcional.

Exemplo:

Sobrenome, Prenome do Autor. Título de obra: subtítulo (se houver). Ano de depósito. Tipo do trabalho (grau e curso) - Vinculação acadêmica, local de apresentação/defesa, data.

Folha	**Linha**	**Onde se lê**	**Leia-se**
1	10	auto-conclavo	autoconclavo

CLARA DOS SANTOS BECKER

PREDIÇÃO DO ÍNDICE DO IDEB COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

Trabalho de conclusão apresentado ao curso de Engenharia de Software do Centro de Educação Superior do Alto Vale do Itajaí da Universidade do Estado de Santa Catarina, como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Software Orientador: Prof. Dr. Marcelo de Souza

BANCA EXAMINADORA:

Prof°. Marcelo de Souza Dr.
Universidade do Estado de Santa Catarina

Membros:

Nome do Orientador e Titulação.
Nome da Instituição

Nome do Orientador e Titulação
Nome da Instituição

Nome do Orientador e Titulação
Nome da Instituição

Joinville, 01 de maio de 2026

Dedico aos meus pais por sempre serem meu maior exemplo de dignidade, força e resiliência. Especialmente à minha mãe, que me ensinou a conquistar a liberdade feminina através dos estudos.

AGRADECIMENTOS

Agradeço primeiramente aos meus pais, Hertz Becker e Rejane Clezar, por sempre me incentivarem e me apoiarem ao longo de toda a minha trajetória pessoal e acadêmica. Sou grata também pelo apoio da minha irmã, Gabriela, por sempre me ouvir quando as coisas pesaram, espero um dia ser uma inspiração para ela. Minha conquista acadêmica não é apenas minha, mas de toda a minha família, que sempre fez o que estava ao seu alcance e além, para me dar oportunidades.

Agradeço também ao meu orientador, Prof. Dr. Marcelo de Souza, pela orientação ao longo dos anos, pela colaboração em vários projetos de pesquisa e por aceitar conduzir este trabalho de conclusão de curso. Meu agradecimento também por mostrar que a pesquisa é um caminho a se seguir e por ser um verdadeiro exemplo de pesquisador.

Sou grata aos meus amigos Thaiane Bento, Erick Warmling, Lucas Gitirana, Thassyana Alves e Marco Possamai que se tornaram uma segunda família em Ibirama, especialmente ao meu mais querido amigo e colega Lucas Falcade, minha dupla de faculdade. Nosso apoio mútuo durante toda a jornada acadêmica fez toda a diferença. Agradeço também aos meus amigos felinos de quatro patas, Jade e Vesguinho, que me acompanharam em todos os momentos, sempre à procura de carinho.

Agradeço também aos outros pilares da minha vida Luz Bopsin, minha melhor amiga a 13 anos que me viu por todas as fases e transformações e sempre decidiu estar ao meu lado. Agradeço por fim ao meu namorado Matheus Oliver por me acompanhar na jornada do desenvolvimento desse trabalho e por sempre acreditar no meu potêncial.

Como disse Taylor Swift: "Nenhum de nós fez isso sozinho. Cada um de nós é uma colcha de retalhos daqueles que nos amaram, daqueles que acreditaram em nosso futuro, daqueles que nos mostraram empatia e bondade ou nos disseram a verdade mesmo quando não era fácil de ouvir". A todos os que foram minha colcha de retalhos nesta jornada, meu muito obrigada.

“Que ninguém se engane: a liberdade é
conquistada a duras penas, mas é o único chão
onde vale a pena pisar.” (Lispector, Clarice)

RESUMO

Elemento obrigatório que contém a apresentação concisa dos pontos relevantes do trabalho, fornecendo uma visão rápida e clara do conteúdo e das conclusões do mesmo. A apresentação e a redação do resumo devem seguir os requisitos estipulados pela NBR 6028 (ABNT, 2003). Deve descrever de forma clara e sintética a natureza do trabalho, o objetivo, o método, os resultados e as conclusões, visando fornecer elementos para o leitor decidir sobre a consulta do trabalho no todo.

Palavras-chave: Palavra 1. Palavra 2. Palavra 3. Palavra 4. Palavra 5.

ABSTRACT

Elemento obrigatório para todos os trabalhos de conclusão de curso. Opcional para os demais trabalhos acadêmicos, inclusive para artigo científico. Constitui a versão do resumo em português para um idioma de divulgação internacional. Deve aparecer em página distinta e seguindo a mesma formatação do resumo em português.

Keywords: Keyword 1. Keyword 2. Keyword 3. Keyword 4. Keyword 5.

LISTA DE ILUSTRAÇÕES

Figura 1 – Matriz de correlação linear entre indicadores do IDSC e o IDEB. 27
Figura 2 – Gráfico de dispersão entre o indicador de Baixa Renda (eixo x) e o IDEB (eixo) com linha de tendência linear. 28

LISTA DE TABELAS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
BU	Biblioteca Universitária
IN	Instrução Normativa
NBR	Normas Técnicas Brasileiras
TCC	Trabalho de Conclusão de Curso
Udesc	Universidade do Estado de Santa Catarina
IDSC	Índice de Desenvolvimento Sustentável das Cidades
ONU	Organização das Nações Unidas
IDEB	Índice de Desenvolvimento da Educação Básica
ODS	Objetivos de Desenvolvimento Sustentável
XAI	Inteligência Artificial Explicável

LISTA DE SÍMBOLOS

@	Arroba
%	Porcento
°C	Graus Celsius
Ca	Cálcio

SUMÁRIO

1	**INTRODUÇÃO**	**15**
1.1	PROBLEMA	**16**
1.2	OBJETIVOS	**16**
1.3	JUSTIFICATIVA	**17**
1.4	METODOLOGIA	**18**
2	**FUNDAMENTAÇÃO TEÓRICA**	**19**
2.1	APRENDIZADO DE MÁQUINA	**19**
2.1.1	**Paradigmas de Aprendizado de Máquina**	**19**
2.1.2	**Técnicas de Agrupamento (*Clustering*)**	**19**
2.1.3	**K-Means**	**20**
2.1.4	**Agrupamento Hierárquico**	**20**
2.1.5	**Agrupamento Espacial Baseado em Densidade para Aplicações com Ruído (DBSCAN)**	**20**
2.2	MODELOS DE REGRESSÃO E PREDIÇÃO	**21**
2.2.1	**Regressão Linear**	**21**
2.2.2	**Random Forest**	**22**
2.2.3	**Gradient Boosting**	**22**
2.2.4	**Métricas de Avaliação de Modelos de Regressão**	**23**
2.2.5	**Métricas Nativas de Importância Baseadas em Árvores**	**23**
2.2.6	**Valores SHAP (*Shapley Additive Explanations*)**	**24**
2.3	TRABALHOS CORRELATOS	**24**
3	**PREDIÇÃO DO IDEB MUNICIPAL COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL**	**26**
3.0.1	**Análise Exploratória de Dados (EDA)**	**26**
4	**CONCLUSÃO**	**29**
	REFERÊNCIAS	**30**
	GLOSSÁRIO	**32**
	APÊNDICE A – TÍTULO	**33**
	ANEXO A – TÍTULO	**34**
	ÍNDICE	**35**

1 INTRODUÇÃO

O plano global criado pela ONU, denominado Agenda 2030, propõe uma ação conjunta que visa o desenvolvimento sustentável e a erradicação da pobreza em todas as suas formas. Segundo (Unidas, 2015), a ação proposta pela Agenda 2030 estabelece 17 objetivos e 169 metas que abrangem as cinco grandes áreas: pessoas, planeta, prosperidade, paz e parceria. As cinco áreas abrangem objetivos para garantir condições dignas de vida às pessoas, possibilitando acesso à educação, saúde e igualdade. Conservação do meio ambiente, com o objetivo de combater a degradação ambiental e promover uso sustentável de recursos ambientais, possibilitando um desenvolvimento e prosperidade da sociedade de forma equilibrada, visando também estabelecer a paz e a justiça social.

O Brasil possui o Índice de Desenvolvimento Sustentável das Cidades (IDSC) (Sustentáveis, 2023), 100 indicadores coletados que apresentam métricas de cada uma das cidades com relação ao cumprimento dos 17 objetivos de desenvolvimento sustentável (ODS) definidos na Agenda. Esses indicadores oferecem uma visão do desenvolvimento dos municípios de forma multidimensional, compreendendo esferas sociais, ambientais e institucionais. Um dos indicadores pertencentes ao IDSC é o Índice de Desenvolvimento da Educação Básica (IDEB), responsável por avaliar a qualidade da educação básica. De acordo com (Teixeira, 2024), o indicador, calculado a partir de dados, abrange dois aspectos fundamentais: o fluxo escolar e as médias de desempenho nas avaliações.

Avanços tecnológicos, como Modelos de Aprendizado de Máquina, fornecem técnicas de aprendizado supervisionado para a predição de avaliadores como o IDEB. A predição desse valor é realizada exclusivamente com base nos dados do IDSC, diferente da realização do cálculo baseado em notas e taxas de aprovação. Sendo assim, leva em conta a realidade do aluno com base em fatores externos à sala de aula. A abordagem aplicada fornece uma predição do valor que se baseia em aspectos sociais, econômicos e ambientais do município dos alunos. A abordagem é válida para gestão pública educacional, apresentando o valor do IDEB integrado a fatores da realidade dos alunos fora do ambiente escolar.

A predição do valor de avaliação do desempenho educacional ainda é aplicada em conjunto com modelos de aprendizado não supervisionados, que são responsáveis por agrupar o conjunto de dados com base em características. Dessa forma, os dados do IDSC podem ser agrupados com relação à um conjunto predefinido de variáveis. O agrupamento do conjunto de dados se mostra uma tecnologia essencial nesse cenário, visto que o conjunto de dados do IDSC, em sua totalidade, abrange 5.570 municípios de diferentes perfis de cidades brasileiras. Os indicadores de desenvolvimento sustentável podem apresentar relações distintas com o índice do IDEB, dependendo das características do município.

Além da segmentação do conjunto de dados para a modelagem do indicador de avaliação do IDEB, se faz necessária a interpretabilidade do resultado da predição. Para a resolução desse aspecto, serão aplicadas métricas de relevância dos atributos nos modelos baseados em árvores

de decisão, o que permite extrair de forma direta quais os indicadores da base de dados do IDSC que possuem maior influência no índice educacional. Embora a análise desses fatores seja baseada principalmente nas métricas extraídas dos modelos, ainda é utilizada Inteligência Artificial Explicável (XAI) como forma de comparação entre ambas as ferramentas destinadas à interpretabilidade do modelo. Diante do cenário apresentado, o entendimento dos aspectos que têm maior peso na variação do índice do IDEB auxiliam à tomada de decisão no poder público, visando à melhoria do sistema educacional. A tarefa de identificação dos fatores de desenvolvimento sustentável do município que influenciam diretamente a qualidade da educação básica pode levar à implementação de políticas públicas com objetivos diretos na educação.

1.1 PROBLEMA

O conjunto de dados IDSC, que abrange todos os indicadores de cumprimento dos objetivos definidos na Agenda 2030, apresenta diversas características com relação ao desenvolvimento sustentável do município que ainda não foram analisadas e exploradas sob a ótica da ciência de dados sobretudo de forma aprofundada por meio da construção de modelos capazes de realizar a predição do indicador do IDEB.

O conjunto abrange informações sobre todos os municípios brasileiros, mas as características de cada localidade podem ter diferentes níveis de associação com o IDEB, não apresentando uma relação determinante com o indicador de avaliação em todos os municípios de forma igualitária.

O indicador do IDEB geralmente é visto como uma métrica isolada apenas no âmbito da educação, sem levar em conta aspectos do desenvolvimento do município, como saúde ou saneamento básico. Aspectos esses que estão disponíveis no conjunto de indicadores IDSC e ainda não foram explorados com esse objetivo. Os modelos preditivos podem ser aplicados e, com base no treinamento, predizer a nota do IDEB. Porém, para uma tomada de decisão com relação à melhoria do sistema educacional, se faz necessária a compreensão dos fatores que influenciam o resultado da predição, por isso a proposta visa à aplicabilidade de técnicas de interpretabilidade dos modelos empregados.

1.2 OBJETIVOS

Este trabalho se propõe à exploração e análise da base de dados dos indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC), aplicando modelos de aprendizado de máquina com o objetivo de realizar o agrupamento com base em características selecionadas do município e predição do Índice de Desenvolvimento da Educação Básica (IDEB).

Adicionalmente, busca-se analisar as métricas de relevância de atributos inerentes aos modelos preditivos para interpretar os fatores que mais influenciam os resultados. O objetivo geral deste trabalho é analisar o desempenho de modelos de regressão baseados em Árvores de Decisão, comparando sua aplicação na base de dados completa e em conjuntos agrupados por

características dos município, utilizando suas métricas estruturais de importância de atributos para identificar os indicadores sustentáveis de maior impacto na educação básica.

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

Realizar uma revisão da literatura sobre modelos de aprendizado de máquina supervisionado e não supervisionado, com ênfase em modelos baseados em árvores de decisão e métricas de interpretabilidade de atributos; Aplicar técnicas para exploração e análise inicial da base de dados do IDSC; Aplicar técnicas de modelo de aprendizado não supervisionado para agrupamento do conjunto de dados com base no perfil socioeconômico e sustentável do município; Aplicar técnicas de modelo de aprendizado de máquina de regressão baseados em árvores de decisão para prever o valor do avaliador educacional IDEB; Aplicar métricas de extração da importância dos atributos nos modelos preditivos, aplicar também abordagens de IA Explicável (XAI) de forma complementar para validar a influência dos indicadores do IDSC no IDEB e o entendimento do funcionamento do modelo de predição; Avaliar e comparar o desempenho dos modelos e o comportamento das métricas de relevância de atributos entre a base integral e as bases agrupadas.

1.3 JUSTIFICATIVA

Diante da crescente complexidade do cenário social e econômico presente nos municípios brasileiros, a tomada de decisão baseada em evidências se revela essencial para a formulação de políticas públicas. O Brasil apresenta acentuada heterogeneidade entre seus municípios devido à grande extensão territorial e à diversidade cultural e socioeconômica. Dessa forma, a adoção de políticas públicas uniformes tende a ser ineficaz, pois falha em abranger todos os cenários e desafios de cada município brasileiro.

Nesse cenário, técnicas de análise de dados e aprendizado de máquina possibilitam a identificação de padrões complexos entre os indicadores de desenvolvimento sustentável (IDSC) e o Índice de Desenvolvimento da Educação Básica (IDEB). O agrupamento dos municípios conforme características semelhantes permite uma análise refinada e contextualizada conforme a realidade de cada perfil regional. A partir desse agrupamento, a predição do índice fornece uma visão estratégica fundamental aos gestores públicos, permitindo identificar possíveis relações entre fatores sociais e ambientais e o rendimento escolar, o que possibilita a adoção de medidas prévias para a melhoria da educação básica, antes da consolidação do índice oficial.

Para que essa aplicação seja verdadeiramente útil à gestão pública, a predição do modelo deve vir acompanhada da interpretabilidade. A predição com a aplicação de modelos baseados em árvores de decisão permite extrair diretamente a relevância de atributos. Embora amparada pelos conceitos de Inteligência Artificial Explicável (XAI), a análise se concentra no uso dessas métricas para mapear quais fatores do IDSC exercem maior peso sobre o desempenho educacional. Esse diagnóstico quantitativo direciona o poder público para a implementação de políticas em aspectos específicos, solucionando problemas que são a causa principal da desigualdade

escolar.

1.4 METODOLOGIA

Para a realização de todos os objetivos, será necessária uma exploração inicial da base de dados, além de um estudo aprofundado em técnicas de aprendizado supervisionado, não supervisionado e métodos de interpretabilidade de modelos. Essa exploração da base e o estudo teórico visam compreender o cenário e fundamentar a escolha dos algoritmos de aprendizado de máquina, levando em consideração uma separação por agrupamento consistente dos dados e melhores resultados na predição do índice do IDEB. A análise exploratória de dados será realizada com o objetivo de compreender a distribuição dos indicadores e identificar padrões preliminares. Após essa análise, será executado o pré-processamento da base de dados, visando à adequação dos dados para a execução dos modelos de aprendizado de máquina, de forma a garantir a confiabilidade e o desempenho dos algoritmos.

A etapa preditiva inicial consiste na aplicação dos modelos de regressão na base de dados integral para a obtenção de um resultado preditivo de referência. Os modelos aplicados para comparação e análise serão Regressão Linear, para base inicial de comparação por se caracterizar como um modelo mais simples em comparação com os demais, e os algoritmos baseados em árvores de decisão Random Forest e Gradient Boosting, sendo representado neste trabalho pelos algoritmos *Extreme Gradient Boosting*, *Light Gradient Boosting Machine* e *Categorical Boosting*. Logo após, para a identificação de perfis de municípios semelhantes, serão aplicadas técnicas de aprendizado não supervisionado. Nessa etapa de agrupamento, serão analisados e avaliados os algoritmos *K-Means*, Agrupamento Hierárquico e Agrupamento Espacial Baseado em Densidade para Aplicações com Ruído.

A etapa subsequente consiste na realização da predição em cada subconjunto da base de dados, definidos pelo modelo de agrupamento que apresentar o melhor desempenho. Como estratégia de aprendizado supervisionado, serão replicados os mesmos modelos aplicados na base integral, permitindo avaliar e comparar o impacto do agrupamento dos municípios em bases de dados menores na precisão dos resultados. O desempenho dos modelos de predição será avaliado por meio das métricas de Erro Médio Absoluto (MAE), Raiz do Erro Quadrático Médio ($RMSE$) e Coeficiente de Determinação (R^2).

Por fim, a extração da relevância dos atributos ocorrerá por meio de duas abordagens complementares. A primeira consiste na análise das métricas de importância intrínsecas aos algoritmos de árvore, calculadas a partir da redução da variância dos dados nos nós de decisão. Em seguida, para mitigar os vieses estruturais dessas métricas e garantir maior consistência teórica, será adotado o método *TreeSHAP*. Enquanto as métricas nativas oferecem uma perspectiva estrutural de quais indicadores do IDSC foram mais acionados pelos modelos, os valores SHAP quantificam a magnitude e direção do impacto de cada variável. Essa abordagem permite identificar se um indicador atua de forma positiva ou negativa na estimativa do IDEB.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 APRENDIZADO DE MÁQUINA

O Aprendizado de Máquina (*Machine Learning*) é o ramo da Inteligência Artificial focado no desenvolvimento de algoritmos com capacidade de identificar padrões em grandes volumes de dados, com o objetivo de predizer o resultado de um atributo específico. Segundo a definição clássica (Mitchell, 1997), o aprendizado de máquina permite que sistemas melhorem seu desempenho com base na experiência. No estudo apresentado, esses algoritmos são empregados para modelar a relação entre os índices do IDSC e o índice de avaliação do IDEB, sendo responsáveis por estimar a relação matemática entre as variáveis.

2.1.1 Paradigmas de Aprendizado de Máquina

A literatura divide as abordagens de aprendizado de máquina em categorias formadas de acordo com a presença ou ausência de uma variável resposta durante o treinamento. As duas categorias abrangidas neste estudo são o aprendizado supervisionado e o não supervisionado.

O aprendizado de máquina supervisionado, de acordo com (Murphy, 2012), consiste no mapeamento de uma função que conecta um vetor de características de entrada X a uma saída esperada Y, utilizando um conjunto de dados previamente rotulado. O objetivo é aproximar uma função $\hat{f}(X) \approx Y$ que minimize o erro. O processo envolve a divisão dos dados em dois subconjuntos: treino e teste. O conjunto de treino é responsável pelo aprendizado por meio da identificação de padrões e o de teste é responsável por validar a eficácia do modelo, observando dados desconhecidos na fase de treinamento para avaliar seu resultado. Então, o algoritmo aprende a função que mapeia entradas em saídas por meio dos dados rotulados, aprendendo a relação entre as variáveis de entrada e de resposta.

Já o aprendizado não supervisionado, segundo (Bishop, 2006), foca na identificação de estruturas e correlações latentes em bases de dados que não possuem um alvo predefinido. Sem rótulos para guiar o treinamento, os algoritmos operam a partir de propriedades matemáticas dos dados, como proximidade espacial e densidade. Nesse estudo, esse paradigma é empregado no agrupamento dos municípios em perfis conforme suas características.

2.1.2 Técnicas de Agrupamento (*Clustering*)

O agrupamento é a principal tarefa do paradigma não supervisionado. Seu propósito é organizar um conjunto de dados em subconjuntos (ou *clusters*) de forma que os elementos de um mesmo grupo guardem alta similaridade entre si, enquanto elementos de grupos distintos sejam o mais dissimilares possível (Jain, 2010). No campo das políticas públicas, essa técnica evita análises generalistas e revela quais municípios compartilham desafios estruturais parecidos.

2.1.3 K-Means

O algoritmo *K-Means* funciona através de um processo iterativo de atribuição e atualização controlado pelo parâmetro K. A distribuição dos dados ocorre conforme a proximidade de cada ponto em relação ao centroide mais próximo. De acordo com (Lloyd, 1982), o algoritmo é baseado no particionamento em K grupos distintos ao minimizar a soma dos quadrados das distâncias, comumente a distância euclidiana entre cada ponto e o centro de gravidade (centroide) do seu respectivo grupo. Após a atribuição do elemento ao grupo conforme a proximidade com relação ao centroide, este é recalculado por meio da média aritmética de todos os elementos associados ao grupo. Essas etapas se repetem até que os centroides estabilizem.

Considerando um conjunto de dados $X = \{x_1, x_2, \ldots, x_n\} \in \mathbb{R}^d$, em que d representa a dimensionalidade dos atributos, o algoritmo tem como objetivo encontrar um particionamento $S = \{S_1, S_2, \ldots, S_K\}$ que visa minimizar a variância interna dos grupos. Esse problema busca a minimização da função de custo baseada na soma dos quadrados intra-cluster.

O algoritmo de minimização opera em duas etapas a cada iteração: atribuição e atualização. A primeira tem como objetivo vincular cada elemento ao centroide mais próximo, calculado através da distância euclidiana. A segunda etapa, de atualização, recalcula os vetores de centroide de cada grupo, realizando o cálculo da média aritmética de todos os elementos pertencentes ao subconjunto do centroide. Esse processo, eventualmente, converge para um ótimo local.

2.1.4 Agrupamento Hierárquico

Diferente do particionamento direto, o Agrupamento Hierárquico se caracteriza como uma abordagem aglomerativa, criando uma estrutura em árvore denominada dendrograma, permitindo visualizar relações de proximidade em diferentes níveis de granularidade. Conforme (Rokach; Maimon, 2005), o algoritmo inicia como um grupo individual e os funde sucessivamente com base na proximidade. Na abordagem aglomerativa adotada neste trabalho, o algoritmo inicia o processamento tratando cada elemento como um grupo individual. Rodada a rodada, os pares de *clusters* mais próximos são fundidos com base em uma métrica de distância e em um critério de ligação, até que todas as observações estejam unidas em um único bloco.

Para determinar quais elementos devem ser atribuídos aos grupos a cada etapa, o algoritmo calcula a proximidade a cada agrupamento. Um dos métodos mais apresentados na literatura para dados socioeconômicos é o método de Ward. Em vez de medir a distância simples entre pontos, o critério de Ward busca minimizar o aumento da variância interna, ou seja, a soma dos quadrados dos erros que ocorre quando dois grupos são combinados.

2.1.5 Agrupamento Espacial Baseado em Densidade para Aplicações com Ruído (DBSCAN)

O algoritmo *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN) é baseado em densidade. Proposto por Ester et al. (1996), o algoritmo adota uma lógica diferente

ao definir grupos por meio da densidade local de pontos. O algoritmo exige a configuração de dois parâmetros básicos: o raio de vizinhança (ε) e o número mínimo de pontos para formar uma região densa ($MinPts$). A partir desses parâmetros, o algoritmo classifica os dados em três tipos: pontos centrais, pontos de borda e ruídos. Os pontos centrais são elementos que contêm pelo menos $MinPts$ dentro do raio ε; os pontos de borda são caracterizados por elementos que não possuem o mínimo de vizinhos, mas estão dentro do raio de alcance de um ponto central; e os ruídos, que são pontos isolados que não atendem aos critérios anteriores. Dessa forma, o algoritmo isola anomalias (*outliers*), dados fora da distribuição normal que, nesse caso, poderiam distorcer o resultado da predição.

O algoritmo funciona por meio de relações de proximidade espacial dentro de um espaço. A ε-vizinhança de um ponto p, representada por $N_\varepsilon(p)$, define o conjunto de pontos presentes dentro do raio de distância ε, calculada geralmente por meio da distância euclidiana:

$$N_\varepsilon(p) = \{q \in D \mid \text{dist}(p,q) \leq \varepsilon\} \tag{1}$$

A partir desta definição, o algoritmo percorre os grupos juntando pontos que cumprem os requisitos de densidade. Um ponto é considerado diretamente alcançável por densidade se estiver dentro do seu raio de vizinhança e o ponto de origem for central. A partir disso, a alcançabilidade ocorre quando existe uma cadeia sequencial de pontos interconectados ligando um elemento ao outro. Então, dois pontos são considerados conectados por densidade quando compartilham um mesmo ponto central de origem em comum, o que permite ao algoritmo expandir o grupo de forma contínua por áreas densas e isolar os elementos que não se conectam a nenhum grupo.

2.2 MODELOS DE REGRESSÃO E PREDIÇÃO

Modelos de regressão, como técnicas de aprendizado de máquina supervisionado, buscam aproximar uma função contínua $f(X)$ capaz de mapear variáveis preditoras X em uma variável alvo numérica Y. Neste estudo, a matriz X guarda os indicadores do IDSC e Y armazena a nota contínua do IDEB.

2.2.1 Regressão Linear

A Regressão Linear é o modelo clássico para estimativas numéricas (James et al., 2013). Sua premissa é modelar a variável dependente através de uma combinação linear das variáveis independentes, somada a um termo de erro:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \varepsilon \tag{2}$$

Onde β_0 é o intercepto e os demais coeficientes β_i representam os pesos de cada atributo na predição. O ajuste ocorre pelo método dos mínimos quadrados ordinários, que busca os parâmetros capazes de minimizar a distância entre os valores reais e as estimativas geradas. Apesar de não capturar relações não lineares, esse modelo funciona como uma linha de base (*baseline*) para comparar com os demais modelos.

2.2.2 Random Forest

O modelo *Random Forest*, proposto por Breiman (2001), evolui o modelo de árvores de decisão. O modelo cria árvores de decisão independentes; cada árvore opera em um subespaço estocástico, ou seja, apenas uma parte dos dados e uma parte das variáveis. Além disso, cada árvore é treinada com uma amostra diferente dos dados originais, selecionada por amostragem com reposição. Essa técnica garante que cada árvore de decisão aprenda especificidades diferentes do conjunto total.

O algoritmo usa duas estratégias de sorteio: a amostragem com reposição (*Bootstrap*), que significa que cada árvore é treinada com uma amostra diferente extraída do banco de dados, e o subespaço aleatório de atributos, onde, em cada divisão de nós da árvore, a escolha do melhor ponto de corte fica restrita a um grupo sorteado de variáveis, e não a todas. O resultado final do algoritmo *Random Forest* para regressão é a média das predições de todas as árvores.

O processo de construção de cada árvore ocorre de forma recursiva, dividindo os dados em nós hierárquicos. Em tarefas de regressão, o algoritmo determina o ponto de corte em cada nó avaliando qual divisão resulta na maior redução da variância dos dados entre os nós filhos criados. Esse cálculo mede a distância dos valores reais em relação à média local, garantindo que os grupos resultantes sejam o mais homogêneos possível. Ao final do treinamento do modelo, o algoritmo consolida o aprendizado coletando as estimativas numéricas independentes de cada árvore e calculando a média aritmética para gerar a predição final.

2.2.3 Gradient Boosting

O modelo *Gradient Boosting Decision Trees* treina árvores de decisão de forma sequencial, se diferenciando do modelo *Random Forest*, que treina árvores de decisão em paralelo. Conforme (Friedman, 2001), o princípio do modelo é a otimização de uma função de perda através de um ajuste iterativo, onde cada árvore é treinada para prever resíduos das árvores anteriores. Existem três variações que evoluem o algoritmo:

XGBoost (*Extreme Gradient Boosting*): Proposto por Chen e Guestrin (2016), adiciona dois termos de regularização (L_1 e L_2) à função de perda para conter o crescimento exagerado das árvores e reduzir o sobreajuste. Destaca-se ao incorporar técnicas de otimização que aumentam a eficiência computacional e contribuem para a construção de um modelo mais robusto.

LightGBM (*Light Gradient Boosting Machine*): Proposto por Ke et al. (2017) no ecossistema da Microsoft, adota o crescimento das árvores focado nas folhas. Essa estratégia divide o nó que traz a maior redução de erro global, independentemente do nível da árvore.

CatBoost (*Categorical Boosting*): Desenvolvido por Prokhorenkova et al. (2018) na empresa Yandex, possui técnicas matemáticas complexas para o tratamento de variáveis categóricas no treinamento, prevenindo o vazamento de dados (*target leakage*).

2.2.4 Métricas de Avaliação de Modelos de Regressão

Para a validação estatística e a comparação dos modelos preditivos, foram adotadas três métricas:

O Erro Médio Absoluto (*MAE*), que calcula a média das distâncias absolutas entre as predições e os valores reais, medindo a magnitude dos erros em uma escala linear, segundo a equação matemática:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|Y_i - \hat{Y}_i| \tag{3}$$

A Raiz do Erro Quadrático Médio (*RMSE*), que calcula a raiz quadrada da média dos erros elevados ao quadrado. Pelo peso da potenciação, o *RMSE* é mais sensível a grandes desvios, ajudando a detectar se o modelo está cometendo erros em elementos específicos, segundo a fórmula matemática:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2} \tag{4}$$

O Coeficiente de Determinação (R^2) indica a proporção da variação total da variável alvo que o modelo conseguiu explicar a variabilidade observada na variável alvo, funcionando como uma nota geral de ajuste do algoritmo. O cálculo é dado pela fórmula matemática:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} \tag{5}$$

Onde Y_i é o valor real, $\hat{Y}_i$ é a predição, $\bar{Y}$ representa a média dos valores reais e n é o total de observações.

2.2.5 Métricas Nativas de Importância Baseadas em Árvores

Os modelos baseados em árvores de decisão possuem indicadores nativos com o objetivo de quantificar a relevância das variáveis preditoras. Em cenários com a aplicação de modelos de regressão, a principal técnica empregada é a redução de impureza, do inglês *Mean Decrease in Impurity* (MDI). Essa técnica aplica um cálculo baseado na redução da variância presentes nos nós de decisão cada vez que um atributo é elegido para dividir os dados. O grau de importância da variável é o somatório ponderado dos ganhos de pureza, calculado ao longo das ramificações da árvore.

Adicionalmente, modelos *Gradient Boosting* possuem três métricas adicionais para o cálculo da importância do atributo. A primeira é o ganho, que representa a relevância do atributo para melhoria da precisão do resultado do modelo; a métrica é semelhante ao MDI e indica quanto uma função de perda, como o erro quadrático médio, caiu ao introduzir uma divisão baseada na variável avaliada. A segunda é denominada frequência, que contabiliza o número de vezes em que o atributo foi selecionado para realizar pontos de corte ao longo das árvores. Por fim, a última métrica é a cobertura, que mede o número de observações que passaram pelo nó associado à variável observada.

2.2.6 Valores SHAP (*Shapley Additive Explanations*)

A técnica de inteligência artificial explicável SHAP (*Shapley Additive Explanations*), inspirada na Teoria dos Jogos Cooperativos (Shapley, 1953), atribui um Valor de Shapley a cada variável. Esse valor representa a contribuição marginal média de uma variável para a predição do modelo. Diferente das métricas de importância mais tradicionais, essa técnica oferece propriedades matemáticas de consistência e localidade, o que permite tanto uma visão global do comportamento do modelo quanto uma justificativa mais detalhada para predições isoladas (Lundberg; Lee, 2017).

Neste trabalho, utiliza-se a variação *TreeSHAP*, uma versão otimizada para modelos de árvores que calcula esses valores explorando as ramificações dos nós em tempo reduzido (Lundberg et al., 2020). Ao apontar tanto a força quanto a direção do impacto de cada indicador do IDSC, o SHAP enriquece o diagnóstico para a gestão pública, mostrando se um avanço em saneamento, saúde ou renda está melhorando o valor do índice do IDEB ou piorando, seja na visão nacional ou dentro de cada perfil municipal agrupado.

2.3 TRABALHOS CORRELATOS

Conforme revisão bibliográfica realizada, são encontrados diversos estudos com aplicações de algoritmos de aprendizado de máquina em microdados do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) para predição do Índice de Desenvolvimento da Educação Básica (IDEB) e para identificação de quais fatores são determinantes. Em uma escala regional, Soares et al. (Soares et al., 2020) realizam a predição por meio da aplicação de Árvores de Decisão em dados de escolas do estado do Maranhão; o estudo identificou que a escolaridade dos pais foi a variável com maior influência no modelo. Ademais, (Pinto, 2021) adotou técnicas de seleção de atributos nos dados de Alagoas, com o objetivo de reduzir o ruído da base de dados, isolando os dados que realmente impactavam a gestão municipal. Outra abordagem adotada por Silva (Silva, 2022) foi o processo KDD (*Knowledge Discovery in Databases*), empregado para projetar cenários preventivos. O autor argumenta que a ciência de dados deve ser aplicada antes do fechamento dos ciclos de avaliação do governo.

Outro estudo, agora em escala nacional, volta-se para o mapeamento de técnicas e modelos mais robustos. A revisão sistemática da literatura de Feitosa (Feitosa, 2025) documentou os métodos mais adotados nas pesquisas do país, apontando modelos como *Random Forest*, SVM e *Árvores de Decisão* como os algoritmos mais aplicados e com melhor desempenho nessa área de pesquisa. Ainda com a aplicação de modelos baseados em árvores, Barros et al. (Barros; Santos; Souza, 2024) combinaram *Gradient Boosting* com a abordagem SHAP (XAI) para adicionar interpretabilidade ao modelo, medindo o impacto de atributos com distorção entre a idade e série do aluno ou falta de laboratórios nas escolas. Por fim, Santos e Oliveira (Santos; Oliveira, 2023) empregaram modelo de rede neural *Multilayer Perceptron*, Regressão linear e *K*-NN. Os autores chegaram à conclusão de que o uso dos microdados disponibilizados

pelo Censo Escolar resulta em predições mais estáveis do que os dados brutos do Sistema de Avaliação da Educação Básica.

O que diferencia esse trabalho da linha de pesquisa dos estudos presentes na literatura é o foco em dados externos ao ambiente escolar para predição da qualidade escolar da educação básica. Enquanto a maior parte das pesquisas explora exclusivamente os dados disponibilizados pelo INEP, o presente estudo avalia o impacto direto dos indicadores do Índice de Desenvolvimento Sustentável das Cidades (IDSC) sobre a nota do IDEB. Além disso, a metodologia integra técnicas de agrupamento para definir os perfis de município, o que permite segmentar a base de dados e entender como os fatores afetam cada subconjunto de dados.

3 PREDIÇÃO DO IDEB MUNICIPAL COM MODELOS DE APRENDIZADO DE MÁQUINA EXPLICÁVEIS E INDICADORES DE DESENVOLVIMENTO SUSTENTÁVEL

A predição do Índice de Desenvolvimento da Educação Básica (IDEB) em âmbito municipal, aplicando modelos em uma base de dados com indicadores exógenos de desenvolvimento sustentável, fornece aos gestores públicos uma ferramenta preditiva e interpretável auxiliando na adoção de políticas públicas educacionais. Portanto, esse trabalho propõe através do uso de modelos de aprendizado de máquina, modelar o impacto do Índice de Desenvolvimento Sustentável das Cidades (IDSC) na qualidade da educação dos municípios brasileiros, de forma complementar empregar métricas de avaliação da importância de atributos e inteligência artificial explicável (XAI) para interpretabilidade do modelo.

Com o objetivo de validar a melhor abordagem para um problema de regressão, a previsão do valor contínuo do indicador, serão testados modelos baseados em árvore de decisão como *Random Forest*, *XGBoost*, *LightGBM*, *CatBoost* e modelo de Regressão Linear como linha de base para comparação. O critério de avaliação do desempenho dos modelos baseia-se em métricas como o Erro Quadrático Médio (MSE), Erro Absoluto Médio (MAE) e o Coeficiente de Determinação (R^2). Para servir de aplicação eficaz ao como auxílio no desenvolvimento da educação, esse cenário exige explicabilidade, sendo assim, necessárias as aplicações de métricas de importância dos atributos e ferramenta de XAI como o Valor SHAP.

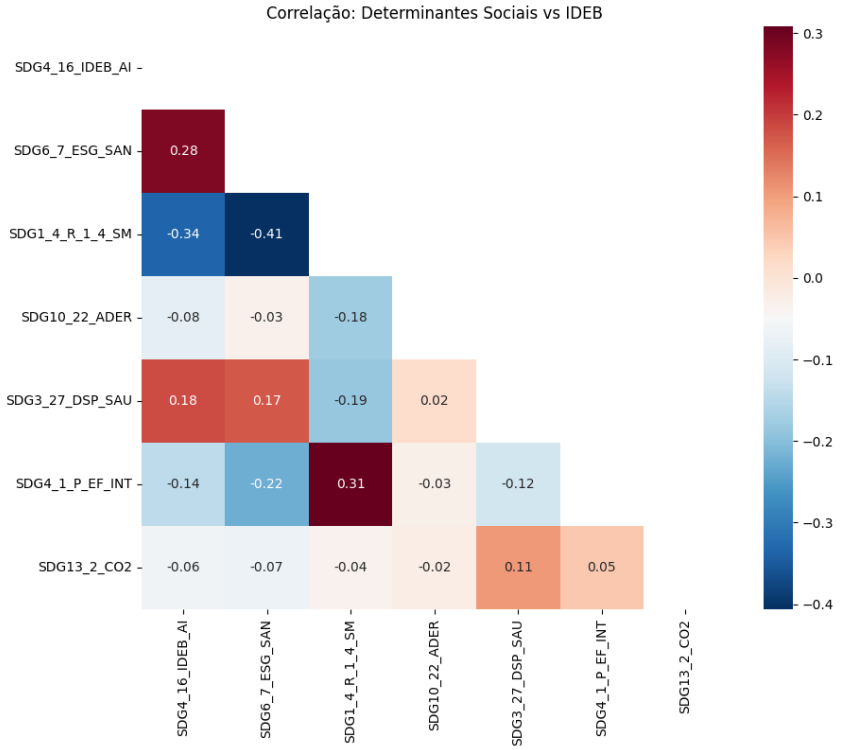
A primeira etapa é o pré-processamento da base de dados, realizando o tratamento de dados ausentes. Logo após, o conjunto de dados será dividido entre subconjunto de treinamento e teste, adotando método de validação cruzada *Holdout*, reservando 80% das observações municipais para treinamento do modelo e 20% para a avaliação de generalização em dados não vistos. A predição será realizada inicialmente com a base completa com indicadores de cada município.

3.0.1 Análise Exploratória de Dados (EDA)

Foram apresentadas informações significativas conforme realizada análise exploratória de dados. Em um primeiro momento foi extraída a matriz de correlação linear entre variáveis dos indicadores IDSC e o índice do IDEB. Apresentadas as correlações, identifica-se uma correlação de $-0,34$ entre a variável do IDEB (SDG4_16) e a variável que identifica baixa renda (SDG1_4). Além disso, outro valor de correlação expressivo é o de $-0,41$ entre a variável de acesso ao saneamento básico (SDG6_7) e baixa renda. A análise da matriz de correlação evidenciou que os indicadores socioeconômicos apresentam associação com o índice do IDEB, porém essa análise identifica apenas relações lineares, se faz necessário o uso de modelos para identificar relações não lineares. A Figura 1 apresenta a matriz de correlação das variáveis citadas.

Conforme observado na Figura 2, ao lado esquerdo do gráfico o cenário de menor vulnerabilidade socioeconômica apresenta maior dispersão de dados, isso indica que ao estabilizar

Figura 1 – Matriz de correlação linear entre indicadores do IDSC e o IDEB.



Fonte: A autora, 2026.

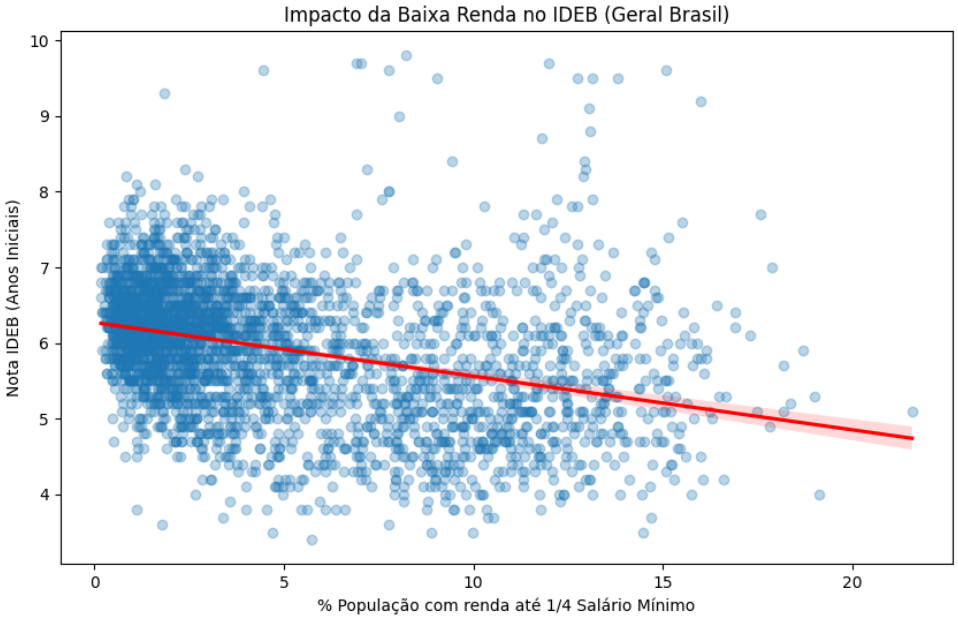
a renda da população outros fatores possuem maior importância no desempenho do índice de qualidade da educação básica. A linha de tendência central tenta resumir o comportamento nacional, levando em conta todos os municípios presentes na base completa, mas não abrange dados de municípios que se comportam como *outliers* positivos.

A Análise Exploratória de Dados evidencia o comportamento da base de dados, demonstrando heterogeneidade dos dados dos municípios brasileiros. Esse comportamento demanda uma estratégia de segmentação da base, no caso deste estudo agrupamento da base de dados conforme perfil do município, levando em conta fatores socioeconômicos, PIB per capita, acesso à saúde e saneamento básico, infraestrutura, etc.

Após um resultado inicial da predição a base de dados será segmentada, serão aplicados modelos de agrupamento, de forma mais específica *K*-Means, Agrupamento Hierárquico e Agrupamento Espacial Baseado em Densidade para Aplicações com Ruído. A predição também será realiza nos subconjuntos, nessa etapa também é necessária a avaliação da precisão do resultado dos modelos conforme as métricas citadas anteriormente. Durante o treinamento dos modelos de árvore, a relevância inicial dos atributos será medida de por meio das métricas nativas de ganho e redução média de impureza (MDI), calculadas com base na redução da variância nos nós de decisão a cada divisão introduzida pelas variáveis do IDSC.

Nas etapas subsequentes, ambos os resultados mais precisos do modelo de melhor desempenho aplicado na base completa dos dados e nas bases segmentadas, serão calculadas as métricas de importância de atributos nativas de modelos baseados em árvores de decisão como a

Figura 2 – Gráfico de dispersão entre o indicador de Baixa Renda (eixo x) e o IDEB (eixo) com linha de tendência linear.



Fonte: A autora, 2026.

Redução de Impureza. De forma complementar, a abordagem ainda intregrará o framework SHAP (*Shapley Additive Explanations*). Ambas as técnicas serão empregadas para explicabilidade do modelo. Ao final do desenvolvimento da abordagem proposta, serão disponibilizados os fatores da infraestrutura municipal que mais penalizam ou auxiliam o fluxo e o aprendizado escolar.

4 CONCLUSÃO

Este trabalho apresenta uma abordagem de apoio à gestão educacional por meio da empregabilidade de técnicas de inteligência artificial e ciência de dados como modelos de aprendizado de máquina. Essa abordagem tem o intuito de proporcionar aos gestores o entendimento de fatores socioeconômicos e estruturais externos à sala de aula que afetam diretamente o aprendizado dos alunos e por consequência a qualidade da educação básica municipal. Para então servir de auxílio na elaboração de políticas públicas eficientes.

Conforme detalhado nos trabalhos correlatos é perceptível a diferença da abordagem proposta com relação a abordagem apresentada nesse trabalho. A principal diferença é o uso de uma base de dados muito diferente da utilizada com microdados do INEP, nessa abordagem, utiliza-se a base de dados do Índice de Desenvolvimento Sustentável das Cidades, focada nos indicadores sustentáveis de cada município brasileiro. Além disso, a abordagem emprega modelos de aprendizado não supervisionado para agrupamento de dados conforme o mapeamento das características semelhantes, formando assim subconjuntos de dados conforme perfis socioestruturais dos municípios. A abordagem ainda se destaca ao trazer explicabilidade do modelo através da aplicação de técnicas como as métricas de importância de atributos e inteligência artificial explicável.

REFERÊNCIAS

BARROS, A. B.; SANTOS, C. D.; SOUZA, E. F. Análise de explicabilidade no desempenho escolar utilizando SHAP. **Brazilian Journal of Development**, v. 10, n. 2, p. 4510–4528, 2024. Citado na página 24.

BISHOP, Christopher M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006. Citado na página 19.

BREIMAN, Leo. Random forests. **Machine Learning**, Springer, v. 45, n. 1, p. 5–32, 2001. Citado na página 22.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco, California: ACM, 2016. p. 785–794. Citado na página 22.

ESTER, Martin et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In: **Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)**. Portland, Oregon: [s.n.], 1996. p. 226–231. Citado na página 20.

FEITOSA, T. C. Aplicações de aprendizagem de máquina com dados do INEP: Uma revisão de literatura. In: SOCIEDADE BRASILEIRA DE COMPUTAçãO (SBC). **Anais do XXIV Congresso Brasileiro de Informática na Educação (CBIE)**. Porto Alegre, RS, 2025. p. 120–131. Disponível em: https://sol.sbc.org.br/index.php/ctrle/article/view/40463. Citado na página 24.

FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, JSTOR, v. 29, n. 5, p. 1189–1232, 2001. Citado na página 22.

JAIN, Anil K. Data clustering: 50 years beyond k-means. **Pattern Recognition Letters**, Elsevier, v. 31, n. 8, p. 651–666, 2010. Citado na página 19.

JAMES, Gareth et al. **An Introduction to Statistical Learning: with Applications in R**. New York: Springer, 2013. Citado na página 21.

KE, Guolin et al. Lightgbm: A highly efficient gradient boosting decision tree. In: **Advances in Neural Information Processing Systems 30 (NIPS 2017)**. [S.l.]: Curran Associates, Inc., 2017. p. 3146–3154. Citado na página 22.

LLOYD, Stuart. Least squares quantization in pcm. **IEEE Transactions on Information Theory**, v. 28, n. 2, p. 129–137, 1982. Citado na página 20.

LUNDBERG, Scott M. et al. From local explanations to global understanding with explainable ai for trees. **Nature Machine Intelligence**, Nature Publishing Group, v. 2, n. 1, p. 56–67, 2020. Citado na página 24.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30 (NIPS 2017)**. Long Beach, California: [s.n.], 2017. p. 4765–4774. Citado na página 24.

MITCHELL, Tom M. **Machine Learning**. New York: McGraw-Hill, 1997. Citado na página 19.

MURPHY, Kevin P. **Machine Learning: A Probabilistic Perspective**. Cambridge: MIT Press, 2012. Citado na página 19.

PINTO, Glevson da Silva. **Modelo de análise e predição para identificação dos fatores que influenciam o desempenho escolar na rede de ensino básico: estudo de caso em escolas municipais de Alagoas**. Dissertação (Dissertação de Mestrado) — Universidade Federal de Alagoas (UFAL), Maceió, AL, 2021. Disponível em: https://www.repositorio.ufal.br/handle/riufal/7782. Citado na página 24.

PROKHORENKOVA, Liudmila et al. Catboost: unbiased boosting with categorical features. In: **Advances in Neural Information Processing Systems 31 (NeurIPS 2018)**. [S.l.]: Curran Associates, Inc., 2018. p. 6639–6649. Citado na página 22.

ROKACH, Lior; MAIMON, Oded. **Data mining with decision trees: theory and applications**. Singapore: World Scientific, 2005. Citado na página 20.

SANTOS, J. M.; OLIVEIRA, R. A. Predição numérica do IDEB através de modelos de regressão. **Revista Brasileira de Estudos Pedagógicos**, v. 104, p. e5320, 2023. Citado na página 24.

SHAPLEY, Lloyd S. A value for n-person games. In: **Contributions to the Theory of Games (AM-28)**. Princeton: Princeton University Press, 1953. v. 2, p. 307–318. Citado na página 24.

SILVA, Ivonaldo Vicente da. **Mineração de Dados para Descoberta de Fatores Preditivos do IDEB**. Tese (Tese de Doutorado) — Universidade Paulista (UNIP), São Paulo, SP, 2022. Disponível em: https://repositorio.unip.br/engenharia-dissertacoes-teses/mineracao-de-dados-para-descoberta-de-fatores-preditivos-de-sucesso-em-avaliacoes-de-larga-escala-dos-a Citado na página 24.

SOARES, Raimundo de Castro et al. Minerando dados para entender os fatores de influência da qualidade educacional do maranhão. **Revista Brasileira de Informática na Educação (RBIE)**, v. 28, p. 854–878, 2020. Disponível em: https://journals-sol.sbc.org.br/index.php/rbie/article/view/2831. Citado na página 24.

SUSTENTáVEIS, Instituto Cidades. Índice de desenvolvimento sustentável das cidades - brasil (idsc-br). 2023. Disponível em: https://idsc.cidadessustentaveis.org.br/. Citado na página 15.

TEIXEIRA, Instituto Nacional de Estudos e Pesquisas Educacionais Anísio. Índice de desenvolvimento da educação básica (ideb). 2024. Disponível em: https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/ideb. Citado na página 15.

UNIDAS, Organização das Nações. Transformando nosso mundo: A agenda 2030 para o desenvolvimento sustentável. 2015. Disponível em: https://brasil.un.org/sites/default/files/2020-09/agenda2030-pt-br.pdf. Citado na página 15.

GLOSSÁRIO

Ardósia: Rocha metamórfica sílico-argilosa formada pela transformação da argila sob pressão e temperatura, endurecida em finas lamelas.

Arenito: rocha sedimentária de origem detrítica formada de grãos agregados por um cimento natural silicoso, calcário ou ferruginoso que comunica ao conjunto em geral qualidades de dureza e compactação.

Feldspato: grupo de silicatos de sódio, potássio, cálcio ou outros elementos que compreende dois subgrupos, os feldspatos alcalinos e os plagioclásios.

APÊNDICE A – TÍTULO

ANEXO A – TÍTULO

ÍNDICE

Andesito, 22, 50, 73
Argila, 52, 75, 121
Basalto, 25, 230, 235